



DOCTORADO EN CIENCIAS EN
SISTEMAS DIGITALES

TESIS

*Análisis de Datos Clínicos
del VIH mediante Optimización
Cuántica*

Juan Pablo Acuña González

Tijuana, Agosto de 2026

Índice general

Agradecimientos	II
Resumen	III
Abstract	IV
Índice de Figuras	VI
Índice de Tablas	VIII
1. Introducción	1
1.1. Planteamiento del Problema	3
1.2. Justificación	5
1.3. Objetivos	6
1.4. Hipótesis	6
2. Estado del Arte	7
2.1. Modelos Predictivos Clásicos en VIH	7
2.2. Teoría de Juegos Cuánticos en VIH	14
2.3. Modelos Predictivos Cuánticos	17
3. Materiales y Métodos	20
3.1. Cohorte de Estudio y Base de Datos Clínica	20
3.2. Cálculo de Interacciones de Competencia	22
3.3. Modelación de Biomarcadores Clínicos	29
3.4. Entorno de Trabajo y Reproducibilidad	31
4. Resultados	32
4.1. Estadística Descriptiva de la Cohorte Clínica	32
4.2. Clasificación de Interacciones Fenotípicas	37
4.3. Biomarcadores Clínicos de la competencia de CD4 y carga viral	41
5. Discusión y Conclusiones	51
5.1. Contraste Metodológico	51
5.2. Interpretación Clínica de las Interacciones en qphen	53
5.3. Limitaciones	57
5.4. Conclusión	58
A. Apéndice: Ingeniería de Características	59
A.1. Qvirus	59
A.2. Base de Datos y Cohorte de Estudio	59
A.3. Interacciones de Competencia	59
A.4. Clasificación de Interacciones	59

A.5. Estimación de Parámetros	59
A.6. Simulación del Algoritmo del Beneficio más Cercano	60
B. Apéndice: Modelación Clásica de Regresión	62
B.1. Regresión sobre el conjunto de entrenamiento	62
B.2. Regresión sobre el conjunto de prueba	66
B.3. Explicador del Modelo de Regresión Lasso	71
B.4. Dominio de Aplicabilidad para la Competencia de CD4	71
B.5. Aprendizaje por Conjuntos	72
B.6. Explicador del Modelo de Bosque Aleatorio	74
B.7. Dominio de Aplicabilidad para la Competencia de Carga Viral	74
Bibliografía	75

Agradecimientos

La realización de esta tesis ha sido posible gracias al apoyo constante, la inspiración y los conocimientos compartidos por muchas personas y herramientas fundamentales que me acompañaron durante este camino.

En primer lugar, deseo expresar mi más profundo agradecimiento a mis directores/as y docentes, quienes con su guía y confianza me impulsaron a enfrentar retos conceptuales, metodológicos y técnicos con rigor y creatividad.

Gracias también a mis compañeras y compañeros por sus conversaciones esclarecedoras, por sus preguntas difíciles y por ayudarme a mantener la curiosidad encendida.

Finalmente, dedico este trabajo a mi familia y seres queridos, quienes con paciencia y cariño me acompañaron en este viaje. Su apoyo ha sido el verdadero entorno de desarrollo que hizo esta tesis posible.

Resumen

Esta tesis aborda la falta de datos clínicos completos en pacientes con VIH, particularmente en relación con los linfocitos T CD4 y la carga viral. La carencia de estos datos puede conducir a diagnósticos incompletos y decisiones médicas deficientes. Se propone el uso de algoritmos cuánticos para simular con precisión los valores faltantes, lo que beneficiaría a los médicos tratantes y mejoraría la atención médica de esta población vulnerable. Los objetivos del estudio incluyen analizar la dinámica de los linfocitos T CD4 y la carga viral, estudiar la evolución numérica de estos indicadores y probar diferentes algoritmos para predecir estos valores y mejorar la calidad de la atención médica para personas que viven con VIH.

Abstract

This thesis addresses the lack of complete clinical data in HIV patients, particularly regarding CD4 T cells and viral load. The absence of these data can lead to incomplete diagnoses and sub optimal medical decisions. The use of quantum algorithms is proposed to accurately estimate missing values, benefiting treating physicians and enhancing medical care for this vulnerable population. The study aims to analyze CD4 T cell and viral load dynamics, study the numerical evolution of these indicators, and test different models to predict these values, thereby improving the quality of healthcare for people living with HIV.

Índice de figuras

3.1. Distribución de la frecuencia de registros longitudinales de linfocitos T CD4 por grupo de estudio. El histograma muestra la disparidad en la cantidad de mediciones disponibles entre los pacientes incluidos en el análisis (que permiten el cálculo de dinámicas temporales) y los excluidos por presentar un registro único.	22
3.2. Distribución de la frecuencia de registros longitudinales de carga viral por grupo de estudio. Se ilustra la estructura de la muestra según la disponibilidad de datos longitudinales, diferenciando entre los pacientes con capacidad de seguimiento clínico para el modelo de competencia fenotípica (Incluido) y aquellos con mediciones insuficientes para dicho cálculo (Excluido). . . .	22
4.1. Distribuciones de las interacciones de competencia. La falta de normalidad en las colas dificultan la implementación de métodos estadísticos clásicos de modelación.	35
4.2. Método del codo con 4 conglomerados.	38
4.3. Clasificación de interacciones fenotípicas.	40
4.4. Comparación del desempeño de modelos (KNN, RF, Regresión Penalizada, SVM) mediante validación cruzada y evaluación de la capacidad predictiva del mejor modelo seleccionado para la competencia de CD4 sobre el conjunto de entrenamiento.	43
4.5. Evaluación comparativa del desempeño de los modelos en el esquema de partición entrenamiento-prueba para la competencia de CD4. Se ilustra la métrica RMSE, la correlación entre valores observados vs. predichos y la comparación de errores para detectar sobreajuste.	43
4.6. Explicador global para el modelo de regresión aplicado a competencia de CD4. El modelo penalizado identifica al beneficio más cercano en el modelo cuñantico y a los beneficios esperados por el modelo clásico como los factor más relevantes, superando incluso a marcadores clínicos de alta severidad como la presencia de genorresistencia o coinfección por tuberculosis.	44
4.7. Comparación y validación cruzada de modelos aplicada a la competencia de carga viral sobre el conjunto de entrenamiento, mostrando la estabilidad del RMSE y el comportamiento de las predicciones frente a los valores reales.	46
4.8. Evaluación final del modelo de bosque aleatorio para competencia de carga viral en el conjunto de prueba y consistencia del RMSE entre los conjuntos de entrenamiento y prueba.	47

4.9.	Explicador global para el modelo de regresión aplicado a competencia de carga viral. El modelo penalizado identifica al beneficio más cercano en el modelo cuántico y a los beneficios esperados por el modelo clásico como los factor más relevantes, superando incluso a marcadores clínicos de alta severidad como la presencia de genorresistencia o coinfección por tuberculosis.	49
5.1.	Marco de reglas de decisión clínica estructurado según la jerarquía de importancia de variables en los modelos Lasso y Random Forest bajo la transformación qphen .	55

Índice de tablas

1.1. Resumen de porcentajes de faltantes y recuentos válidos para CD4 y carga viral.	4
3.1. Análisis de sensibilidad y comparación de distribuciones entre la cohorte completa y la depurada.	21
4.1. Resumen estadístico de recuentos de linfocitos T CD4.	33
4.2. Resumen estadístico de cargas virales.	33
4.3. Resumen estadístico de interacciones de competencia para linfocitos T CD4 y carga viral.	34
4.4. Análisis de Patrones de Datos Faltantes.	36
4.5. Fenotipo evolutivamente estable del juego.	37
4.6. Resumen estadístico de variables para la clasificación de interacciones. . . .	38
4.7. Clasificación de interacciones de competencia.	38
4.8. Comportamientos fenotípicos esperados en la clasificación.	39
4.9. Parámetros del modelo de juegos cuánticos para las interacciones fenotípicas del VIH.	41
4.10. Asignación de estrategias y puertas cuánticas para pacientes con coinfección por tuberculosis.	41
4.11. Rendimiento consolidado de los modelos para la competencia de CD4 mediante 10 semillas.	42
4.12. Rendimiento consolidado de los modelos para la competencia de carga viral mediante 10 semillas.	42
4.13. Tabla de resultados de la evaluación comparativa del desempeño para la competencia de CD4 en conjunto de prueba.	44
4.14. Tabla de resultados de la clasificación de fenotipos para la competencia de CD4.	45
4.15. Resumen del dominio de aplicabilidad para el modelo de regresión penalizada en la predicción de competencia de CD4, evaluando la distancia de las observaciones de prueba respecto al espacio de entrenamiento.	46
4.16. Resumen de las métricas finales de rendimiento del modelo de ensamble para la predicción de competencia de CD4, superando a los modelos individuales en términos de RMSE y coeficiente de determinación.	46
4.17. Tabla de resultados de la evaluación comparativa del desempeño para la competencia de carga viral en conjunto de prueba.	47
4.18. Tabla de resultados de la clasificación de fenotipos para la competencia de carga viral.	49

4.19. Resumen del dominio de aplicabilidad para el modelo de regresión penalizada en la predicción de competencia de carga viral, evaluando la distancia de las observaciones de prueba respecto al espacio de entrenamiento.	50
5.1. Comparativa del rendimiento predictivo entre el estado del arte y la metodología qphen.	52

Capítulo 1

Introducción

En los últimos años, el poder de la computación cuántica ha aumentado de manera constante, lo que ha resultado en un creciente interés por los algoritmos cuánticos. Para que la comunidad en crecimiento pueda avanzar en esta tecnología emergente, es fundamental contar con marcos de trabajo y herramientas accesibles, ya que uno de los factores limitantes en las tareas computacionales cuánticas, sigue siendo es el número de qubits disponibles ([IBM, 2025](#)).

El término Cuántica Ruidosa de Escala Intermedia (NISQ) se usa para describir la era actual de procesadores cuánticos, pues aún no son lo suficientemente avanzados para ser tolerantes a fallos ni lo suficientemente grandes para alcanzar la ventaja cuántica. Sin embargo, con la ruta de desarrollo tecnológico de IBM y otras compañías, se prevé que la computación cuántica logre una mejor estabilidad y escalabilidad en los próximos años ([IBM, 2025](#); [Paliulis, 2024](#)).

IBM Quantum, Google Quantum AI ([Google Quantum AI, 2025](#)), Azure Quantum ([Microsoft Azure Quantum, 2025](#)), Amazon Braket ([Amazon Web Services, 2024](#)) y Nvidia CuQuantum ([NVIDIA, 2025](#)) son algunas de las soluciones de computación cuántica más conocidas y accesibles al público, operando en diferentes tipos de hardware cuántico. Aquí es importante hacer una distinción clave: la computación cuántica puede realizarse a través de simulaciones en entornos locales o en la nube, o bien ejecutarse en una computadora cuántica real. Esto requiere soluciones de software compatibles con ambas opciones o especializadas en tareas particulares.

Por ejemplo, Qiskit ([Qiskit Development Team, 2024](#); [Aleksandrowicz et al., 2019](#)), un paquete de desarrollo de software en Python ([van Rossum y the Python Development Team, 2024](#)), proporciona soporte para primitivas nativas, servicios en la nube y hardware cuántico, así como simuladores locales. A pesar de su versatilidad, Qiskit sigue estando altamente vinculado a IBM, lo que lo hace dependiente de esta plataforma. En contraste el marco de trabajo PennyLane ([Xanadu Quantum Technologies, 2024](#); [Bergholm et al., 2018](#)), también en Python, es independiente del hardware y permite el uso de algoritmos variacionales mediante circuitos parametrizados.

Por otro lado, la computación cuántica en R ([R Core Team, 2016](#); [Team, 2024](#)) ha avanzado significativamente en los últimos años, consolidándose como un entorno viable para la exploración de algoritmos cuánticos en aplicaciones biomédicas. Diversos paquetes han sido desarrollados para expandir las capacidades de simulación, optimización y descubri-

miento de herramientas de computación cuántica dentro de este ecosistema. Entre ellos, `qsimulatR` ([Ostmeier y Urbach, 2023](#)) proporciona herramientas de simulación cuántica en R, permitiendo la construcción y manipulación de circuitos cuánticos; `QCSimulator` ([Ganesh, 2016](#)) es un simulador de 5 qubits que permite evaluar circuitos con compuertas de 1 y 2 qubits, ideal para experimentación conceptual; `QuantumOps` ([Resch, 2020](#)) facilita la gestión de estados y puertas cuánticas; mientras que `QGameTheory` ([Ghosh, 2020](#)) permite la implementación de teoría de juegos cuánticos, un enfoque particularmente útil para modelar dinámicas de interacción en sistemas biológicos complejos, como las respuestas fenotípicas del Virus de la Inmunodeficiencia Humana (VIH). Además, `QWDAP` ([Pan y Yu, 2024](#)) se centra en métodos variacionales para la optimización cuántica, lo que amplía el potencial de estrategias computacionales en problemas biomédicos.

Bajo esta perspectiva, la teoría de juegos cuánticos ha sido utilizada para representar la supervivencia del VIH a nivel molecular, considerando reglas de la mecánica cuántica para describir procesos evolutivos ([Özlüer Başer, 2022](#)). Paralelamente, los algoritmos variacionales, como el Eigensolver Variacional Cuántico (VQE), han demostrado ser eficaces en la simulación molecular mediante la minimización de la energía fundamental en sistemas representados como Hamiltonianos cuánticos ([Peruzzo et al., 2014](#)).

El VQE ha demostrado su utilidad optimizando estructuras biomoleculares, incluyendo técnicas con ansatzes de bajo costo computacional ([The Qiskit Nature developers and contributors, 2023](#); [Anaya y Delgado, 2022](#); [Casares et al., 2022](#); [Robert et al., 2021](#)). La adaptación de modelos biomédicos para encontrar configuraciones de mínima energía en un sistema de Hamiltonianos derivados de variables de carga viral y linfocitos T CD4, puede proporcionar representaciones más informativas que los modelos clásicos para predecir estados fenotípicos y respuesta a Terapia Anti Retroviral (ART).

A escala epidemiológica, los primeros pasos empíricos hacia las aplicaciones cuánticas en la salud poblacional fueron demostrados por Don Roosan y su grupo de investigación en su aplicación del Algoritmo de Optimización Aproximada Cuántica (QAOA) para la predicción de conglomerados de VIH ([Roosan et al., 2025f](#)). Esta investigación introdujo un enfoque de aceleración cuántica para la vigilancia del VIH, replanteando la detección de conglomerados como un problema de Optimización Binaria Cuadrática (QUBO) sin restricciones. Utilizando QAOA, el método alcanzó una precisión de agrupamiento del 92 % en 1.6 segundos, superando a los enfoques clásicos basados en algoritmos no supervisados. Paralelamente, en [Roosan et al. \(2025f\)](#), una Red Neuronal Cuántica (QNN) híbrida alcanzó una precisión de pronóstico del 94 % para la prevalencia del VIH, superando a su contraparte puramente clásica. Cabe destacar que las redes bayesianas cuánticas revelaron el papel causal de la inestabilidad de la vivienda y el estigma en la aparición y expansión de conglomerados, destacando los determinantes estructurales de la enfermedad ([Roosan et al., 2025f](#)). Este estudio demuestra el potencial de la computación cuántica para ir más allá de las aplicaciones a escala molecular hacia el modelado a nivel poblacional, informando así las estrategias de prevención, la asignación de recursos para la Profilaxis Pre Exposición (PrEP) y las intervenciones que abordan las desigualdades estructurales.

Investigadores del Merrimack College, dirigidos por Roosan, han realizado contribuciones significativas en este campo, con especial atención a la aplicación de la computación cuántica y el Aprendizaje Automático Cuántico (QML) a problemas complejos en biología y medicina clínica. Su trabajo abarca diversos algoritmos y arquitecturas cuánticas a escala molecular, demostrando cómo los métodos cuánticos para interacciones biomolecu-

lares complejas pueden predecir la afinidad de unión proteína-ligando mediante el mapeo de las interacciones moleculares en un espacio de Hilbert de alta dimensión, capturando relaciones complejas con menos parámetros, a la par o incluso mejor que los modelos clásicos (Roosan et al., 2025a). Esto se complementa con la simulación cuántica para el análisis estructural de proteínas, que investigó la estabilidad estructural de las proteínas implicadas en trastornos neurodegenerativos e identificó regiones para las interacciones proteína-proteína (Roosan et al., 2025e). Además, se desarrolló un modelo de regresión cuántica para predecir la toxicidad de compuestos herbales, integrando datos moleculares y farmacocinéticos para lograr errores de predicción más bajos que la regresión lineal clásica y los modelos de bosque aleatorio (Roosan et al., 2025c). Su investigación también destaca cómo una QNN híbrida puede superar a una Red Neuronal Líquida (LNN) clásica en la reutilización de fármacos al aprovechar la codificación de amplitud y los mapas de características para analizar bases de datos de fármacos (Roosan et al., 2025b).

A partir de estos avances, el grupo de Roosan demostró además el poder de un modelo cuántico de transformador variacional para una mejor clasificación del cáncer, utilizando un enfoque híbrido para capturar patrones genómicos complejos con mayor eficacia que los modelos de transformador clásicos, lo que resultó en una menor clasificación errónea de tipos de cáncer complejos (Roosan et al., 2026). También desarrollaron un prototipo para la reutilización de fármacos utilizando datos ómicos, integrando el Análisis Cuántico de Componentes Principales (QPCA) y los métodos de kernel cuántico para lograr una agrupación más precisa y un mejor rendimiento en comparación con los enfoques clásicos, especialmente al combinarse con Modelos de Lenguaje Grande (LLM) (Roosan et al., 2025d). En conjunto, estos estudios establecen un contexto fundamental para el presente trabajo, demostrando la capacidad de los métodos QML para abordar desafíos complejos en la investigación biológica y clínica.

1.1. Planteamiento del Problema

La falta de datos clínicos completos en la atención médica de PLWH dificulta la toma de decisiones médicas fundamentadas, lo que puede llevar a diagnósticos incompletos y tratamientos inadecuados. La medición precisa de linfocitos T CD4 y la carga viral (VL) es esencial para guiar las decisiones clínicas. Por lo tanto, es necesario desarrollar modelos que permitan la estimación de valores faltantes y la mejora de la precisión de las evaluaciones clínicas. Los algoritmos de clasificación cuántica ofrecen una alternativa prometedora a los enfoques clásicos, ya que pueden manejar problemas de optimización y aprendizaje de manera más eficiente.

En la cohorte de PLWH analizada en esta tesis, con $n = 213$ y calculando NAs/213 por periodo, muestra que el panorama es más severo de lo que una cohorte con datos faltantes sugiere habitualmente en la literatura, como se ilustra en la Tabla 1.1. En promedio, se cuenta con 80.8 % (CD4) y 81.9 % (VL) de faltantes por periodo. Solo 2-3 de 17 periodos bajan de 50 %. 12 de 17 periodos (70.6 %) superan el 80 % en ambos marcadores. Y 8 de 17 periodos por marcador tienen n válido ≤ 8 (incluyendo dos con $n=1$ y varios con $n=2$).

La literatura sobre imputación de datos faltantes en cohortes clínicas de VIH converge en tres familias de métodos, cada una con limitaciones documentadas que resultan directamente relevantes para los registros longitudinales de CD4 y carga viral analizados en este trabajo.

Tabla 1.1: Resumen de porcentajes de faltantes y recuentos válidos para CD4 y carga viral.

Periodo	% Falt. CD4	N Válido CD4	% Falt. VL	N Válido VL
2018_1	99.1 %	29	99.1 %	29
2018_2	99.5 %	19	99.5 %	19
2019_1	99.1 %	29	99.1 %	29
2019_2	99.1 %	29	99.1 %	29
2020_1	82.2 %	38	82.2 %	38
2021_1	85.4 %	31	86.4 %	29
2021_2	60.6 %	84	63.8 %	77
2021_3	99.1 %	2	99.1 %	2
2022_1	82.2 %	38	83.1 %	36
2022_2	38.0 %	132	42.3 %	123
2022_3	96.2 %	8	98.1 %	4
2023_1	96.2 %	8	97.7 %	5
2023_2	72.8 %	58	72.3 %	59
2023_3	26.8 %	156	29.6 %	150
2024_1	47.9 %	111	52.1 %	102
2024_2	91.5 %	18	91.1 %	19
2024_3	97.2 %	6	98.6 %	3

La imputación múltiple por ecuaciones encadenadas (MICE) es el enfoque más establecido ([Jakobsen et al., 2017](#)). [Jakobsen et al. \(2017\)](#) señalan que el análisis de casos completos solo es defendible con menos del 5 % de valores faltantes, y que proporciones superiores al 40 % sobre variables importantes reducen los resultados a un carácter meramente generador de hipótesis. [Brummel et al. \(2022\)](#) aplicaron MICE mediante un modelo mixto lineal longitudinal (intercepto y pendiente aleatorios por edad y esquema antirretroviral) para imputar carga viral en la cohorte pediátrica PHACS-AMP, recurriendo a su vez a ecuaciones encadenadas para el conteo de CD4 como covariable auxiliar; su estudio de simulación muestra que el sesgo bajo MCAR y MAR se reduce prácticamente a cero con un modelo de imputación correctamente especificado, pero que bajo MNAR el sesgo persiste incluso con dicho modelo (por ejemplo, -62.4% para la edad de carga viral máxima usando solo datos observados, frente a 7.9% con el modelo correcto). En un contexto distinto, [Mendoza et al. \(2024\)](#) compararon MICE con Hmisc, Amelia y missForest para predecir estado serológico de VIH en Uganda, encontrando que las imputaciones por MICE y Hmisc produjeron mayor sensibilidad y exactitud predictiva que missForest, con menor variabilidad entre corridas.

Los métodos basados en árboles (missForest, y por extensión Hmisc/Amelia en su comparación con MICE) ilustran una disociación importante entre precisión de imputación y utilidad del análisis posterior. [Mendoza et al. \(2024\)](#) muestran que missForest generó los valores más cercanos a los observados (menor NRMSE), pero esto no se tradujo en mejores modelos predictivos: el mejor desempeño en exactitud y sensibilidad correspondió a MICE y Hmisc. [Dong et al. \(2021\)](#) confirman además que el costo computacional de missForest escala de forma prohibitiva con el tamaño de muestra (1300 minutos para

$n = 50\,000$, frente a 32 minutos de una red generativa antagónica).

Las redes generativas antagónicas de imputación (GAIN) muestran mejor desempeño que MICE y missForest cuando la tasa de valores faltantes es alta y el tamaño de muestra es grande (Dong et al., 2021): en datasets clínicos de 50,000 y 10,000 casos completos, GAIN superó a missForest específicamente al 50 % de datos faltantes y para variables sesgadas o categóricas desbalanceadas. Sin embargo, los propios autores acotan dos límites relevantes para esta tesis: (i) no simulaban tasas de valores faltantes superiores al 50 %, señalando que “algunos investigadores han sugerido que una tasa de valores faltantes superior al 50 % no es aceptable para estudios clínicos”; y (ii) su evaluación se restringió a datos transversales, de modo que sus resultados “pueden no ser generalizables a problemas de datos faltantes en estudios longitudinales con observaciones repetidas” (Dong et al., 2021).

Un problema específico de la carga viral, es la censura por límite de detección: los valores registrados por debajo del umbral del ensayo no son mediciones sino códigos de censura, y su sustitución simple por el límite de detección o su mitad sesga tanto las estimaciones como sus errores estándar (Soret et al., 2018). Soret et al. desarrollan un estimador Buckley-James con regularización Lasso para carga viral censurada por la izquierda en presencia de predictores de alta dimensión, mostrando que este enfoque supera a la imputación simple; no obstante, documentan que el algoritmo exhibe comportamiento oscilante en el 82.5 % y el 95.0 % de las réplicas bajo tasas de censura del 50 % y 70 % respectivamente, es decir, que incluso el método diseñado específicamente para este problema pierde estabilidad numérica antes de alcanzar los niveles de censura observados en los periodos más tempranos de carga viral.

Al contrastar estos techos con los datos de la cohorte, el vacío se hace explícito. El límite más permisivo reportado en los cinco estudios revisados — 60 % en Mendoza et al. (2024), con inestabilidad de convergencia ya documentada desde el 50 % por Soret et al. (2018), y una disponibilidad mínima del 18 % (82 % de datos faltantes) en el corte etario más desfavorable de la cohorte pediátrica real de Brummel et al. (2022) — es superado por 12 de los 17 periodos tanto de CD4 como de carga viral en esta cohorte, con ocho periodos por marcador cuyo número de observaciones válidas es igual o inferior a ocho. Ninguno de los cuatro métodos revisados fue validado, ni siquiera en su versión más favorable a datos faltantes extremos, en este régimen.

Además se comparte un supuesto estructural común: la imputación es tratada como la estimación de un modelo condicional o la minimización de una función de pérdida escalar (NRMSE, PFC, error cuadrático de predicción, verosimilitud) sobre cada variable o desenlace por separado — incluso en GAIN, donde el componente “antagónico” es una heurística de entrenamiento (generador contra discriminador) y no una modelización explícita de la interacción biológica entre CD4 y carga viral como procesos que compiten por un mismo desenlace inmunológico. Frente a este vacío, el marco de teoría de juegos cuántica propuesto en esta tesis no se plantea como sustituto directo de MICE, missForest o GAIN, sino como una perspectiva complementaria: en lugar de imputar CD4 y carga viral como objetivos separados dentro del mismo esquema de ecuaciones encadenadas, ambos marcadores se modelan como estrategias interdependientes de un juego cuyo equilibrio se estima variacionalmente, sin exigir la reconstrucción completa de la rejilla temporal de 17 sub-periodos por paciente. Esta reformulación no elimina el problema de los valores faltantes, pero desplaza la pregunta de “cómo imputar una columna con 80–99 % de va-

lores faltantes” a “qué estrategia de equilibrio es consistente con la información parcial disponible en ambos marcadores conjuntamente”.

1.2. Justificación

Esta investigación se centra en la evaluación de algoritmos predictivos en el análisis de datos clínicos del VIH. Se espera que el enfoque de teoría de juegos cuánticos como perspectiva complementaria para lidiar con datos clínicos faltantes, ofrezca ventajas que mejoren la precisión, estabilidad y escalabilidad de los modelos predictivos, contribuyendo al desarrollo de herramientas computacionales avanzadas para la medicina personalizada.

1.3. Objetivos

Objetivo General: Desarrollar una metodología de análisis de datos clínicos del VIH mediante simulación de algoritmos de la teoría de juegos cuánticos.

Los objetivos específicos de la investigación son:

- Identificar y comparar los algoritmos predictivos más relevantes en la literatura (2019-2026) mediante revisión sistemática, con criterio de selección PICOS documentado.
- Selección de conjuntos de datos adecuados para la evaluación de los algoritmos predictivos, con énfasis en datos clínicos de VIH.
- Construir un modelo de teoría de juegos cuánticos basado en el conjunto de datos.
- Simular el algoritmo de juegos cuánticos para encontrar estados óptimos que permitan manejar la falta de datos clínicos completos.
- Implementar algoritmos predictivos clásicos en base al esquema de teoría de juegos cuánticos.
- Validar la aplicabilidad del enfoque bajo un esquema de entrenamiento y prueba para permitir la generalización de los resultados.
- Presentación de resultados y recomendaciones sobre la aplicabilidad de los algoritmos predictivos en el análisis biomédico.

1.4. Hipótesis

El enfoque de teoría de juegos cuánticos puede encontrar configuraciones óptimas que permitan lidiar con el problema de datos clínicos faltantes derivados de variables de carga viral y linfocitos T CD4, permitiendo la aplicación de modelos de regresión para predecir estados fenotípicos y respuesta a ART.

Capítulo 2

Estado del Arte

2.1. Modelos Predictivos Clásicos en VIH

Antes de que los clasificadores de aprendizaje automático (KNN, bosques aleatorios, XGBoost) se aplicaran a la predicción de biomarcadores de VIH, la línea de trabajo iniciada por el Grupo Insight en Bogotá, Colombia, y validada posteriormente en población mexicana por [Salgado-Jiménez et al. \(2020\)](#), estableció un precedente metodológico directo para esta tesis: la predicción de linfocitos T CD4 mediante teoría de conjuntos y probabilidad, usando únicamente leucocitos y linfocitos totales de una biometría hemática convencional. El estudio de [Salgado-Jiménez et al. \(2020\)](#) es particularmente relevante porque se realizó en el Hospital General Regional Vicente Guerrero de Acapulco — la misma sede del IMSS en Guerrero, de la que procede la cohorte analizada en este trabajo — sobre 232 pacientes con VIH, en un estado que ocupa el sexto lugar nacional en casos de infección ([Salgado-Jiménez et al., 2020](#)).

La metodología define cuatro conjuntos (A , B , C , D) a partir de umbrales de leucocitos, linfocitos y CD4, y mediante operaciones de unión e intersección ($(A \cup C)$, $(B \cup D)$, $(A \cup B) \cap (B \cup D)$) estima la probabilidad de que una tripleta de valores hematológicos corresponda a un rango específico de CD4, tomando como ancla el último valor de CD4 registrado, siempre que no tuviera más de cuatro meses de antigüedad ([Salgado-Jiménez et al., 2020](#)). Sobre los 232 casos, la efectividad global fue de 0.94 para $A \cup C$, 0.97 para $B \cup D$ y 0.91 para la intersección, con valores por rango de leucocitos entre 0.54 y 1.00; para conteos leucocitarios inferiores a 9000/mm³ se predijeron valores de CD4 inferiores a 570 células con 91–100 % de efectividad, alcanzando 100 % en los rangos de 3000 y de 8000–8999 leucocitos ([Salgado-Jiménez et al., 2020](#)).

Tres limitaciones de este antecedente, reconocidas por los propios autores, motivan directamente la ingeniería de la base qphen y el enfoque adoptado en este trabajo. Primero, el método se construyó deliberadamente excluyendo hemoglobina, edad, sexo, comorbilidades y, de forma explícita, la carga viral, “dado el carácter simplificador del método” ([Salgado-Jiménez et al., 2020](#)) — un biomarcador que esta tesis incorpora como variable predictiva central junto con CD4, no como un dato prescindible. Segundo, los propios autores enfatizan que la capacidad predictiva del método “es aplicable a un conjunto de datos no individual” ([Salgado-Jiménez et al., 2020](#)): se trata de una afirmación probabilística sobre un rango poblacional de leucocitos, no de una predicción a nivel de paciente, lo cual es insuficiente para las tareas de modelación predictiva individual de los recuen-

tos de linfocitos T CD4 y de carga viral que esta tesis aborda. Tercero, el método es inherentemente transversal: exige un único valor de CD4 reciente como ancla y una sola tripleta leucocitos-linfocitos-CD4 por evaluación, sin ningún mecanismo para incorporar la trayectoria temporal del paciente. La propia efectividad reportada no es uniforme: cae a 53.8–77 % en el rango de 10,000 leucocitos o más (Salgado-Jiménez et al., 2020), el extremo clínico donde con mayor frecuencia coinciden cuadros más complejos — precisamente el tipo de paciente multimórbido que una regla estática de umbrales, sin memoria de sus valores previos, tiene más dificultad para caracterizar.

Un segundo antecedente, más cercano aún, extiende directamente ese primer trabajo hacia el análisis longitudinal: Salgado Jimenez et al. (2024), estudio metodológico del mismo grupo de investigación — abandona la predicción transversal por un enfoque de aprendizaje no supervisado sobre 142 pacientes con registro continuo de CD4 entre 2018 y 2022. Mediante la distancia Euclidiana sobre los recuentos de CD4 estandarizados en cuatro cortes anuales (2018, 2019, 2021 y 2022; 2020 no se incluyó entre los cortes analizados debido a la ausencia de datos de calidad consecuencia de la pandemia por coronavirus) y el algoritmo de k -medias, con el método del codo como criterio de selección, se identificaron tres conglomerados: uno minoritario ($n = 18$) con los promedios de CD4 más altos pero con “caídas y ascensos abruptos”; uno mayoritario ($n = 82$) con un promedio estable alrededor de 600 células CD4; y uno de menor conteo ($n = 42$, promedio cercano a 300 células CD4) que los propios autores señalan como el grupo que requiere “mayor vigilancia médica por posibilidad de descender a cifras con mayor susceptibilidad de desarrollar tuberculosis, toxoplasmosis, etc.” (Salgado Jimenez et al., 2024) — la primera conexión explícita, dentro de esta línea de trabajo, entre el comportamiento longitudinal de CD4 y la dinámica con la carga viral que esta tesis busca modelar.

La discusión de Salgado Jimenez et al. (2024) señala que la estabilidad observada en el seguimiento temporal “puede contribuir a un patrón de memoria”, apoyándose en un trabajo fractal previo del mismo grupo sobre la variabilidad de CD4, y concluye recomendando explícitamente “un análisis fractal extenso” como siguiente paso para formalizar ese patrón de memoria (Salgado Jimenez et al., 2024). Esta tesis retoma directamente esa recomendación no resuelta, aunque por una vía distinta a la fractal: el marco de juegos cuánticos formaliza la memoria temporal de CD4 y carga viral como parte del propio mecanismo de competencia entre ambos marcadores, en lugar de tratarla como un patrón posterior a describir. Persisten, no obstante, tres límites en Salgado Jimenez et al. (2024) relevantes para justificar el uso de qphen: el análisis usa únicamente CD4, sin carga viral; se restringe a pacientes con registros continuos en los cuatro cortes anuales, es decir, un criterio de casos completos que — de forma análoga al riesgo de sesgo de selección evaluado en la Tabla 3.1 de esta tesis — excluye por diseño a los pacientes con seguimiento más irregular; y el método es descriptivo y no supervisado, de modo que agrupa comportamientos similares pero no realiza predicciones sobre desenlaces individuales como el recuento de CD4 o los valores de la carga viral.

Un tercer antecedente, del mismo grupo de investigación y el más cercano de los tres al problema que aborda esta tesis, se enfoca directamente en la predicción de CD4: Salgado Jiménez et al. (2025) realizaron un estudio de cohorte en la misma Clínica de VIH del Hospital General Regional No. 1 (diciembre de 2023 a diciembre de 2024, $n = 534$) prediciendo el conteo de CD4 mediante regresión lineal secuencial sobre hasta seis mediciones seriadas cada seis meses, usando las dos mediciones inmediatamente anteriores para predecir la siguiente ($H3_CD4 \sim H1_CD4 + H2_CD4$, $N = 447$, $R^2 = 0.656$;

$H4_CD4 \sim H2_CD4 + H3_CD4$, $N = 354$, $R^2 = 0.644$; todos los coeficientes con $p < .001$) (Salgado Jiménez et al., 2025). A diferencia de Salgado-Jiménez et al. (2020) y Salgado Jimenez et al. (2024), este estudio sí incorpora carga viral ($H1_CV$, $p < .001$) como covariable, y estratifica explícitamente por presencia de TB: el análisis mostró que la recuperación inmunológica fue más lenta en el grupo coinfectado con TB, “evidenciando mayores desafíos en el manejo terapéutico de la coinfección” (Salgado Jiménez et al., 2025). Es, dentro de esta línea de trabajo, el primer antecedente que aplica modelos predictivos de regresión a la dinámica temporal de CD4, y lo hace en una entidad con una de las tasas de incidencia de tuberculosis pulmonar más altas del país (30.3 casos por 100,000 habitantes) (Salgado Jiménez et al., 2025).

No obstante, persisten limitaciones directamente relevantes para justificar el enfoque de esta tesis. El modelo de (Salgado Jiménez et al., 2025) es lineal y de solo dos rezagos, sin mecanismo para capturar relaciones no lineales o interacciones de mayor orden entre CD4 y carga viral; y, de forma notable, los propios autores reconocen esta brecha en su discusión: señalan que los algoritmos de aprendizaje automático permiten identificar de manera más precisa las variables que determinan la recuperación inmunológica, “ofreciendo una perspectiva que supera las limitaciones inherentes a los modelos lineales tradicionales”, y anticipan que la perspectiva a futuro del grupo apunta hacia técnicas computacionales más avanzadas capaces de capturar relaciones no lineales complejas (Salgado Jiménez et al., 2025). Esta tesis puede leerse como una respuesta directa a esa misma brecha identificada por el grupo que originó la línea de investigación.

Fuera de esta línea de trabajo del Hospital General Regional No. 1 y en un contexto poblacional independiente, un cuarto antecedente aporta evidencia externa directamente pertinente para esta subsección, pues compara — sin ensamblarlos entre sí — un método de kernel (SVM), un método de bagging de bosque aleatorio (RF, es decir, un ensamble por derecho propio) y una red neuronal (MLP) sobre el mismo tipo de problema que aquí interesa: predecir marcadores inmunológicos del VIH a partir de indicadores clínicos rutinarios. Li et al. (2022) construyeron y compararon estos tres modelos individuales de aprendizaje automático para predecir cambios en la función inmune de 96 pacientes con VIH/SIDA bajo ART de alta actividad (HAART) en la provincia de Yunnan, China, con un seguimiento de hasta 9.9 años (mediana de 5.9 años; mínimo de 2.6 años) entre septiembre de 2009 y septiembre de 2019. A diferencia de los tres antecedentes anteriores, el estudio integra simultáneamente biometría hemática, función hepática y renal, perfil lipídico, subconjuntos linfocitarios y carga viral como variables de entrada, estratificando a los pacientes según su conteo basal de CD4 en un subgrupo inferior a 200 células/ μl ($n = 54$) y un subgrupo igual o superior a 200 células/ μl ($n = 42$) (Li et al., 2022). Implementados mediante las funciones `SVR`, `RandomForestRegressor` y `MLPRegressor` de `scikit-learn` (kernel RBF para SVM; 100 árboles para RF), los tres modelos coincidieron en identificar al cociente CD4/CD8 como la variable mejor predicha, con un desempeño altamente consistente entre sí: en el subgrupo con CD4 inferior a 200 células/ μl , SVM obtuvo el mejor ajuste ($R^2 = 0.519$), seguido de RF ($R^2 = 0.438$) y MLP ($R^2 = 0.307$); en el subgrupo con CD4 igual o superior a 200 células/ μl el orden se invirtió — RF fue el mejor modelo ($R^2 = 0.806$), seguido de MLP ($R^2 = 0.700$) y SVM como el más débil ($R^2 = 0.651$) — y, en conjunto, los tres modelos exhibieron un desempeño sistemáticamente superior en el subgrupo con mayor CD4 basal que en el subgrupo con inmunosupresión más avanzada (Li et al., 2022).

Para los fines de esta tesis, esa asimetría es el hallazgo más relevante del estudio, pre-

cisamente porque no se explica por el tamaño de muestra: el subgrupo peor predicho ($CD4 < 200$, $n = 54$) es el más grande de los dos, no el más pequeño. [Li et al. \(2022\)](#) documentan, además, que dentro de ese subgrupo más vulnerable únicamente el conteo plaquetario — junto con el cociente $CD4/CD8$ — alcanzó significancia estadística de forma consistente en los tres modelos, mientras que variables como $CD8$, triglicéridos o AST resultaron significativas para unos modelos y no para otros. El mismo patrón de fragilidad aparece en la dimensión temporal: hacia el extremo tardío del seguimiento (≥ 9 años), el número de observaciones válidas de carga viral se reduce a apenas $n = 4$ por subgrupo, una contracción que — en otra escala — es del mismo tipo que la que exhibe la cohorte de Guerrero en sus periodos más escasos. Los propios autores atribuyen esta limitación a las pérdidas durante el seguimiento y proponen la integración de modelos (ensamblado) como dirección futura, sin llegar a probarla ([Li et al., 2022](#)).

A esto se suman dos brechas que [Li et al. \(2022\)](#) deja ver, aunque los autores no las señalen como tales. Primero, la carga viral se mide longitudinalmente y se describe de forma comparativa entre grupos, pero no figura entre las once variables cuyo desempeño predictivo se reporta: ninguno de los tres modelos fue evaluado en su capacidad de predecir la carga viral misma, pese a ser, junto con el $CD4$, el marcador central de la eficacia de ART. Y segundo, cada variable clinicopatológica se valida de forma aislada frente a su propio valor observado, sin ningún mecanismo que module la competencia o interdependencia entre $CD4$ y carga viral — el propio esquema de preprocesamiento, que convierte la serie temporal de cada marcador en un par de vectores de predictor y objetivo mediante diferencias ponderadas por el intervalo entre visitas, incorpora una noción de trayectoria comparable a las diferencias ponderadas de $qphen$, pero aplicada de forma aislada a cada variable, nunca de forma conjunta entre $CD4$ y carga viral.

Cabe señalar, por último, que los propios autores encuadran su elección metodológica en términos de recursos limitados: en Yunnan, una provincia fronteriza que describen como relativamente subdesarrollada, no siempre es factible cuantificar $CD4$ u otros subconjuntos linfocitarios porque estas mediciones dependen de una plataforma de citometría de flujo, mientras que la biometría hemática y las pruebas de función hepática y renal resultan más accesibles ([Li et al., 2022](#)) — una restricción de infraestructura diagnóstica estructuralmente análoga a la que, en el contexto de Guerrero, motiva construir $qphen$ sobre biomarcadores rutinarios ($CD4$ y carga viral) en lugar de depender de paneles inmunológicos más completos. En conjunto, [Li et al. \(2022\)](#) demuestran — en una cohorte, un país y un conjunto de arquitecturas de aprendizaje completamente independientes de la línea de Guerrero — que la fragilidad de los modelos clásicos individuales y de ensamble frente a subgrupos clínicamente vulnerables y de tamaño reducido no es una particularidad de esta tesis ni de un único algoritmo, sino un patrón que atraviesa arquitecturas (kernel, bagging, red neuronal), países y sistemas de salud. Es ese patrón — y no la ausencia de un algoritmo clásico suficientemente sofisticado — el que refuerza, desde fuera de la cohorte de esta tesis, la necesidad de desplazar la pregunta de qué modelo predice mejor una variable clinicopatológica aislada hacia qué marco puede representar a $CD4$ y carga viral como procesos interdependientes con memoria, sin exigir representación balanceada de clases en cada subconjunto de validación.

A esta línea de evidencia externa se suma una quinta referencia de una escala muy distinta a las cuatro anteriores: [Sun et al. \(2026\)](#) construyeron y validaron externamente un modelo de aprendizaje automático para la predicción temprana de no respondedores inmunológicos (INR) — personas que, pese a lograr supresión virológica bajo ART, no logran

normalizar su recuento de CD4 — sobre una cohorte retrospectiva multicéntrica de 30,938 PLWH atendidos en tres hospitales de China entre enero de 2003 y diciembre de 2023. Con una cohorte de derivación de 11,287 pacientes (INR: 1325 casos, 11.74 %) y una cohorte externa de validación de 1278 pacientes de una región distinta (INR: 240 casos, 18.77 %), [Sun et al. \(2026\)](#) compararon siete algoritmos — RF, XGBoost, GBM, LightGBM, AdaBoost, TabNet y MLP — sobre veinte indicadores clínicos basales, encontrando que RF ofreció el mejor desempeño (AUC=0.864, área bajo la curva de precisión-exhaustividad o AUPRC=0.473), seguido en ese orden por XGBoost, GBM, LightGBM, AdaBoost, TabNet y MLP ([Sun et al., 2026](#)). Mediante una reducción de características guiada por SHAP, el modelo final — un RF de nueve variables (CD4, CD4/CD8, CD8, conteo de glóbulos blancos, hemoglobina, carga viral, edad al inicio de ART, bilirrubina total y plaquetas) — alcanzó AUC=0.864 y AUPRC=0.498, con calibración favorable (Brier=0.082), validación interna por 5 pliegues de AUC= 0.884 ± 0.003 , y validación externa de AUC=0.855 y AUPRC=0.561 pese a las diferencias demográficas y de prevalencia entre cohortes ([Sun et al., 2026](#)).

Para esta tesis, el valor de [Sun et al. \(2026\)](#) no está tanto en el algoritmo ganador — de nuevo un ensamble de árboles, coincidiendo con [Li et al. \(2022\)](#) — sino en lo que revela sobre la escala necesaria para que ese ensamble funcione de forma estable. Los propios autores compararon el RF de nueve variables contra un modelo “tradicional” — una regresión logística multivariable con solo tres predictores (edad, CD4, plaquetas) seleccionados por LASSO — y encontraron una discriminación casi idéntica (AUC=0.856 frente a 0.864, una diferencia de apenas 0.008), con la ventaja del RF concentrada en una mejor calibración (Brier=0.086 frente a 0.082) y en la utilidad clínica de las curvas de decisión, más que en la discriminación misma ([Sun et al., 2026](#)). Es decir, aumentar la complejidad algorítmica — de tres variables con regresión logística a nueve variables con un ensamble optimizado por SHAP — desplazó muy poco el techo de desempeño; lo que sí resultó decisivo fue el volumen de casos positivos disponibles. Los 1325 casos de INR en la cohorte de derivación superan en casi un orden de magnitud a los casos disponibles en la cohorte depurada de esta tesis; incluso la cohorte externa de validación — 240 casos de INR, pensada únicamente para confirmar generalización, no para entrenar — contiene más casos que el total de la cohorte en Guerrero. [Sun et al. \(2026\)](#) también reportan que, ante el desbalance de clases, SMOTE mejoró el reconocimiento de la clase minoritaria sin sacrificar discriminación, y que la imputación con MissForest superó modestamente a MICE ([Sun et al., 2026](#)) — técnicas de remuestreo e imputación que presuponen precisamente la disponibilidad de cientos de casos positivos sobre los cuales remuestrear, una condición que no se cumple en los $> 80\%$ de datos faltantes por desenlace de CD4 y carga viral en esta cohorte.

Más relevante aún para esta tesis es lo que [Sun et al. \(2026\)](#) identifican, en su propia sección de limitaciones, como aquello que su modelo no pudo capturar. Primero, señalan que numerosos PLWH de su cohorte cambiaron de esquema de tratamiento durante el seguimiento por razones que incluyen la resistencia genotípica, y que — al depender el modelo únicamente del régimen registrado al inicio de ART — no fue posible examinar en qué medida esos cambios de régimen, impulsados en buena parte por la resistencia, influyen sobre el riesgo de INR ([Sun et al., 2026](#)). Aquí se hace explícita la brecha entre INR y la falla virológica, que la dinámica de los datos de la carga viral puedan capturar, y que esta tesis busca abordar: conceptualmente, INR describe un fracaso inmunológico sobre un fondo de éxito virológico (la carga viral se suprime, pero el CD4 no se reconstituye),

mientras que la interdependencia entre los biomarcadores de la base de datos qphen describe un fracaso virológico por resistencia fenotípica que el marco de la teoría de juegos cuánticos busca representar. No son el mismo fenómeno, pero el estudio de clasificación de INR más grande y mejor validado disponible en esta revisión reconoce que ambos se entrelazan a través de los cambios de régimen motivados por resistencia — y que, por diseño, su modelo no puede desenredar esa relación. Segundo, y de forma igualmente relevante para qphen, [Sun et al. \(2026\)](#) reconocen explícitamente no haber modelado predictores longitudinales de INR recolectados durante el tratamiento — como el CD4, el cociente CD4/CD8, los leucocitos o la hemoglobina variando en el tiempo —, limitándose a una única medición basal, y señalan como trabajo futuro precisamente la incorporación de estas medidas repetidas para refinar la estratificación de riesgo ([Sun et al., 2026](#)). Es decir, incluso el modelo clásico de mayor escala y mejor validado de toda esta revisión — entrenado sobre 30,938 pacientes a lo largo de veinte años — desemboca en la misma conclusión que [Salgado Jimenez et al. \(2024\)](#) alcanzaron con apenas 142: la trayectoria temporal de los biomarcadores, no solo su valor basal, es la pieza que falta. El marco de teoría de juegos cuánticos de esta tesis, al modelar CD4 y carga viral como estrategias interdependientes con memoria en lugar de una medición basal estática, ofrece una vía — aunque a una escala muestral necesariamente distinta — para abordar simultáneamente la trayectoria inmunológica que INR captura solo transversalmente.

Una sexta referencia completa el arco individual-ensamble de esta subsección desde el polo opuesto a [Li et al. \(2022\)](#): en lugar de comparar modelos individuales, [Jin et al. \(2026\)](#) construyen un ensamble apilado heterogéneo — XGBoost, LightGBM, Random Forest y Gradient Boosting como aprendices base, integrados mediante un meta-modelo de regresión Ridge — para predecir de forma prospectiva el conteo de CD4, el conteo de CD8 y el cociente CD4/CD8 en una cohorte retrospectiva multicéntrica de 5,436 pacientes que iniciaron ART entre 2016 y 2025 en Xi'an, China, reducida a 4,620 tras depuración de datos. El diseño excluye deliberadamente los valores basales de CD4 y CD8 de la matriz de características — usándolos solo para definir la cohorte, no para predecir — precisamente para evitar la fuga de datos, y estructura el historial de cada paciente en una ventana retrospectiva de doce visitas para dar cabida a cierta dimensión temporal ([Jin et al., 2026](#)). Sobre un conjunto de prueba independiente ($n = 1088$), el ensamble alcanzó $R^2 = 0.768$ (MAE=74.8 células/ μl) para CD4, $R^2 = 0.636$ (MAE=300.5 células/ μl) para CD8, y $R^2 = 0.131$ (MAE=0.137) para el cociente CD4/CD8 — una mejora relativa del 66.4 % y 128.6 % sobre un modelo Transformer Robusto entrenado con el mismo conjunto de variables, arquitectura que los propios autores incluyeron como comparador de aprendizaje profundo ([Jin et al., 2026](#)).

Para esta tesis, el resultado más revelador de [Jin et al. \(2026\)](#) es precisamente el que sus autores presentan como el más modesto: el cociente CD4/CD8 — la variable que [Li et al. \(2022\)](#) predijeron mejor de todas, con R^2 hasta 0.806 — se convierte aquí en la peor predicha del estudio, con $R^2 = 0.131$. Comparando con el trabajo de [Li et al. \(2022\)](#), en el trabajo de [Jin et al. \(2026\)](#) sí se excluyeron los valores basales de CD4 y CD8 como insumo del modelo. Es decir, en cuanto se retira el ancla basal — el mismo valor contemporáneo que [Li et al. \(2022\)](#) usan tanto para definir subgrupos como para alimentar sus modelos — la predicción genuinamente prospectiva del cociente CD4/CD8 se derrumba, incluso con una cohorte cuarenta y ocho veces mayor (4,620 frente a 96) y un ensamble de cuatro algoritmos con meta-aprendizaje. A esto se suma una tensión que el artículo no resuelve: entre los quince predictores mejor rankeados por SHAP para la predicción de CD4, el

término de interacción $CD4 \times CD8$ encabeza la lista con un valor absoluto medio de SHAP de 150.22 — más de catorce veces superior al segundo predictor, la edad (10.14) — y los autores lo describen como el término de interacción entre los recuentos de CD4 y CD8, presentando su dominancia como evidencia de la interdependencia inmunológica capturada por el modelo (Jin et al., 2026). El artículo no explica cómo un término derivado de dos variables declaradas ausentes de la matriz de entrada llega a dominar, por un orden de magnitud, su propio análisis de interpretabilidad — una inconsistencia no resuelta que sugiere una fuga de datos residual precisamente en el diseño que se construyó de forma explícita para evitarla.

A diferencia de Li et al. (2022) y Sun et al. (2026), Jin et al. (2026) sí incorporan una noción explícita de memoria temporal — la ventana retrospectiva de doce visitas, con secuencias solapadas para pacientes con seguimiento suficiente y repetición hacia atrás para quienes tienen menos — y es, de las seis referencias de esta subsección, la que más se acerca en estructura a la memoria que qphen formaliza. Sin embargo, esa ventana contiene únicamente variables demográficas y clínicas no inmunológicas — edad, sexo, presión arterial, frecuencia cardíaca, índice de masa corporal, esquema de ART —, variables que cambian poco de una visita a otra; la trayectoria de los propios marcadores que se busca predecir, CD4, CD8 y su cociente, queda fuera de la ventana por el mismo diseño anti-fuga que excluye los valores basales. El modelo tiene memoria de casi todo excepto de la dinámica de los biomarcadores que le interesa pronosticar — lo inverso de qphen, donde la memoria se construye sobre las diferencias ponderadas de CD4 y carga viral mismos. Los propios autores, en su discusión de limitaciones, nombran esta carencia como trabajo futuro — señalan explícitamente la incorporación de datos genómicos virales, como mutaciones de resistencia a fármacos, entre las variables pendientes (Jin et al., 2026) —, y reconocen, por separado, que su cohorte — 92.6 % masculina, reclutada exclusivamente en Xi'an, con distintas vías de transmisión — puede no generalizar a poblaciones con perfiles epidemiológicos distintos, mencionando explícitamente a los pacientes con nadir de CD4 muy bajo como un subgrupo con dinámicas potencialmente distintas (Jin et al., 2026), una salvedad directamente aplicable a la cohorte de Guerrero. El marco de teoría de juegos cuánticos de esta tesis responde a ambas observaciones a la vez: construye la memoria directamente sobre CD4 y carga viral — no sobre variables demográficas repetidas para preservar la dimensionalidad de una ventana — y lo hace sobre un contexto epidemiológico y de recursos que ninguna de las seis referencias revisadas comparte con Guerrero.

Estas limitaciones acumuladas de los seis antecedentes — predicción no individualizada y transversal en Salgado-Jiménez et al. (2020); restricción a casos completos, ausencia de carga viral, y una noción de memoria identificada pero no formalizada predictivamente en Salgado Jimenez et al. (2024); un modelo lineal de dos rezagos, con una necesidad de métodos no lineales explícitamente reconocida por sus propios autores en Salgado Jiménez et al. (2025); en una cohorte y un país independientes, un desempeño predictivo sistemáticamente inferior en el subgrupo clínicamente más vulnerable pese a contar con mayor tamaño muestral, sin extensión hacia la carga viral como desenlace modelado, en los tres modelos — de kernel, de ensamble y neuronal — evaluados por Li et al. (2022); a una escala de casi un orden de magnitud mayor, una discriminación estable únicamente alcanzable con volúmenes de casos positivos inaccesibles para esta cohorte, junto con dos brechas que Sun et al. (2026) reconocen explícitamente no haber resuelto: la ausencia de predictores longitudinales más allá de la medición basal, y la imposibilidad de desenredar la contribución de la resistencia genotípica sobre el desenlace inmunológico;

y, en el ensamble heterogéneo de Jin et al. (2026) — diseñado explícitamente para prevenir la fuga de datos basales —, una inversión reveladora: el cociente CD4/CD8, la variable mejor predicha por Li et al. (2022) (R^2 hasta 0.806), se convierte en la peor predicha ($R^2 = 0.131$) en cuanto se retira el anclaje basal, junto con un término de interacción CD4×CD8 que domina su propio análisis de interpretabilidad sin que el artículo explique su origen — son exactamente las que la base qphen fue diseñada para superar: al incorporar carga viral junto con CD4, preservar la identidad del paciente a lo largo del seguimiento 2018–2024, y habilitar el cálculo de diferencias ponderadas que representan la competencia entre ambos marcadores a lo largo del tiempo, qphen traslada el problema de “estimar un rango poblacional de CD4 a partir de una biometría hemática” o “predecir el siguiente valor de un marcador aislado” hacia “predecir el estado individual y longitudinal de un paciente a partir de biomarcadores con memoria”.

Autor	Año	Método	Dato	Métrica principal	Limitación
Salgado-Jiménez et al.	2020	Teoría de conjuntos y probabilidad (metodología de Rodríguez/Grupo Insight)	232 pacientes VIH, biometría hemática + último CD4 (Hospital Gral. Regional no. 1 Vicente Guerrero, Acapulco)	Efectividad por rango: 0.54–1.00; global 0.91–0.97	Predicción poblacional/por rango, no individual; excluye carga viral; sin componente temporal
Salgado-Jiménez et al.	2024	Conglomerados k -medias sobre distancia Euclidiana (no supervisado)	142 pacientes VIH, CD4 continuo 2018–2022, 4 cortes anuales (excluye 2020); misma sede	3 conglomerados ($k=3$, método del codo); SC intra/inter = 251.1/312.9 de 564	Solo CD4; restringido a casos completos (registro continuo); descriptivo, no predictivo; memoria sugerida, no formalizada
Salgado-Jiménez et al.	2025	Regresión lineal secuencial (autoregresiva, 2 rezagos) sobre CD4 seriado	$n = 534$ ($N = 447/354$ submuestras), CD4 seriado (6 mediciones, cada 6 meses) + CV + comorbilidades, estratificado por TB; misma sede, dic. 2023–dic. 2024	$R^2 = 0.656$ ($N = 447$) y 0.644 ($N = 354$); coef. de rezago $p < .001$	Lineal, solo 2 rezagos; autores piden explícitamente métodos no lineales
Li et al.	2022	SVM, RF y MLP individuales (regresión por variable, sin ensamble conjunto)	96 pacientes VIH/HAART, Yunnan, China; seguim. hasta 9.9 años; CD4 basal < 200 ($n = 54$) vs ≥ 200 ($n = 42$) cél./ μ l	CD4/CD8 mejor predicho: $R^2 = 0.519$ (SVM, < 200) vs $R^2 = 0.806$ (RF, ≥ 200)	Regresión aislada por variable; CV medida pero excluida de la validación predictiva; peor desempeño en subgrupo vulnerable pese a mayor n
Sun et al.	2026	7 algoritmos ML (RF, XGBoost, GBM, LightGBM, AdaBoost, TabNet, MLP); clasificación binaria + SHAP	30 938 PLWH, 3 hospitales, China (2003–2023); derivación $n = 11\,287$ (INR $n = 1325$); val. externa $n = 1278$ (INR $n = 240$)	RF 9 var.: AUC= 0.864, AUPRC= 0.498; val. externa AUC= 0.855, AUPRC= 0.561	Solo variables basales, sin trayectoria longitudinal (reconocido por autores); no desenreda resistencia/cambios de régimen del riesgo de INR; escala inalcanzable en Guerrero
Jin et al.	2026	Ensamble stacking (XGBoost, LightGBM, RF, GB + meta Ridge); ventana de 12 visitas; sin CD4/CD8 basal	5 436 PLWH inicial, 4 620 tras depuración; Xi'an, China (2016–2025); prueba independiente $n = 1088$	CD4: $R^2 = 0.768$; CD8: $R^2 = 0.636$; CD4/CD8: $R^2 = 0.131$; mejora 66.4%/128.6% vs. Transformer	CD4/CD8 se derrumba sin anclaje basal ($R^2 = 0.131$); término CD4×CD8 domina SHAP sin explicación (posible fuga residual); ventana de 12 visitas repite demográficos, no la trayectoria de CD4/CV

2.2. Teoría de Juegos Cuánticos en VIH

La aproximación cuántica para abordar la dinámica del VIH-1 —que propone modelar el conteo de células CD4 y la carga viral como estrategias interdependientes en lugar de variables clasificadas por separado— encuentra su fundamento teórico en la teoría de juegos cuánticos aplicada a la competencia biológica. Esta perspectiva examina las condiciones bajo las cuales un grupo reducido de mutantes con acceso a estrategias cuánticas logra invadir y reemplazar una estrategia evolutivamente estable (ESS) clásica en poblaciones biológicas. Sobre esta línea, Özlüer Başer (2022) demuestra que los fenotipos del virus a nivel molecular pueden utilizar estrategias cuánticas para desestabilizar equilibrios clásicos subóptimos y alcanzar estados evolutivamente estables que son Pareto óptimos. Es sobre la posibilidad de que una estrategia cuántica mutante reemplace un equilibrio evolutivo clásico que Özlüer Başer (2022) construye el modelo que esta tesis retoma como base metodológica directa de su ingeniería de características.

Özlüer Başer (2022) aplica, hasta donde esta revisión ha podido establecer, por primera vez este aparato de ESS cuantizada a la competencia de fenotipos del VIH-1. Su punto de partida es idéntico al que retoma esta tesis: dos fenotipos virales que compiten por el mismo recurso limitado —los linfocitos T CD4— uno de baja tasa de replicación (v) y otro de alta tasa de replicación (V), formalizados mediante un juego simétrico 2×2 con beneficios (α, α) , (β, γ) , (γ, β) y (θ, θ) para los encuentros $v - v$, $v - V$, $V - v$ y $V - V$ respectivamente, sujetos a la relación jerárquica $\gamma > \alpha > \theta > \beta$. Aplicando la definición de ESS, Özlüer Başer (2022) muestra que el equilibrio clásico se alcanza en la combinación (V, V) con beneficio (θ, θ) : V es la estrategia evolutivamente estable, pero el equilibrio no es óptimo de Pareto, pues ningún fenotipo tiene incentivo unilateral para desviarse de él aunque ambos podrían, en principio, obtener un pago mayor bajo otra combinación. La lectura clínica que la propia autora señala como implicación directa de este resultado es que, bajo teoría de juegos evolutiva estándar, correspondería “dar prioridad al fenotipo V al desarrollar ingredientes farmacéuticos” —una recomendación que, precisamente por no ser Pareto-óptima, deja sin explorar una región del espacio de estrategias en la que el resultado podría ser distinto para ambos fenotipos.

El aporte central de Özlüer Başer (2022) consiste en mostrar que ese resultado clásico no es el único alcanzable si se permite a los fenotipos jugar bajo la codificación cuántica $|0\rangle$ para v y $|1\rangle$ para V . La autora verifica primero que, restringiendo las estrategias disponibles a los operadores clásicos I y σ_x , el juego cuántico reproduce exactamente los cuatro resultados de la matriz clásica: el juego clásico es un caso particular del juego cuántico, no un modelo alternativo o incompatible con él. Sobre esa base introduce sucesivamente dos mutantes. El primero, capaz de jugar la matriz de Hadamard, desplaza el equilibrio a la combinación (H, H) , con beneficio promedio $(\alpha + \beta + \gamma + \theta)/4$ para ambos fenotipos —un resultado distinto del clásico, pero tampoco óptimo de Pareto—. El segundo, capaz de jugar el operador σ_z , desplaza el equilibrio a (σ_z, σ_z) con beneficio (α, α) , que sí es óptimo de Pareto. La autora concluye señalando que podrían existir presiones evolutivas hacia el desarrollo de estrategias cuánticas en juegos biológicos a nivel molecular, y anticipa la necesidad de diseñar, en investigaciones futuras, entornos de decisión que operen explícitamente bajo las reglas de la mecánica cuántica para este tipo de juegos —sin proponer, sin embargo, un procedimiento para construir tal entorno a partir de datos clínicos reales.

Para los fines de esta tesis, el valor de Özlüer Başer (2022) es estrictamente teórico y no debe sobreestimarse como un modelo aplicado. Los parámetros α , β , γ y θ nunca se estiman

a partir de datos clínicos: se manejan como símbolos abstractos sujetos únicamente a la restricción de orden $\gamma > \alpha > \theta > \beta$. El juego se resuelve como una única ronda estática, sin ninguna estructura longitudinal que represente la trayectoria de un paciente a lo largo del tiempo. Y el análisis no contempla —ni podría contemplar, dado su alcance— ninguna tarea de clasificación de un desenlace clínico individual como la coinfección por tuberculosis o la genoresistencia al tratamiento. El artículo no incluye una sola cohorte, un solo recuento de CD4 o una sola medición de carga viral: es, en el sentido más literal, una demostración de existencia —prueba que una estrategia cuántica Pareto-óptima existe dentro del espacio de juegos posibles— y no un procedimiento para identificarla, estimarla o aplicarla sobre una población real.

Esta tesis retoma el modelo de [Özlüer Başer \(2022\)](#) precisamente en el punto donde su alcance teórico se agota, convirtiéndolo en la base metodológica directa de la ingeniería de características desarrollada mediante el paquete *qvirus* ([Acuña González, 2025](#)). Tres extensiones son centrales en esa transición de un juego teórico a un procedimiento aplicado. Primero, los parámetros α, β, γ y θ dejan de ser símbolos abstractos y se estiman empíricamente mediante un ensamble de modelos de aprendizaje automático ajustado sobre las diferencias medias, estandarizadas y transformadas logarítmicamente, de CD4 y carga viral de los 176 pacientes de la cohorte de Guerrero, preservando en todo momento la relación jerárquica $\gamma > \alpha > \theta > \beta$ que [Özlüer Başer \(2022\)](#) exige para que el juego sea internamente consistente. Segundo, la ronda estática única del juego original se sustituye por una noción explícita de memoria longitudinal: las diferencias medias consecutivas de CD4 y de carga viral logarítmica estandarizada, calculadas sobre los puntos de tiempo disponibles para cada paciente, formalizan —por una vía distinta a la fractal, pero de forma directamente predictiva— el “patrón de memoria” que [Salgado Jimenez et al. \(2024\)](#) había identificado sin resolver. Y tercero, el conjunto minimal de estrategias que [Özlüer Başer \(2022\)](#) utiliza para ilustrar su argumento (I, σ_x , más los mutantes H y σ_z) se amplía en esta tesis a una librería de siete puertas cuánticas (I, X, H, Z, S, Y, T), generando un espacio combinatorio de estrategias sustancialmente mayor que el necesario para la demostración original de Pareto-optimalidad.

Sobre ese espacio ampliado, el algoritmo del beneficio más cercano —sin antecedente en [Özlüer Başer \(2022\)](#), cuyo artículo nunca necesita mapear una observación real sobre su espacio de juego— constituye la contribución metodológica que cierra el ciclo entre la teoría y el dato: para cada paciente, identifica el beneficio cuántico simulado más próximo a su diferencial de carga viral observado, y devuelve simultáneamente una predicción numérica y una etiqueta interpretable de combinación de puertas que codifica la dinámica fenotípica subyacente. Este conjunto de etiquetas, junto con las variables de clasificación por conglomerados, es precisamente lo que integra la base de datos *qphen*.

Esta extensión no es incidental frente a las deficiencias documentadas en la subsección anterior. La fragilidad de los modelos individuales y de ensamble frente a subgrupos pequeños y desbalanceados —observada por [Li et al. \(2022\)](#) en el subgrupo con CD4 basal más bajo, reconocida por [Sun et al. \(2026\)](#) al constatar que ni ampliar el número de variables ni ensamblar con selección SHAP desplaza significativamente el techo de discriminación sin un volumen mínimo de casos positivos, y expuesta por [Jin et al. \(2026\)](#) en la inversión de desempeño del cociente CD4/CD8 al retirar el anclaje basal— comparte una raíz común: son modelos que operan sobre un espacio de características puramente clásico, sin ningún mecanismo que garantice la existencia de una representación más favorable del problema. El resultado central de [Özlüer Başer \(2022\)](#) —que un juego evolutivo puede

quedar atrapado en un equilibrio clásicamente estable pero subóptimo, y que existe una estrategia cuántica capaz de desplazarlo hacia un óptimo de Pareto— ofrece, a nivel del juego subyacente y no solo como recurso computacional, una justificación teórica para intentar precisamente derivar el espacio de características de qphen de un juego cuántico con las diferencias clásicas de CD4 y carga viral, con apenas 176 pacientes— donde el espacio de características clásico ha demostrado, en poblaciones y países independientes, ser estructuralmente insuficiente.

Esta vía es, además, viable precisamente en el contexto de recursos limitados que caracteriza a la cohorte de Guerrero. La extensión de Özlüer Başer (2022) desarrollada en esta tesis no depende de acceso a hardware NISQ: el espacio de estrategias y el algoritmo del beneficio más cercano se ejecutan como simulación clásica de un sistema de pocos qubits, lo cual hace que la ingeniería de características cuántica sea aplicable hoy, sobre hardware convencional, a una población de VIH atendida en un hospital regional del IMSS en un estado con recursos limitados, en lugar de condicionarse a la infraestructura NISQ.

En síntesis, Özlüer Başer (2022) establece —en un plano exclusivamente teórico— que la aleatorización cuántica permite a un juego evolutivo escapar de un equilibrio clásicamente estable pero Pareto-ineficiente, y aplica por primera vez ese resultado a la competencia de fenotipos del VIH-1. Lo que su modelo no ofrece, ni pretende ofrecer, es un procedimiento para estimar ese juego a partir de datos clínicos reales, para representar la trayectoria longitudinal de un paciente dentro de él, o para clasificar un desenlace clínico individual a partir de sus resultados. Esta tesis argumenta que esa brecha —entre la demostración teórica de que existe una estrategia cuántica superior y la ausencia de un procedimiento para encontrarla en una cohorte real— es precisamente la que la base de datos qphen y el algoritmo del beneficio más cercano están diseñados para cerrar: transforman el juego estático y de parámetros abstractos de Özlüer Başer (2022) en una canalización de ingeniería de características estimada empíricamente, con memoria longitudinal explícita sobre CD4 y carga viral conjuntas, aplicada sobre una cohorte de VIH de un sistema de salud público con recursos limitados, donde la subsección anterior mostró que los modelos clásicos individuales y de ensamble llegan de forma consistente a su límite estructural.

Autor	Año	Método	Dato	Métrica principal	Limitación
Özlüer Baer	2022	Teoría de juegos evolutiva cuantizada: ESS clásica (I, σ_x) vs. mutantes cuánticos (Hadamard, σ_z)	Ninguno (modelo teórico, sin cohorte ni mediciones clínicas)	ESS clásica en $(V, V) = (\theta, \theta)$, no Pareto-óptima; ESS cuántica en $(\sigma_z, \sigma_z) = (\alpha, \alpha)$, Pareto-óptima	Parámetros $\alpha, \beta, \gamma, \theta$ abstractos (solo orden definido); sin componente longitudinal
Esta tesis		Juego cuántico con parámetros estimados por ensamble ML (7 puertas: I, X, H, Z, S, Y, T) + algoritmo del beneficio más cercano + VQE inverso	176 pacientes VIH, CD4 y carga viral longitudinal 2018–2024 (Hospital Gral. Regional No. 1 Vicente Guerrero, IMSS)	MAE del modelo cuántico (beneficio más cercano) inferior al clásico y ad-hoc en subgrupos TB/GR (Cap. 4)	Validación en una única cohorte y sede

2.3. Modelos Predictivos Cuánticos

La subsección anterior mostró que la extensión de Özlüer Başer (2022) desarrollada en esta tesis no depende de acceso a hardware NISQ: el juego y el algoritmo del beneficio

más cercano se ejecutan como simulación clásica. Esa independencia es, sin embargo, una elección metodológica de esta tesis, no una limitación inherente a todo el aprendizaje automático cuántico. Existe una segunda línea de investigación, independiente de la de [Özlüer Başer \(2022\)](#) y anterior en el tiempo, que sí ha sido validada experimentalmente sobre hardware cuántico real: los métodos de kernel cuántico y de clasificación variacional cuántica para aprendizaje supervisado. Esta subsección examina esa línea a través de su referencia fundacional, [Havlíček et al. \(2019\)](#).

[Havlíček et al. \(2019\)](#) proponen e implementan experimentalmente, sobre un procesador superconductor de cinco qubits de IBM (del cual solo dos, Q_0 y Q_1 , se emplean efectivamente), dos clasificadores binarios que comparten un mismo mecanismo subyacente: mapear los datos clásicos $x \in \Omega$ a un estado cuántico $|\Phi(x)\rangle$ mediante un circuito de mapa de características $\mathcal{U}_{\Phi(x)} = U_{\Phi(x)} H^{\otimes n} U_{\Phi(x)} H^{\otimes n}$, donde $U_{\Phi(x)} = \exp\left(i \sum_{S \subseteq [n]} \phi_S(x) \Pi_{i \in S} Z_i\right)$ es una compuerta diagonal en la base de Pauli- Z que codifica tanto términos de un solo qubit ($|S| = 1, \phi_i(x) = x_i$) como términos de interacción entre pares de qubits ($|S| = 2, \phi_{1,2}(x) = (\pi - x_1)(\pi - x_2)$ para $n = 2$), y los Hadamard intermedios rotan la base para que el mapa capture relaciones no lineales. El primer clasificador, el clasificador variacional cuántico, aplica sobre ese estado un circuito de profundidad corta $W(\vec{\theta})$ y clasifica según una medición binaria diagonal en la base Z ; el segundo, el estimador de kernel cuántico, estima directamente en el hardware cuántico el kernel $K(x, z) = |\langle \Phi(x) | \Phi(z) \rangle|^2$ para todos los pares del conjunto de entrenamiento y alimenta esa matriz a una SVM clásica.

El valor de [Havlíček et al. \(2019\)](#) para el campo es, ante todo, una demostración de viabilidad de hardware, y los propios autores delimitan ese alcance de forma explícita: buscan el problema de elegir un mapa de características adecuado para un conjunto de datos práctico —es decir, separan deliberadamente si el clasificador puede implementarse en hardware de si resuelve un problema real—. Para lograr esa separación, los datos con los que validan ambos métodos no provienen de ningún dominio externo: se generan a partir del propio mapa de características que después los clasifica. Fijan un observable $f = Z_1 Z_2$ y una unitaria aleatoria $V \in SU(4)$, y asignan la etiqueta mediante el umbral $\langle \Phi(x) | V^\dagger f V | \Phi(x) \rangle \gtrless \pm \Delta$ (margen $\Delta = 0.3$): la verdad fundamental se define con la misma estructura de espacio de Hilbert que el clasificador explota, no con un fenómeno clínico o biológico independiente de ese formalismo. Sobre conjuntos perfectamente balanceados (20 puntos por etiqueta, tres unitarias aleatorias distintas como Conjuntos I, II y III) y con apenas $n = 2$ qubits, el clasificador variacional alcanza un éxito cercano al 100 % para profundidades $l > 1$, y el estimador de kernel alcanza 100 % en los Conjuntos I y II y 94.75 % en el Conjunto III. Ninguno de los dos métodos se evalúa sobre datos reales de algún dominio, y los propios autores señalan como trabajo futuro —no como algo demostrado en el artículo— el desarrollo de mapas de características con mejoras a bases de datos reales. A esto se suma una limitación de escalamiento directamente relevante para una cohorte de 176 pacientes: estimar la matriz de kernel completa con una desviación acotada en norma de operador requiere $R = \mathcal{O}(\delta - 2|T|4)$ disparos del circuito —una dependencia cuártica del tamaño del conjunto de entrenamiento— que hace impráctico escalar el estimador de kernel cuántico, tal como fue implementado originalmente, más allá de los 20–60 puntos con los que se demostró. Incluso la premisa de ventaja cuántica del propio mapa de dos capas de Hadamard es, por admisión de los mismos autores, una conjetura y no un resultado demostrado.

Estos resultados permiten que el aparato de [Havlíček et al. \(2019\)](#) sí es adaptable, con una ingeniería de circuitos y de predicción considerable, a un desenlace clínico real—no es, en principio, inaplicable fuera de datos sintéticos—. Sin embargo, al exigir validación genuinamente retenida —particiones estratificadas repetidas con remuestreo bootstrap, en lugar de valores de ajuste sobre el propio conjunto de entrenamiento— el desempeño se puede desplomar a una exactitud balanceada estadísticamente indistinguible del azar. Es la misma firma de fragilidad ya documentada, sobre cohortes y países independientes, para los ensambles clásicos, y anticipada en términos puramente teóricos: un espacio de características —clásico o cuántico— sin un mecanismo de estructuración específico del dominio no garantiza que la representación resultante favorezca las predicciones de un desenlace raro (datos faltantes extremos), por la que esta tesis no adopta un kernel cuántico crudo sobre biomarcadores continuos como ruta de clasificación, y en su lugar canaliza el mecanismo cuántico a través de la ingeniería de características de juegos cuánticos (qphen, construida sobre el modelo de [Özlüer Başer \(2022\)](#)) que permita realizar tareas de modelación predictiva a través de las combinaciones de puertas cuánticas del algoritmo del beneficio más cercano en lugar de sobre biomarcadores continuos representados como un kernel cuántico de alta dimensión.

En conjunto con las dos subsecciones anteriores, esta revisión traza una progresión clara. Los modelos clásicos individuales y de ensamble muestran, sobre esta cohorte y sobre cohortes independientes en México y China, que la escasez de casos positivos desestabiliza tanto el ajuste como la validación de los modelos predictivos entrenado directamente sobre biomarcadores crudos. La teoría de juegos cuánticos ofrece, en [Özlüer Başer \(2022\)](#), una justificación teórica para representar la competencia entre fenotipos virales mediante una estructura no clásica, sin ningún procedimiento para estimarla sobre datos reales. Los métodos de kernel cuántico (QSVM) y de redes neuronales cuánticas (QNN) sí ofrecen ese procedimiento, validado incluso sobre hardware cuántico real por [Havlíček et al. \(2019\)](#) y [Simoes et al. \(2023\)](#).

La base de datos qphen de esta tesis se sitúan precisamente en la intersección no cubierta por ninguna de las líneas revisadas: un mecanismo cuántico de representación —el juego de fenotipos, no un kernel ni un circuito variacional genérico— estimado empíricamente sobre datos clínicos longitudinales reales, aplicado a la predicción de biomarcadores clínicos con memoria.

Autor	Año	Método	Dato	Métrica principal	Limitación
Havlicek et al.	2019	Clasificador variacional cuántico + estimador de kernel cuántico (SVM)	Datos sintéticos generados por el propio mapa de características ($n = 2$ qubits, 20 pts./etiqueta, 3 unitarias aleatorias)	Éxito de clasificación $\approx 100\%$ (profundidad > 1); kernel cuántico: 100 % (Sets I–II), 94.75 % (Set III)	Datos separables y balanceados por construcción (misma unitaria genera dato y etiqueta); 2 qubits; binario; escalamiento $O(\delta^{-2} T ^4)$ en disparos; sin dataset clínico real
Simões et al.	2023	QSVM + QNN (circuito variacional de principio a fin); 4 optimizadores clásicos (AMSGRAD, SPSA, BFGS, COBYLA)	5 datasets sintéticos/balanceados (100 registros, 2 clases equilibradas c/u; incluye el generador Adhoc de Havlicek et al.); simulador + ibmq_belem (5 qubits)	QSVM +3–4 % vs. SVM clásico; QNN +5 % vs. QSVM y +7 % vs. NN clásica (15 vs. 69,402 parámetros)	5 datasets balanceados por diseño, 100 registros c/u; máx. 5 qubits (1 por característica); sin dataset clínico; autores reportan alta varianza entre circuitos/optimizadores sin ganador claro
Esta tesis	—	Ingeniería de características vía juego cuántico (Ozluer Baser) + algoritmo del beneficio más cercano	176 pacientes VIH, memoria longitudinal de CD4 y carga viral (2018–2024)	Predicción de la dinámica de CD4/carga viral sobre los 176 pacientes (Cap. 4)	N reducido de 176; validación en una única cohorte y sede

Capítulo 3

Materiales y Métodos

3.1. Cohorte de Estudio y Base de Datos Clínica

3.1.1. Descripción de la Cohorte

Se utilizó una base de datos longitudinal recopilada de una cohorte de PLWH atendidas en la ciudad de Acapulco en Guerrero, México. Este análisis abarcó datos de 213 personas atendidas en la Clínica de VIH del Hospital General Regional No. 1: Vicente Guerrero del Instituto Mexicano del Seguro Social (IMSS), obtenidos entre 2018 y 2024.

Todos los procedimientos realizados en este estudio que involucraron a participantes humanos se llevaron a cabo de acuerdo con los estándares éticos del comité de investigación institucional y nacional, y con la Declaración de Helsinki de 1964 y sus enmiendas posteriores. El protocolo del estudio fue revisado y aprobado por el Comité Local de Investigación en Salud 1102 del Hospital General Regional No. 1, con los siguientes números de registro:

- Registro COFEPRIS: 17 CI 12 001 066
- Registro CONBIOÉTICA: CONBIOÉTICA 12 CEI 002 2018082
- Número de Registro Institucional: R-2023-1102-029

3.1.2. Variables Clínicas Recopiladas

La información recopilada incluyó mediciones clave para el seguimiento de la infección por VIH:

- Recuentos de linfocitos T CD4: Estas medidas reflejan la salud del sistema inmunitario de los pacientes. Recuentos bajos de CD4 se asocian con una mayor vulnerabilidad a infecciones oportunistas.
- Carga viral: Niveles plasmáticos de ARN del VIH, indicativos de la cantidad de virus en el cuerpo y un marcador principal de la eficacia de ART.
- Diagnóstico de Tuberculosis (TB): Información sobre la coinfección con TB, una de las principales complicaciones en personas que viven con VIH.

- Indicador de genoresistencia (GR): Presencia de resistencia al tratamietno (1 = resistente, 0 = no resistente).

3.1.3. Limpieza y Preparación de Datos

Inicialmente, la cohorte comprendía 213 registros. Sin embargo, para permitir el cálculo de diferencias ponderadas que representan la competencia de linfocitos y carga viral a lo largo del tiempo, y como estrategia para manejar valores faltantes e irregularidades en la periodicidad de las mediciones, se realizó un proceso de limpieza de datos. Este proceso incluyó la exclusión de registros con un solo valor longitudinal, ya que no permitían la derivación de tasas de cambio o dinámicas temporales necesarias para el modelo. Tras esta depuración, la base de datos se redujo a 176 registros, los cuales fueron utilizados para el análisis.

Se realizó un análisis estadístico para comparar las características clínicas entre los registros incluidos en el análisis ($n = 176$) y los registros originales ($n = 216$), con el fin de verificar la existencia de sesgos de selección. No se encontraron diferencias significativas en el recuento basal de CD4 ni en los valores de la carga viral, lo que sugiere que la exclusión no introdujo un sesgo sistemático en la muestra.

Para verificar la ausencia de sesgo de seleccion sistematico, se compararon las características clinicas basales de ambos grupos. Se define el valor basal de cada paciente como su primera observacion disponible de recuento de CD4 y carga viral a lo largo del seguimiento.

Se llevó a cabo un análisis de sensibilidad para evaluar el impacto de la exclusión de los 37 registros en las variables dependientes principales: recuento de células CD4 y carga viral. Se compararon las distribuciones de los valores completos y depurados mediante las pruebas de Kolmogorov-Smirnov y U de Mann-Whitney. Las características comparativas se detallan en la Tabla 3.1.

Tabla 3.1: Análisis de sensibilidad y comparación de distribuciones entre la cohorte completa y la depurada.

Variable	Prueba	Estadístico	p-valor	Interpretación
CD4	Kolmogorov-Smirnov	$D = 0.0085$	1.000	No hay diferencia significativa en la distribución.
CD4	U Mann-Whitney	$W = 229633$	0.882	No hay diferencia significativa en la mediana/ubicación.
VL	Kolmogorov-Smirnov	$D = 0.0142$	1.000	No hay diferencia significativa en la distribución.
VL	U Mann-Whitney	$W = 211317$	0.562	No hay diferencia significativa en la mediana/ubicación.

La Tabla 3.1 presenta la comparacion entre los 176 pacientes incluidos en el analisis y la base de datos original de 213 con 37 registros excluidos por insuficiencia de datos longitudinales. Los grupos *Incluido* y *Excluido* no mostraron diferencias estadisticamente significativas ($p > 0.05$) en los recuentos basales de CD4 ni en la carga viral basal, segun las pruebas de Mann-Whitney y Kolmogorov-Smirnov.

La unica diferencia estructural esperada entre grupos es el numero de observaciones longitudinales disponibles: las observaciones excluidas contienen pacientes con una sola medicion registrada, lo que impide el cálculo de las diferencias temporales requeridas por el modelo de competencia fenotipica. Esta exclusion refleja una limitacion del diseño de seguimiento —no necesariamente del estado clinico del paciente— y es la unica fuente de sesgo potencial.




Figura 3.1: Distribución de la frecuencia de registros longitudinales de linfocitos T CD4 por grupo de estudio. El histograma muestra la disparidad en la cantidad de mediciones disponibles entre los pacientes incluidos en el análisis (que permiten el cálculo de dinámicas temporales) y los excluidos por presentar un registro único.




Figura 3.2: Distribución de la frecuencia de registros longitudinales de carga viral por grupo de estudio. Se ilustra la estructura de la muestra según la disponibilidad de datos longitudinales, diferenciando entre los pacientes con capacidad de seguimiento clínico para el modelo de competencia fenotípica (Incluido) y aquellos con mediciones insuficientes para dicho cálculo (Excluido).

3.2. Cálculo de Interacciones de Competencia

Para el desarrollo del modelo de juegos cuánticos, se requiere la cuantificación de las interacciones entre los fenotipos del VIH y las células T CD4. Esta cuantificación se realiza mediante el cálculo de las diferencias en los recuentos de células T CD4 y la carga viral a lo largo del tiempo, a partir de los datos longitudinales de la cohorte de estudio. La

obtención de valores estandarizados y cargas virales transformadas mediante logaritmo en base 10 permite un análisis detallado de estas interacciones para la posterior modelización en el marco de la teoría de juegos cuánticos.

3.2.1. Diferencias Medias de Recuentos de Linfocitos T CD4

Sea $X_{i,t}$ la medición (recuento de CD4 o carga viral) para la persona i en el punto de tiempo t . Se asume que los datos longitudinales para cada persona i están disponibles en una secuencia de M puntos de tiempo: $t_1, t_2, \dots, t_M$. Para los recuentos de células T CD4 de la persona i en el tiempo t , denotados como $C_{i,t}$, se calculan las diferencias consecutivas:

$$\Delta C_{ij} = C_{i,t_{j+1}} - C_{i,t_j} \text{ para } j = 1, \dots, M-1.$$

La interacción para la persona i , $\mathcal{I}_i^{\text{CD4}}$, se define como la media de estas diferencias:

$$\mathcal{I}_i^{\text{CD4}} = \frac{1}{M-1} \sum_{j=1}^{M-1} \Delta C_{i,j}.$$

Para cada persona i , los recuentos de CD4 se estandarizan utilizando su propia media y desviación estándar a lo largo del tiempo. Sea $\bar{C}_i = \frac{1}{M} \sum_{k=1}^M C_{i,t_k}$ la media de los recuentos de CD4 de la persona i , y $\sigma_{C_i} = \sqrt{\frac{1}{M-1} \sum_{k=1}^M (C_{i,t_k} - \bar{C}_i)^2}$ su desviación estándar. El valor estandarizado del recuento de CD4 para la persona i en el tiempo t es:

$$C'_{i,t} = \frac{C_{i,t} - \bar{C}_i}{\sigma_{C_i}}.$$

Luego, se calculan las diferencias entre los recuentos de CD4 estandarizados consecutivos:

$$\Delta C'_{i,j} = C'_{i,t_{j+1}} - C'_{i,t_j} \text{ para } j = 1, \dots, M-1.$$

La interacción estandarizada para la persona i , $\mathcal{I}_i^{\text{CD4-STD}}$, se define como la media de estas diferencias estandarizadas:

$$\mathcal{I}_i^{\text{CD4-STD}} = \frac{1}{M-1} \sum_{j=1}^{M-1} \Delta C'_{i,j}.$$

3.2.2. Diferencias Medias de Cargas Virales

Para la carga viral de la persona i en el tiempo t , denotada como $V_{i,t}$, se calculan las diferencias consecutivas:

$$\Delta V_{i,j} = V_{i,t_{j+1}} - V_{i,t_j} \text{ para } j = 1, \dots, M-1.$$

La interacción, $\mathcal{I}_i^{\text{CV}}$, se define como la media de estas diferencias:

$$\mathcal{I}_i^{\text{CV}} = \frac{1}{M-1} \sum_{j=1}^{M-1} \Delta V_{i,j}.$$

Después, la carga viral se transforma utilizando el logaritmo en base 10. Se aplica una condición para manejar los valores de carga viral iguales a cero:

$$L_{i,t} = \begin{cases} \log_{10}(V_{i,t}), & \text{si } V_{i,t} > 0 \\ 0, & \text{si } V_{i,t} = 0. \end{cases}$$

Luego, se calculan las diferencias entre los valores de carga viral logarítmica consecutivos:

$$\Delta L_{i,j} = L_{i,t_{j+1}} - L_{i,t_j} \text{ para } j = 1, \dots, M-1$$

La interacción en base logarítmica se define como la media de estas diferencias:

$$\mathcal{I}_i^{\text{CV-LOG}} = \frac{1}{M-1} \sum_{j=1}^{M-1} \Delta L_{i,j}$$

Estos valores logarítmicos se estandarizan para cada registro a lo largo del tiempo. Sea $\bar{L}_i = \frac{1}{M} \sum_{k=1}^M L_{i,t_k}$ la media de sus cargas virales logarítmicas, y $\sigma_{L_i} = \sqrt{\frac{1}{M-1} \sum_{k=1}^M (L_{i,t_k} - \bar{L}_i)^2}$ su desviación estándar. El valor estandarizado de la carga viral logarítmica para la persona i en el tiempo t es:

$$L'_{i,t} = \frac{L_{i,t} - \bar{L}_i}{\sigma_{L_i}}.$$

Finalmente, se calculan las diferencias entre los valores de carga viral logarítmica estandarizados consecutivos:

$$\Delta L'_{i,j} = L'_{i,t_{j+1}} - L'_{i,t_j} \text{ para } j = 1, \dots, M-1.$$

La interacción, en base logarítmica y estandarizada, se vuelve:

$$\mathcal{I}_i^{\text{CV-LOG-STD}} = \frac{1}{M-1} \sum_{j=1}^{M-1} \Delta L'_{i,j}.$$

3.2.3. Modelo de Juegos Cuánticos de Fenotipos del VIH

Un juego cuántico Q se define como $Q = Q(\mathbb{H}, \Lambda, \{s_i\}_j, \{\pi_i\}_j)$ donde $\mathbb{H}$ es un espacio de Hilbert, Λ es el estado inicial del juego, $\{s_i\}_j$ es el conjunto de movimientos del jugador j , $\{\pi_i\}_j$ es el conjunto de beneficios para el jugador j y el objetivo del juego es determinar las estrategias que maximizan los beneficios para el jugador j .

Los operadores unitarios se utilizan para transformar estados en la teoría de juegos cuánticos. Para un sistema de dos estados, resulta útil realizar esto con las matrices de Pauli I, X, Y, Z (denotadas también como σ_0, σ_x o el operador NOT, σ_y, σ_z) y la matriz de Hadamard (H).

La teoría juegos cuánticos requiere un estado inicial para que el juego comience a buscar las estrategias óptimas. Para este juego, el estado inicial se define como la competencia entre los fenotipos v (baja replicación viral) y V (alta replicación viral). Los qubits de las estrategias se asignan como $|0\rangle$ para v y $|1\rangle$ para V . Entonces, el estado inicial del juego donde ambos fenotipos son de baja replicación, se convierte en:

$$\Lambda = U|vv\rangle = U|00\rangle, \quad (3.1)$$

donde U es un operador unitario. U_v es el conjunto de movimientos (s_v) del fenotipo v , y U_V es el conjunto de movimientos (s_V) del fenotipo V . Siguiendo el estado inicial $U|00\rangle$ y después de que los fenotipos (v, V) hayan realizado sus movimientos, el estado del juego se convierte en:

$$(U_v \otimes U_V)U|00\rangle. \quad (3.2)$$

Luego, los fenotipos envían sus qubits para la medición final. Se aplica $U^\dagger$ (la inversa o adjunta hermítica del operador unitario U) para llevar el juego al estado:

$$|\psi_f\rangle = U^\dagger(U_v \otimes U_V)U|00\rangle. \quad (3.3)$$

Los beneficios esperados de los jugadores (π_v, π_V) se pueden obtener utilizando los resultados del juego de la Tabla 4.5 de la siguiente manera:

$$\pi_v = \alpha|\langle\psi_f|00\rangle|^2 + \beta|\langle\psi_f|01\rangle|^2 + \gamma|\langle\psi_f|10\rangle|^2 + \theta|\langle\psi_f|11\rangle|^2 \quad (3.4)$$

y

$$\pi_V = \alpha|\langle\psi_f|00\rangle|^2 + \gamma|\langle\psi_f|01\rangle|^2 + \beta|\langle\psi_f|10\rangle|^2 + \theta|\langle\psi_f|11\rangle|^2. \quad (3.5)$$

Para este juego, la matriz unitaria U se define como:

$$U = \frac{1}{\sqrt{2}}(I^{\otimes 2} + i\sigma_x^{\otimes 2}). \quad (3.6)$$

y la inversa del operador unitario, $U^\dagger$ es:

$$U = \frac{1}{\sqrt{2}}(I^{\otimes 2} - i\sigma_x^{\otimes 2}), \quad (3.7)$$

para dar igual probabilidad a cada movimiento cuántico, donde $\otimes 2$ denota el producto tensorial dos veces. Después de la implementación de U en el estado inicial Λ , el estado del sistema se transforma en:

$$U|00\rangle = \frac{1}{\sqrt{2}}(|00\rangle + i|11\rangle). \quad (3.8)$$

3.2.4. Clasificación de Interacciones Fenotípicas

Para clasificar las interacciones fenotípicas, se aplicó el método de conglomerados k -medias, el cual utiliza las diferencias estandarizadas en la carga viral logarítmica y los recuentos de CD4. Este análisis busca agrupar las interacciones, facilitando la identificación de patrones de comportamiento entre los fenotipos virales según sus diferencias observadas.

El algoritmo k -medias es un método de agrupamiento basado en prototipos que busca particionar un conjunto de N puntos de datos en k conglomerados, donde cada punto pertenece al conglomerado cuyo centroide (media) es el más cercano. Formalmente, dado un conjunto de puntos de datos $\{x_1, x_2, \dots, x_N\}$, donde cada punto $x_i \in \mathbb{R}^d$ representa una interacción caracterizada por las diferencias estandarizadas de CD4 y carga viral logarítmica, el objetivo del algoritmo k -medias es minimizar la Suma de los Cuadrados Dentro de los Conglomerados (WSS), definida como:

$$WSS = \sum_{j=1}^k \sum_{x \in C_j} \|x - \mu_j\|^2.$$

Donde:

- k es el número de conglomerados deseado.
- C_j representa el conjunto de puntos de datos asignados al conglomerado j .
- x es un punto de datos que pertenece al conglomerado C_j .
- μ_j es el centroide (media) del conglomerado C_j , con $|C_j|$ como el número de puntos en el conglomerado j , y calculado como:

$$\mu_j = \frac{1}{|C_j|} \sum_{x \in C_j} x,$$

- $\|\cdot\|$ denota la distancia euclidiana entre un punto $x = (x_{CD4}, x_{CV})$ y un centroide $\mu = (\mu_{CD4}, \mu_{CV})$ en el espacio 2-dimensional de las interacciones, calculada como:

$$\|x - \mu\| = \sqrt{(x_{CD4} - \mu_{CD4})^2 + (x_{CV} - \mu_{CV})^2}$$

3.2.5. Algoritmo del Beneficio más Cercano

Sea L_{obs} un valor de la diferencia de carga viral logarítmica estandarizada observada para una observación individual. Este valor es el dato de entrada que se busca caracterizar y predecir.

El modelo de juegos cuánticos, a través de la generación exhaustiva de escenarios, produce un conjunto de beneficios esperados cuánticos simulados. Se denota este conjunto como Π . Cada elemento en Π es una pareja ordenado p_j, N_j , donde:

- $p_j \in \mathbb{R}$ es un beneficio esperado derivado de una simulación de juego cuántico específica. Estos p_j son los valores de π_v o π_V resultantes de una combinación particular de puertas cuánticas (G_1, G_2) aplicadas por los fenotipos en el juego.

- N_j es la etiqueta o nombre descriptivo de la combinación de puertas cuánticas que generó ese beneficio p_j .

El conjunto Π se puede expresar formalmente como:

$$\Pi = \{(p_j, N_j) | j = 1, \dots, K\}$$

El algoritmo opera de la siguiente manera:

1. **Cálculo de Distancias:** Para la L_{obs} de una observación dada, el algoritmo calcula la distancia euclidiana (en este caso, la diferencia absoluta) entre L_{obs} y cada beneficio simulado $p_j \in \Pi$. Sea d_j esta distancia:

$$d_j = |L_{obs} - p_j| \text{ para cada } j = 1, \dots, K$$

2. **Minimización de la Distancia:** El algoritmo identifica el índice j^* que corresponde al valor de p_j que minimiza esta distancia:

$$j^* = \min_{j \in 1, \dots, K} |L_{obs} - p_j|$$

3. **Salida del Algoritmo:** El resultado del algoritmo es la pareja (p_{j^*}, N_{j^*}) , que representa:

- Predicción Numérica p_{j^*} : El beneficio esperado cuántico que mejor se ajusta a la observación real del paciente. Esta es la predicción del modelo cuántico para la carga viral diferencial.
- Caracterización Fenotípica N_{j^*} : El nombre de la combinación de puertas cuánticas asociada a este beneficio. Esta etiqueta proporciona una interpretación cualitativa del tipo de interacción fenotípica que subyace a la dinámica viral observada.

Cada $p_j \in \Pi$ es el resultado de la interacción de amplitudes de probabilidad en un espacio de Hilbert, que logra capturar relaciones no lineales inherentes al comportamiento viral. En lugar de forzar una observación clínica a una predicción basada en una función lineal o una media simple (como un modelo clásico o ad-hoc), este algoritmo mapea la observación al punto más cercano en este espacio de soluciones cuántico.

La predicción p_{j^*} es una instancia de una dinámica compleja pre-simulada por el modelo cuántico, que por su construcción es más adecuada para la complejidad de la dinámica del VIH. Dado que los beneficios p_j ya han sido derivados de un formalismo que inherentemente maneja distribuciones no-gaussianas y efectos cuánticos, el algoritmo del beneficio más cercano puede encontrar un ajuste más preciso para las observaciones reales que exhiben estas características. Esto se traduce directamente en un Error Absoluto Medio (MAE) más bajo, ya que la predicción está buscando en un conjunto de resultados que ya están sintonizados con la naturaleza compleja y probabilística de los datos.

3.2.6. Ingeniería de características: Base de datos qphen

Las predicciones numéricas generadas por el algoritmo del beneficio más cercano, si bien son precisas en su cuantificación de las interacciones fenotípicas, pueden presentar una dificultad de interpretación directa en un contexto clínico para la clasificación de estados

de enfermedad específicos como la coinfección o resistencia al tratamiento. La variable de respuesta principal bajo esta modelación representa una diferencia continua de la carga viral logarítmica estandarizada, que si bien es un indicador fundamental, no se traduce directamente en una etiqueta binaria de diagnóstico (presencia o ausencia de cierto estado clínico).

Para superar esta limitación y proporcionar un marco más estandarizado y clínicamente interpretable, se ha empleado el modelo de juegos cuánticos como una herramienta de ingeniería de características exhaustiva sobre la base de datos original de recuentos de linfocitos T CD4 y carga viral del IMSS Guerrero. El objetivo es transformar esta información en un formato que permita una mejor aproximación a la clasificación binaria de los estados clínicos que serán las variables de respuesta para algoritmos variacionales y la formulación de Hamiltonianos clínicos.

La base de datos **qphen**, resultante de este proceso, integra las variables características derivadas directamente de la modelación de juegos cuánticos. Esta integración proporciona un conjunto de datos robusto y multifacético para la clasificación. Las principales transformaciones y adiciones a la base de datos incluyen:

- Interacciones de Competencia de Variables de Carga Viral y CD4 Diferencial (**vl_diff**, **cd_diff**): Se mantienen las diferencias de carga viral y CD4, tanto en su escala original como en su versión logarítmica estandarizada. Estas variables capturan la dinámica a lo largo del tiempo y son la entrada principal para la inferencia de las interacciones fenotípicas.
- Variables de Clasificación de Interacciones (**vlogs_diff_mean**, **cds_diff_mean**, **n**, **classification_2**, **classification_3**, **classification_4**): Se incluyen los valores del centroide del conglomerado asignado a cada interacción, la cantidad de observaciones dentro de cada conglomerado y las asignaciones a cada uno de los conglomerados obtenidos mediante k -medias aplicados a las interacciones de competencia de CD4 y carga viral. Estos conglomerados agrupan pacientes con dinámicas fenotípicas similares, proporcionando una categorización basada en el comportamiento observado.
- Beneficios Cuánticos (**payoffs**, **payoffs_b**, **nearest_payoff**): Los beneficios calculados por el modelo de juegos cuánticos (estimados empleando observaciones completas o por lote) y el valor obtenido por el algoritmo del beneficio más cercano, incorporándose como variables numéricas. Estos valores representan la magnitud de las interacciones fenotípicas bajo diversas estrategias cuánticas.
- Codificación de Estrategias de Puertas Cuánticas (**phen_1**, **str1_2** a **str2_7**): Esta es la adición más crítica para la interpretación clínica y la preparación para algoritmos variacionales. El algoritmo del beneficio más cercano no solo devuelve un valor numérico, sino también el nombre de la combinación de puertas cuánticas (N_{j*}) que generó ese beneficio (p_{j*}). Estas combinaciones de fenotipos de alta o baja replicación (**phen_1**) y sus estrategias empleadas, ahora se codifican como variables binarias (0 o 1) dentro de la base de datos para cada observación. Cada columna **strX_Y** (e.g., **str1_2**, **str2_3**) representa una estrategia específica de una puerta cuántica. Una entrada de 1 en **strX_Y** indica que esa puerta particular fue parte de la combinación óptima de estrategias que el algoritmo del beneficio más cercano identificó como la más cercana a la observación clínica del paciente. Una entrada de

0 indica que no fue parte de esa combinación. Esto transforma una predicción numérica con mayor dificultad a interpretación clínica en un conjunto de características discretas y explicables (las puertas cuánticas) que representan las dinámicas subyacentes del virus y la respuesta inmunológica. Por ejemplo, la presencia de una puerta Pauli- X (`strX_2`) podría indicar una mutación o inversión de comportamiento en la dinámica viral o inmunológica asociada a esa observación.

- Indicadores de TB y GR (`TB_1`, `GR_1`): Estas son las variables de respuesta binarias clave (1 = presente, 0 = ausente). Al unificar la base de datos con las características de las puertas cuánticas identificadas como estrategias, se crea un marco estandarizado para correlacionar directamente estas dinámicas cuánticas con la presencia de coinfección o resistencia.

3.3. Modelación de Biomarcadores Clínicos

La integración de las estrategias de puertas cuánticas como variables explícitas en la base de datos `qphen` es fundamental para la ingeniería inversa de patrones de enfermedad.

Para evaluar rigurosamente el rendimiento y la estabilidad del enfoque, sus resultados se emplean como las características que alimentan a un conjunto de sólidos modelos clásicos de aprendizaje automático. Este análisis se realizó bajo un esquema de validación unificado y robusto (validación cruzada estratificada de 5 particiones), diseñado para garantizar la reproducibilidad en condiciones aleatorias y evaluar la robustez de las características. Se seleccionaron los siguientes modelos de referencia para la predicción de la competencia de linfocitos T CD4 y de la carga viral:

1. K-Vecinos más Cercanos (KNN): Un modelo no paramétrico basado en instancias, implementado mediante el motor `kknn`, que clasifica o predice el valor de una observación en función de la cercanía de sus vecinos más próximos optimizados (k).
2. Bosques Aleatorios (RF): Un algoritmo de ensamblaje basado en árboles de decisión, implementado con el motor `ranger` (con 500 árboles), que introduce aleatoriedad tanto en el muestreo de las filas como en la selección de predictores por división (`mtry`) para reducir la varianza y el sobreajuste.
3. Regresión Penalizada (Elastic Net / Lasso / Ridge): Un modelo lineal generalizado implementado a través del motor `glmnet`, el cual combina las penalizaciones L1 y L2 mediante los hiperparámetros de penalización (`penalty`) y mezcla (`mixture`) para controlar la multicolinealidad y realizar selección de variables.
4. Máquina de Soporte Vectorial (SVM) con kernel radial: Un modelo de vectores de soporte con función de base radial (motor `kernlab`), idóneo para capturar relaciones no lineales complejas en el espacio de características mediante la optimización del costo de penalización (`cost`) y el parámetro del kernel (`rbf_sigma`).

Todo el proceso de modelado, incluyendo el procesamiento de características, el ajuste de hiperparámetros y la evaluación final, se anidó dentro de un riguroso bucle de validación de múltiples semillas para garantizar la estabilidad de los resultados. El análisis se replicó en $N = 10$ semillas aleatorias distintas. Para cada semilla, se realizó una nueva división 80/20 de entrenamiento/prueba y se ejecutaron los subsiguientes valores cruzados (CV) repetidos y la evaluación final. Las métricas finales reportadas son la media y

la desviación estándar en estas N réplicas. El ajuste de hiperparámetros para todas las líneas base clásicas se realizó utilizando un CV de 5 veces repetido 3 veces en el conjunto de entrenamiento. La selección de modelos durante el CV se basó en la maximización del coeficiente de determinación R^2 , así como la minimización del Error Cuadrático Medio (RMSE) y el Error Absoluto Medio (MAE). El proceso de modelado utilizó el marco **tidymodels** en R. Todos los predictores numéricos se estandarizaron ($\mu = 0, \sigma = 1$) y las características de varianza cero se eliminaron utilizando la función **step_zv**.

Para garantizar la generalización y la robustez de los modelos predictivos frente a los riesgos de sobreajuste y contaminación de información, todo el flujo de modelado —incluyendo la ingeniería de características cuánticas, el cálculo de interacciones y la optimización de hiperparámetros— se estructuró bajo un estricto aislamiento entre conjuntos.

Previo a cualquier cálculo de diferencias clínicas o transformaciones cuánticas, los datos originales se dividieron de forma independiente (esquema de partición con proporciones controladas 80/20 para entrenamiento y prueba) utilizando semillas reproducibles. Las transformaciones derivadas y el cálculo de estados cuánticos mediante el paquete **qvirus** se ejecutaron de manera estrictamente disjunta para los subconjuntos de entrenamiento y prueba.

Para atender directamente cualquier posible contaminación entre las fases de extracción de características de interacción y la validación del clasificador, los estadísticos de resumen grupal, las proyecciones de distancias y la asignación de beneficios óptimos (**payoffs** y **payoffs_b**) se calcularon de forma independiente dentro del conjunto de entrenamiento y se aplicaron de manera ciega sobre el conjunto de prueba.

Se implementó una función defensiva de depuración para eliminar columnas con varianza cero de manera separada en cada partición. Asimismo, dentro del marco de **tidymodels**, los predictores numéricos se estandarizaron ($\mu = 0, \sigma = 1$) y se eliminaron aquellas características con colinealidad o varianza cercana a cero exclusivamente a partir de los parámetros aprendidos en los pliegues de entrenamiento, evitando cualquier propagación de información del conjunto de prueba hacia el modelo.

Una vez completado el entrenamiento de los algoritmos mediante validación cruzada, se identificaron y seleccionaron las configuraciones óptimas basándose en la minimización del RMSE. Los desempeños de los modelos finalizados se evaluaron comparativamente tanto en el conjunto de entrenamiento como en el de prueba para detectar posibles indicios de sobreajuste.

Adicionalmente, con el propósito de maximizar la capacidad predictiva y aprovechar la complementariedad entre los algoritmos, se implementó un marco de aprendizaje por conjuntos utilizando el paquete **stacks**. Mediante la combinación ponderada de los candidatos evaluados por validación cruzada y el ajuste de los miembros con **fit_members()**, se construyó un meta-modelo robusto capaz de mitigar las debilidades individuales de cada estimador clásico.

Para evaluar la contribución de los predictores en los modelos de mejor desempeño, se empleó la librería de explicabilidad **DALEXtra**. A través de la función **model_parts()**, se cuantificó la importancia global de las características basándose en la pérdida de rendimiento ante permutaciones, permitiendo contrastar el peso relativo de las variables clínicas frente a las derivadas de los operadores cuánticos.

Finalmente, para garantizar que las predicciones realizadas en nuevos conjuntos de datos (como el conjunto de prueba) se encuentren respaldadas por el espacio de calibración original, se evaluó el dominio de aplicabilidad mediante el análisis de componentes principales (`apd_pca`) implementado en el paquete `viraldomain`. Esto permitió calcular la distancia de las nuevas observaciones respecto al espacio multivariado de entrenamiento, estableciendo un umbral de confianza estricto (99%) para filtrar predicciones fuera del dominio de soporte y asegurar la fiabilidad biológica y clínica de los resultados.

3.4. Entorno de Trabajo y Reproducibilidad

Esta tesis ha sido redactada íntegramente mediante herramientas de software libre, priorizando la transparencia, reproducibilidad y automatización del flujo de trabajo científico.

El entorno principal de desarrollo es el lenguaje de programación R ([R Core Team, 2016](#)), en combinación con el entorno integrado RStudio ([RStudio Team, 2015](#)), lo que permite realizar análisis estadísticos, procesamiento de datos y generación dinámica de documentos desde una misma plataforma.

La generación del manuscrito se lleva a cabo usando los paquetes knitr ([Xie, 2025](#)) y rmarkdown ([Allaire et al., 2025](#)), que integran código fuente, resultados y texto narrativo en un único documento reproducible. Estas herramientas permiten adoptar un enfoque técnico que alinea el desarrollo científico con las buenas prácticas de la ciencia abierta.

El formato, estilo y estructura de esta memoria siguen las directrices establecidas por la plantilla MemoriaTFE, diseñada y mantenida por Pedro L. Luque Calvo ([Luque Calvo, 2019](#)). Este repositorio, difundido desde su página web personal y desde la Facultad de Matemáticas de la Universidad de Sevilla ([Luque Calvo, Pedro L., 2021](#); [Facultad de Matemáticas \(Univ. Sevilla\), s.f.](#)), ha sido clave para adaptar el contenido al estándar académico hispanohablante, ofreciendo un marco coherente para la presentación del trabajo final de estudios.

Capítulo 4

Resultados

4.1. Estadística Descriptiva de la Cohorte Clínica

Los registros de 2018 muestran niveles de CD4 relativamente altos, con un promedio de 707 células/ μ L. En 2019, aunque se observa un aumento en los niveles de CD4 en comparación con 2018, los valores varían más, con registros que oscilan entre 251 y 838 células/ μ L, lo que indica una heterogeneidad en el estado inmunitario de los pacientes. En 2020, se produjo una disminución significativa en los recuentos de CD4, con un mínimo de 48 y un promedio de 489 células/ μ L. En 2021, los registros fueron altamente variables, con niveles de CD4 extremadamente bajos en ciertos casos (mínimo de 8) y otros alcanzando hasta 1485 células/ μ L. Para 2022, los niveles de CD4 muestran una ligera recuperación, aunque con un amplio rango, manteniendo el promedio alrededor de 389.5 células/ μ L. En 2023, la tendencia positiva persiste, con promedios que alcanzan 365.3, 405.5 y 478.6 células/ μ L en los diferentes registros. Finalmente, en 2024, los valores de CD4 muestran un promedio de 503.5 células/ μ L, con algunos registros estables (482 células/ μ L). Esto sugiere que, al menos en algunos pacientes, los niveles de CD4 se han mantenido o mejorado, aunque persiste una cantidad considerable de datos faltantes. La Tabla 4.1 y la Tabla 4.2 presentan los resúmenes estadísticos de estas bases de datos.

La tendencia general en los datos de carga viral presenta un panorama complejo y variable, que refleja tanto la efectividad del tratamiento como las fluctuaciones en la salud de los pacientes a lo largo del tiempo. Los registros de 2018 muestran una carga viral baja, con un mínimo constante de 40 copias/mL (nivel indetectable), lo que sugiere que muchos pacientes se encontraban en una fase controlada de la infección. En 2019, la situación se mantuvo relativamente estable, con valores que oscilaron entre 40 y 74 copias/mL. La media aumentó a 57 copias/mL, indicando una ligera variación en la carga viral, pero aún un período donde muchos registros se mantuvieron en el rango bajo. El año 2020 presenta un cambio drástico, mostrando una carga viral de cero, lo que sugiere una posible respuesta efectiva a los tratamientos. Sin embargo, se observan picos altos con valores que alcanzan hasta 415,200 copias/mL, lo que indica que algunos pacientes no lograron controlar su carga viral. Durante 2021, los datos reflejan una gran heterogeneidad, con picos extremos en las cargas virales (hasta 2,396,609 copias/mL) y muchos registros mostrando cero. Esto sugiere que, aunque algunos pacientes han logrado controlar su carga viral, otros enfrentan dificultades significativas en el manejo de la enfermedad. En 2022, la carga viral presenta un amplio rango, con registros que van de cero a 1,558,752 copias/mL, con un promedio

Tabla 4.1: Resumen estadístico de recuentos de linfocitos T CD4.

Period	Min	Q1	Median	Mean	Q3	Max	NAs
cd_2018_1	498	602.5	707.0	707.0	811.5	916	174
cd_2018_2	498	498.0	498.0	498.0	498.0	498	175
cd_2019_1	251	397.8	544.5	544.5	691.2	838	174
cd_2019_2	362	373.5	385.0	385.0	396.5	408	174
cd_2020_1	48	335.5	486.0	489.2	647.2	971	140
cd_2021_1	26	187.0	468.0	500.2	721.8	1328	146
cd_2021_2	8	290.5	459.0	470.8	586.5	1485	93
cd_2021_3	43	115.8	188.5	188.5	261.2	334	174
cd_2022_1	14	197.0	359.5	389.5	499.2	917	138
cd_2022_2	28	245.0	417.0	445.8	602.0	1185	47
cd_2022_3	49	85.0	121.0	130.0	170.5	220	173
cd_2023_1	47	92.5	340.0	365.3	537.5	910	169
cd_2023_2	32	223.5	341.5	405.5	552.0	1035	122
cd_2023_3	10	286.0	453.0	478.6	652.0	1124	23
cd_2024_1	53	349.0	496.0	503.5	627.0	1240	69
cd_2024_2	77	236.5	458.0	466.4	594.0	1176	164
cd_2024_3	482	482.0	482.0	482.0	482.0	482	175

Tabla 4.2: Resumen estadístico de cargas virales.

Period	Min	Q1	Median	Mean	Q3	Max	NAs
vl_2018_1	40	40.0	40.0	40.0	40.0	40	174
vl_2018_2	40	40.0	40.0	40.0	40.0	40	175
vl_2019_1	40	48.5	57.0	57.0	65.5	74	174
vl_2019_2	40	40.0	40.0	40.0	40.0	40	174
vl_2020_1	0	0.0	0.0	13027.3	35.0	415200	138
vl_2021_1	0	0.0	10.0	133172.4	58.0	2396609	148
vl_2021_2	0	0.0	0.0	6909.1	40.0	254443	100
vl_2021_3	1146	31957.8	62769.5	62769.5	93581.2	124393	174
vl_2022_1	0	0.0	20.0	36295.4	57.0	971999	140
vl_2022_2	0	0.0	20.0	21291.9	39.5	1558752	53
vl_2022_3	20	117.0	214.0	3087.0	4620.5	9027	173
vl_2023_1	0	0.0	20.0	49087.0	65.0	245350	171
vl_2023_2	0	0.0	20.0	120571.8	82.0	4538095	121
vl_2023_3	0	0.0	20.0	76080.9	28.0	10000000	27
vl_2024_1	0	0.0	20.0	6950.4	20.0	293018	77
vl_2024_2	0	0.0	0.0	13.5	20.0	76	163
vl_2024_3	0	0.0	0.0	0.0	0.0	0	175

Tabla 4.3: Resumen estadístico de interacciones de competencia para linfocitos T CD4 y carga viral.

Statistic	cd3_diff	cds3_diff	vl3_diff	vlog3_diff	vlogs3_diff
Min	-296.0000	-1.3828	-9999850.000	-5.1022	-3.9347
Q1	-7.8125	-0.0872	-576.625	-0.9612	-0.6643
Median	29.8750	0.0442	0.000	0.0000	-0.0886
Mean	47.0468	0.1514	-105223.080	-0.6088	-0.4136
Q3	79.4167	0.2725	0.000	0.0000	0.0203
Max	482.0000	2.1804	292058.000	2.4846	2.2454

de 21,291.9 copias/mL. La tendencia parece seguir una línea similar en 2023, donde los valores altos son aún más pronunciados, alcanzando hasta 4,538,095 copias/mL, lo que indica que algunos pacientes experimentan episodios graves de alta carga viral a pesar del tratamiento. A medida que se avanza en 2024, la tendencia de la carga viral parece estabilizarse en algunos registros, con muchos de ellos mostrando cero, lo que sugiere que los pacientes han logrado una supresión viral adecuada. Sin embargo, la falta de datos en otros registros dificulta una evaluación completa.

La generación de estas interacciones se lleva a cabo mediante funciones especializadas que procesan los datos longitudinales de CD4 y carga viral. Estas funciones calculan las diferencias medias entre años y transforman los valores en un formato estandarizado, sirviendo como entradas fundamentales para la construcción del juego cuántico de fenotipos. La comprensión de estas interacciones es crucial para modelar el comportamiento de los fenotipos del VIH, ya que correlacionan la respuesta inmunitaria (CD4) con la actividad viral (carga viral).

De manera similar se trabaja con las otras interacciones. La Tabla 4.3 muestra los resúmenes estadísticos de cada interacción. El análisis de las distribuciones de estas métricas de interacción revela características importantes que influyen en la elección de los métodos de modelización (Figura 4.1).

Las diferencias absolutas en CD4 muestran un amplio rango, desde disminuciones significativas hasta aumentos notables. Las diferencias estandarizadas de CD4 reducen este rango y centralizan la distribución, como se observa en los histogramas de la Figura 4.1. Sin embargo, los gráficos Q-Q sugieren que, incluso después de la estandarización, la distribución de CD4 se desvía de la normalidad, presentando colas más pesadas de lo que una distribución gaussiana implicaría. Esto indica la presencia de valores atípicos o extremos en las variaciones de CD4, que pueden ser críticos para comprender la dinámica inmunológica.

Por otro lado, las diferencias absolutas de carga viral exhiben una dispersión extremadamente amplia y una asimetría pronunciada, con la mayoría de los valores concentrados cerca de cero pero con picos muy elevados (positivos y negativos) que son indicativos de cambios drásticos en la viremia.




Figura 4.1: Distribuciones de las interacciones de competencia. La falta de normalidad en las colas dificultan la implementación de métodos estadísticos clásicos de modelación.

La transformación logarítmica mitiga esta asimetría y compresa la escala, lo que es una práctica común para normalizar datos de carga viral y hacerlos más manejables estadísticamente. No obstante, al examinar los gráficos Q-Q de la carga viral transformada logarítmicamente, se aprecia que, a pesar de la transformación y estandarización, las distribuciones persisten en exhibir colas pesadas. Esto se manifiesta en los puntos de los gráficos Q-Q que se desvían significativamente de la línea de referencia en los extremos de la distribución, tanto en la parte superior como en la inferior.

La presencia de colas pesadas en las distribuciones de estas interacciones, incluso después de las transformaciones, implica que los eventos extremos (grandes cambios en CD4 o carga viral) son más frecuentes de lo que se esperaría bajo una distribución normal. Esta característica es crucial porque la mayoría de los métodos estadísticos clásicos, como la regresión lineal o las pruebas t, asumen una distribución normal de los datos o de los residuos, y su aplicación directa a datos con colas pesadas puede conducir a inferencias erróneas o modelos poco robustos.

La falta de normalidad y la naturaleza no gaussiana de estas distribuciones limitan la efectividad de los enfoques estadísticos clásicos para una modelación precisa. En contraste, la computación cuántica, al operar sobre amplitudes de probabilidad y permitir estados en superposición y entrelazamiento, ofrece un marco inherente para lidiar con la naturaleza probabilística y las complejidades distributivas de estos datos biológicos.

Las propiedades cuánticas pueden capturar las correlaciones y las dinámicas no lineales de las interacciones fenotípicas de una manera que los modelos clásicos, basados en supuestos de normalidad, no pueden. Esto justifica el enfoque de la teoría de juegos cuánticos para modelar la competencia de los fenotipos del VIH, ya que permite una representación más fiel de la realidad molecular y probabilística de la infección.

Para corroborar esta justificación, se realizó un análisis de los patrones de datos faltantes en las variables de las Tablas 4.1 y 4.2. Se aplicó la prueba de Little, bajo la hipótesis nula de que los datos son Missing Completely At Random (MCAR), ya que representa el escenario ideal donde los métodos de imputación o modelado no introducen sesgos y permiten al VQE trabajar con las interacciones calculadas sin riesgo de distorsión sistemática. Los resultados se muestran en la Tabla 4.4.

Tabla 4.4: Análisis de Patrones de Datos Faltantes.

Variable	Prueba	Estadístico	p-valor	Interpretación
CD4	Little	296.0, $gl = 296$	0.485	No se rechaza MCAR; los valores faltantes son compatibles con aleatoriedad completa.
VL	Little	174, $gl = 299$	1.000	No se rechaza MCAR; los valores faltantes son compatibles con aleatoriedad completa.

La aplicación de la prueba de Little para la aleatoriedad de los datos faltantes arrojó un p-valor > 0.05 , lo que no permite rechazar la hipótesis de que los datos faltan completamente al azar. En consecuencia, se determina que el mecanismo de falta de datos es MCAR, donde la probabilidad de ausencia no está condicionada por la variable temporal (periodo de recolección). Dado que la ausencia no es una propiedad intrínseca del diseño muestral o sesgo de respuesta, se puede considerar que el modelo de competencia es robusto bajo esta estructura.

4.2. Clasificación de Interacciones Fenotípicas

La Tabla 4.5 representa la ESS para el juego.

Tabla 4.5: Fenotipo evolutivamente estable del juego.

Fenotipo	v	V
v	(α, α)	(β, γ)
V	(γ, β)	(θ, θ)

En la matriz de la Tabla 4.5:

- α : Beneficio asociado a la interacción entre dos fenotipos de baja replicación v-v, donde los recursos se utilizan de manera sostenible, permitiendo un agotamiento lento de las células CD4 y una supervivencia prolongada.
- θ : Beneficio asociado a la interacción entre dos fenotipos de alta replicación V-V, donde se produce un rápido agotamiento de los recursos, baja supervivencia y una disminución del éxito reproductivo.
- β y γ : Representan los beneficios asociados a las interacciones entre fenotipos de alta y baja replicación v-V y V-v. En estas interacciones, el fenotipo V de alta replicación domina, obteniendo el mayor beneficio γ , mientras que el fenotipo v se ve desfavorecido y recibe el menor beneficio β .

Los beneficios se ordenan como $\gamma > \alpha > \theta > \beta$, lo que indica que, aunque V agota rápidamente los recursos, inicialmente obtiene una mayor ventaja en comparación con v.

Aunque no es óptimo de Pareto, el punto de equilibrio se produce en el punto de combinación (V - V) con los pagos (θ, θ) . Por lo tanto, V es el fenotipo evolutivamente estable. Según estos resultados de los aspectos clásicos, se puede interpretar como “dar prioridad al fenotipo V al desarrollar ingredientes farmacéuticos”. Este argumento lleva los juegos biológicos a una perspectiva cuántica.

La selección del número óptimo de conglomerados k es crucial para la interpretación y efectividad de la clasificación. Se empleó el método del codo, que evalúa la relación entre el número de conglomerados y la suma de los cuadrados dentro de ellos. Este método se basa en graficar el WSS en función del número de conglomerados k . El punto de “codo” en el gráfico, donde la disminución de WSS se ralentiza considerablemente, se considera el número óptimo de conglomerados. Como se muestra en la Figura 4.2, este método identificó 4 conglomerados como el número óptimo, al observar un punto de inflexión donde la adición de más conglomerados no reduce significativamente la suma de cuadrados.

Tabla 4.6: Resumen estadístico de variables para la clasificación de interacciones.

Statistic	cds3_diff	vlogs3_diff
Min	-1.3828	-3.9347
Q1	-0.0872	-0.6643
Median	0.0442	-0.0886
Mean	0.1514	-0.4136
Q3	0.2725	0.0203
Max	2.1803	2.2454

Tabla 4.7: Clasificación de interacciones de competencia.

Classification	Count
1	12
2	119
3	11
4	34




Figura 4.2: Método del codo con 4 conglomerados.

Los resultados de la clasificación y el comportamiento observado en los recuentos de CD4 y la carga viral son consistentes con las interpretaciones de las interacciones fenotípicas, tal como se detalla en la Tabla 4.8. Esta asimilación empírica del análisis de conglomerados con el escenario clásico de juegos de fenotipos del VIH (Tabla 4.5), permite asociar los 4 conglomerados observados con las posibles dinámicas de competencia entre un fenotipo v

de baja reproducción viral y un fenotipo V de alta reproducción.

Tabla 4.8: Comportamientos fenotípicos esperados en la clasificación.

Clase	Comportamiento linfocitos T CD4	Comportamiento Carga Viral	Tipo de Interacción	Justificación
1	Aumento	Disminución	$v \times v$	Respuesta inmune saludable con fuerte recuperación de CD4 y supresión viral.
2	Estable o Ligero	Aumento moderado	$V \times V$	Estabilidad en CD4 con aumento de carga viral sugiere ventaja competitiva del fenotipo V .
3	Aumento (posiblemente durante seroconversión)	Aumento	$v \times V$	Aumento dual indica que ningún fenotipo domina; interacción común en seroconversión.
4	Disminución	Disminución	$V \times v$	Disminución de recuentos podría implicar una interacción no competitiva sino mutua (ambos se ven afectados).

La interpretación de la clase 3, donde tanto los recuentos de CD4 como la carga viral aumentan, puede entenderse como reflejo de una dinámica inmunológica transitoria presente en las fases tempranas de la infección por VIH, especialmente durante la seroconversión ([i-Base, 2023b](#)). Durante este periodo, es común observar un pico inicial de carga viral seguido de una recuperación parcial de linfocitos T CD4, como respuesta del sistema inmunitario ante la replicación viral activa ([Seth et al., 2005](#); [Scriba et al., 2005](#)).

El tiempo de infección por VIH influye en la dinámica de CD4 a lo largo del tiempo. En la seroconversión, los aumentos temporales de CD4 pueden reflejar respuestas inmunes efímeras, como se ha observado en varias fases del VIH. En el conglomerado 3, los pacientes de 2021-2024 tienen un período más corto bajo ART, lo que podría explicar un comportamiento de seroconversión más temprano o una respuesta menos efectiva al tratamiento. Este grupo muestra un aumento tanto en CD4 como en la carga viral, lo que sugiere una interacción v - V donde ninguno de los fenotipos domina completamente. Este patrón es común en la seroconversión, donde el sistema inmunitario lucha por controlar la infección, lo que resulta en fluctuaciones en ambos marcadores ([i-Base, 2023a](#)).

El aumento simultáneo de CD4 y carga viral en el conglomerado 3 podría indicar una competencia fenotípica entre un virus menos agresivo (v) y uno dominante (V). Durante la seroconversión, es común observar aumentos temporales en CD4 a medida que el sistema inmunitario intenta adaptarse, incluso cuando la carga viral permanece alta. Un aspecto clave es que estos pacientes han recibido ART por menos tiempo, lo que puede afectar la respuesta inmunológica y virológica, impidiendo una supresión viral efectiva o un sostenimiento de la recuperación inmunológica. Esto sugiere un estado temprano o una respuesta ineficaz al tratamiento, reflejada en el aumento temporal de CD4 junto con una carga viral elevada. El comportamiento observado en el conglomerado 3 es consistente con las fluctuaciones inmunológicas típicas de las primeras etapas del tratamiento o la seroconversión. La falta de tiempo bajo ART podría explicar la incapacidad de estos pacientes para estabilizar completamente la carga viral y los recuentos de CD4, lo que resulta en un patrón de competencia fenotípica.

La Figura 4.3 muestra la representación visual de los resultados de la clasificación de interacciones, permitiendo evaluar visualmente la distribución de las interacciones en función de sus diferencias de carga viral y recuentos de CD4 como una representación de su clasificación fenotípica. El conglomerado 2, con 119 observaciones, es el más grande, sugiriendo un estado de diferencias mínimas entre la carga viral y el CD4. El conglomerado 1, con 12 observaciones, presenta una disminución en la carga viral y un aumento en CD4, indicando una respuesta inmune favorable. El conglomerado 3, aunque más pequeño (11 observaciones), muestra un aumento en ambos marcadores, lo que sugiere una interacción competitiva. Finalmente, el conglomerado 4 (34 observaciones) presenta una disminución en la carga viral y un ligero aumento en CD4, indicando una respuesta fenotípica variable.




Figura 4.3: Clasificación de interacciones fenotípicas.

La clasificación puede variar al tomar diferentes valores que representen las diferencias en la carga viral y el CD4, así como varios parámetros opcionales. El número de conglomerados se espera en 4 por defecto debido a la estructura del modelo de juego cuántico de fenotipos de VIH, aunque puede ajustarse según las necesidades del análisis. Además, se pueden considerar otros escenarios con el número de inicios aleatorios para el algoritmo k-means o se puede fijar una semilla en los inicios aleatorios para asegurar la reproducibilidad de los resultados.

La estimación de parámetros mediante el modelo de red neuronal seleccionado (5 unidades ocultas, penalización $L2 = 0.1673$, 673 épocas) produjo los valores de beneficio presentados en la Tabla 4.9. Los parámetros mantienen la relación jerárquica $\gamma > \alpha > \theta > \beta$ requerida por el modelo de juego cuántico.

La aplicación del Algoritmo del Beneficio Más Cercano a los 6 pacientes de la cohorte con coinfección por tuberculosis (IDs: 37, 102, 148, 174, 180, 205) produjo los resulta-

Tabla 4.9: Parámetros del modelo de juegos cuánticos para las interacciones fenotípicas del VIH.

Classification	CD4 Diff Mean	VL Diff Mean	Payoff Full	Payoff Batch	N
1	0.771	-3.039	-1.309	-1.988	12
2	-0.034	-0.014	-0.230	-0.254	119
3	1.299	0.392	-0.754	0.382	11
4	0.210	-1.146	-0.566	-0.674	34

dos de la Tabla 4.10. La asignación de puertas cuánticas reveló que los pacientes 37 y 148 correspondieron a la estrategia V_X_H (fenotipo V aplica X, fenotipo v aplica H), mientras que los pacientes 102 y 174 correspondieron a V_X_I. Los pacientes 180 y 205 correspondieron a las variantes por lotes v_X_H_b y v_X_I_b, respectivamente.

Tabla 4.10: Asignación de estrategias y puertas cuánticas para pacientes con coinfección por tuberculosis.

ID de Paciente	Estrategia	Descripción del Fenotipo
37	V_X_H	V aplica X / v aplica H
102	V_X_I	V aplica X / v aplica I
148	V_X_H	V aplica X / v aplica H
174	V_X_I	V aplica X / v aplica I
180	v_X_H_b	Variante por lotes
205	v_X_I_b	Variante por lotes

4.3. Biomarcadores Clínicos de la competencia de CD4 y carga viral

Con el propósito de garantizar la robustez, generalizabilidad y estabilidad de los algoritmos predictivos frente a la variabilidad en la partición de los datos, se implementó un esquema de validación cruzada utilizando un total de 10 semillas aleatorias independientes. Este protocolo permitió evaluar de forma rigurosa el rendimiento de los modelos predictivos al estimar tanto la dinámica diferencial de los linfocitos T CD4 como la de la carga viral, mitigando cualquier sesgo derivado de una única partición muestral.

El análisis agregado a través de las diez semillas para la competencia de linfocitos T CD4 evidenció una superioridad consistente de los enfoques de regularización lineal. El modelo de Regresión penalizada sobresalió al registrar el error cuadrático medio más bajo y la mayor estabilidad en la varianza explicada, cuyos valores consolidados se presentan en la Tabla 4.11.

De manera congruente, la evaluación multisemilla para la competencia de carga viral ratificó la eficiencia de la Regresión penalizada en la captura de las relaciones multivariadas complejas del sistema virológico, alcanzando un coeficiente de determinación promedio superior y una menor dispersión en el error, tal como se detalla en la Tabla 4.12.

Tabla 4.11: Rendimiento consolidado de los modelos para la competencia de CD4 mediante 10 semillas.

Modelo	RMSE (Media)	RMSE (DE)	MAE (Media)	MAE (DE)	R^2 (Media)	R^2 (DE)
Regresión penalizada	0.2340	0.0552	0.1643	0.0394	0.8851	0.0301
Random Forest	0.2450	0.0859	0.1528	0.0406	0.8495	0.0649
XGBoost	0.2723	0.0720	0.1698	0.0338	0.7994	0.0898
SVM radial	0.2911	0.0712	0.1964	0.0590	0.7544	0.2226
KNN	0.3105	0.0736	0.2125	0.0458	0.7179	0.1259

Tabla 4.12: Rendimiento consolidado de los modelos para la competencia de carga viral mediante 10 semillas.

Modelo	RMSE (Media)	RMSE (DE)	MAE (Media)	MAE (DE)	R^2 (Media)	R^2 (DE)
Regresión penalizada	0.2801	0.0552	0.2250	0.0433	0.9210	0.0378
Random Forest	0.4048	0.1106	0.2668	0.0595	0.8507	0.1036
XGBoost	0.4639	0.0849	0.3303	0.0631	0.8051	0.0788
SVM radial	0.4851	0.1276	0.3393	0.0936	0.7926	0.1461
KNN	0.4934	0.1301	0.3670	0.1186	0.7882	0.1160

Los resultados globales consolidan a la regresión penalizada como el núcleo analítico óptimo para la interpretación estructural de los biomarcadores fenotípicos y cuánticos del modelo qphen.

Para evaluar la capacidad predictiva de las características fenotípicas cuánticas (qphen), se implementó un flujo de trabajo analítico estandarizado enfocado en predecir dos desenlaces inmunovirológicos continuos: la competencia de linfocitos T CD4 (cd_diff) y la competencia de carga viral (vl_diff). El análisis integró cuatro familias de algoritmos —K-Vecinos Más Cercanos (KNN), Bosques Aleatorios (RF), Máquina de Soporte Vectorial (SVM) y Regresión Penalizada— utilizando la suite tidymodels. En la fase inicial de entrenamiento para la dinámica de CD4, se aplicó un esquema de validación cruzada estratificada de 5 pliegues (5-fold CV) sobre la totalidad del conjunto de datos. Tal como se ilustra en la Figura 4.4 el modelo de Regresión Penalizada demostró un desempeño logrando realizar una selección efectiva de variables en el espacio multidimensional qphen. Esto le permitió alcanzar un error cuadrático medio ($RMSE$) de 0.1537, un coeficiente de determinación (R^2) de 0.898 y un error absoluto medio (MAE) de 0.1045 en entrenamiento.




Figura 4.4: Comparación del desempeño de modelos (KNN, RF, Regresión Penalizada, SVM) mediante validación cruzada y evaluación de la capacidad predictiva del mejor modelo seleccionado para la competencia de CD4 sobre el conjunto de entrenamiento.

Con la finalidad de diagnosticar la presencia de sobreajuste y verificar la capacidad de generalización del modelo Regresión Penalizada en la predicción de competencia de CD4, se ejecutó una partición estratificada conservando el 80 % de los datos para entrenamiento ($n = 140$) y reservando el 20 % restante para evaluación independiente en prueba ($n = 36$), cuyos parámetros se sintetizan en la Tabla 4.13. La evaluación detallada en el conjunto de prueba, representada en la Figura 4.5, confirmó la estabilidad del modelo de regresión al registrar un $RMSE$ en prueba de 0.1914, un R^2 de 0.8677 y un MAE de 0.1485. La mínima discrepancia observada entre el error de entrenamiento y prueba ($\Delta RMSE < 0.1$) descartó la presencia de memorización, mientras que la dispersión de predicciones mostró una clara alineación sobre la diagonal de identidad $y = x$.




Figura 4.5: Evaluación comparativa del desempeño de los modelos en el esquema de partición entrenamiento-prueba para la competencia de CD4. Se ilustra la métrica RMSE, la correlación entre valores observados vs. predichos y la comparación de errores para detectar sobreajuste.

El explicador global para el modelo de regresión penalizada (Figura 4.6) reveló que la variable con mayor pérdida de rendimiento al ser permutada, demuestra que el modelo depende críticamente de la proyección no lineal de las diferencias de CD4 sobre las expectativas teóricas del juego cuántico. Esto significa que al mapear la variación clínica a un

Tabla 4.13: Tabla de resultados de la evaluación comparativa del desempeño para la competencia de CD4 en conjunto de prueba.

Métrica	Valor
N Observaciones	176
N Prueba	36
Mejor Modelo	Regresión penalizada
RMSE (Prueba)	0.1914
R2 (Prueba)	0.8677
MAE (Prueba)	0.1485

estado de beneficios óptimos regido por interferencias y operadores cuánticos, se captura la estructura subyacente más potente para predecir el comportamiento del sistema. En segundo lugar, la posición de la variable del beneficio clásico indica que existe una estrategia de aprendizaje híbrido o en cascada altamente efectiva. En el contexto de la teoría de juegos, esto actúa como una estrategia de beneficio esperado derivada de la interacción cruzada entre los fenotipos de replicación lenta (v) y rápida (V), dotando al modelo lineal penalizado de información multivariada avanzada sin requerir relaciones puramente lineales directas.




Figura 4.6: Explicador global para el modelo de regresión aplicado a competencia de CD4. El modelo penalizado identifica al beneficio más cercano en el modelo cuántico y a los beneficios esperados por el modelo clásico como los factor más relevantes, superando incluso a marcadores clínicos de alta severidad como la presencia de genorresistencia o coinfección por tuberculosis.

Tabla 4.14: Tabla de resultados de la clasificación de fenotipos para la competencia de CD4.

classification	cds_diff_mean	vlogs_diff_mean	payoff	n	payoff_b
1	0.8173448	-3.0061832	0.7464828	9	0.7430715
2	-0.0198789	0.0157594	0.0183350	87	0.0182404
3	0.1815008	-1.0211102	0.1926270	35	0.1959017
4	1.2922704	0.4992175	0.8451674	9	0.8510248

El análisis de explicabilidad global mediante permutación de variables (DALEXtra) expuesto en la Figura 4.6 reveló que los atributos del marco cuántico ejercen un dominio jerárquico determinante sobre la competencia linfocitaria. Específicamente, los beneficios obtenidos en el juego cuántico (payoffs) y los beneficios calculados por lote (payoffs _b) se posicionaron como factores importantes en la reducción de la pérdida de *RMSE*.

Avanzando en la jerarquía de importancia, en cuarto lugar se posiciona la variable fenotípica binaria phen_1 ($0 = v$, $1 = V$), la cual opera como un interruptor estructural que discrimina los regímenes virales dominantes. Su relevancia radica en que traduce los estados cuánticos de superposición a una categorización biológica directa, permitiendo al modelo capturar el cambio de fase entre la replicación viral reprimida y la alta proliferación. Por su parte, la inclusión del one-hot encoding a través de classification_4 (representativa del cuarto clúster de interacción) adquiere un rol explicativo fundamental al alinearse con la teoría de Özlüer Başer (2022). Al examinar el comportamiento espacial de los centroides (Tabla 4.14), el clúster 4 se caracteriza por presentar los valores más elevados tanto en la media de las diferencias de CD4 (cgs_diff_mean = 1.292) como en la media de las diferencias de carga viral (vlogs_diff_mean = 0.499), con un tamaño de población reducido ($n = 9$). Esta configuración geométrica extrema representa un estado de alta divergencia inmunológica y viral donde el beneficio esperado alcanza su cota máxima (payoff = 0.845 y payoff_b = 0.851). De este modo, la variable classification_4 actúa como un marcador de frontera altamente sensible, permitiendo que la regresión penalizada identifique y penalice desviaciones en pacientes con dinámicas de co-evolución agresivas, superando en poder explicativo a marcadores clínicos tradicionales como la genoresistencia (GR_1) o la coinfección activa por tuberculosis (TB_1).

Para garantizar que estas inferencias fueran confiables y no constituyeran extrapolaciones en zonas no representadas del espacio muestral, se calculó el dominio de aplicabilidad con el paquete viraldomain. Los resultados descritos en la Tabla 4.15 demostraron que las observaciones del conjunto de prueba mantuvieron distancias al centroide bien contenidas por debajo del percentil 86 %, confirmando la validez espacial de las predicciones.

Buscando optimizar aún más la precisión en la competencia de CD4, se construyó un modelo de ensamble apilado mediante la librería **stacks**, combinando las predicciones ponderadas de los cuatro algoritmos evaluados. Como se registra en la Tabla 4.16, la arquitectura de ensamble logró superar los límites de varianza de los modelos individuales, alcanzando un *RMSE* de 0.182, reduciendo el *MAE* a 0.111 y capturando un 89 % de la varianza total ($R^2 = 0.890$), lo que la consolidó como la herramienta predictiva más ajustada para la competencia de linfocitos CD4.

Al extender la metodología analítica hacia la competencia de carga viral (vl_diff), la

Tabla 4.15: Resumen del dominio de aplicabilidad para el modelo de regresión penalizada en la predicción de competencia de CD4, evaluando la distancia de las observaciones de prueba respecto al espacio de entrenamiento.

Observation	pred	distance	distance_pctl
Obs_1	-0.6128	6.3048	85.9806
Obs_2	0.7559	3.8058	61.2265
Obs_3	0.8651	3.4573	71.1892
Obs_4	-0.5914	4.3407	61.8300
Obs_5	0.1337	3.7636	82.4164
Obs_6	0.1247	5.7657	82.4489

Tabla 4.16: Resumen de las métricas finales de rendimiento del modelo de ensamble para la predicción de competencia de CD4, superando a los modelos individuales en términos de RMSE y coeficiente de determinación.

Métrica	Valor
N Entrenamiento	140
N Prueba	36
Mejor Modelo	Ensamble Apilado
RMSE (Prueba)	0.182
R2 (Prueba)	0.89
MAE (Prueba)	0.111

validación cruzada inicial de 5 pliegues en entrenamiento también reflejó una adecuada tasa de convergencia para el modelo de Regresión Penalizada ($RMSE = 0.2981$, $R^2 = 0.8861$, $MAE = 0.1931$), según se aprecia en la Figura 4.7.




Figura 4.7: Comparación y validación cruzada de modelos aplicada a la competencia de carga viral sobre el conjunto de entrenamiento, mostrando la estabilidad del RMSE y el comportamiento de las predicciones frente a los valores reales.

Para el diagnóstico integral del modelo en la fase de prueba, desplegado en la Figura

4.8, la regresión penalizada demostró una capacidad de generalización al alcanzar un $RMSE$ de 0.3458, un R^2 de 0.904 y un MAE de 0.2489. La consistencia entre el error de entrenamiento ($RMSE \approx 0.2981$) y el de prueba ($RMSE = 0.3458$) confirmó la ausencia de sobreajuste.




Figura 4.8: Evaluación final del modelo de bosque aleatorio para competencia de carga viral en el conjunto de prueba y consistencia del RMSE entre los conjuntos de entrenamiento y prueba.

La arquitectura aplicada al conjunto de prueba independiente (20 %, $n = 36$) sobre la partición estratificada resumida en la Tabla 4.17 para el algoritmo de Regresión Penalizada emergió como la solución óptima para capturar las no linealidades complejas de la replicación virológica.

Tabla 4.17: Tabla de resultados de la evaluación comparativa del desempeño para la competencia de carga viral en conjunto de prueba.

Métrica	Valor
N Observaciones	176
N Prueba	36
Mejor Modelo	Regresión penalizada
RMSE (Prueba)	0.3458
R2 (Prueba)	0.904
MAE (Prueba)	0.2489

El análisis de explicabilidad global mediante permutación de variables para la predicción de la carga viral muestra un comportamiento estructural análogo al observado en el recuento de células CD4. Al igual que en el modelo de CD4, la variable con mayor pérdida de rendimiento al ser permutada es el beneficio cuántico más cercano (`nearest_payoff`). Esto demuestra que la dinámica de la carga viral depende críticamente de la proyección sobre los estados de superposición y entrelazamiento modelados por matrices unitarias, capturando la selección natural a nivel molecular donde los fenotipos virales escapan de los equilibrios clásicos subóptimos.

A diferencia del modelo de CD4, en la predicción de la carga viral se observa una jerarquía superior de los beneficios clásicos esperados por lotes (payoffs_b) por encima de los beneficios calculados sobre observaciones individuales (payoffs). Esto indica que el modelado en cascada y por bloques captura de manera más eficiente la varianza poblacional de la replicación viral y la presión de mutación masiva inherente a la alta tasa evolutiva del VIH.

La inclusión destacada de la media de la diferencia de carga viral (vlogs_diff_mean) y del identificador de pertenencia al clúster de interacción (classification) refleja que la estructuración geométrica del espacio muestral aporta información multivariada clave.

En quinto lugar se posiciona la variable classification_4, que según la tabla de centroides del modelo (Tabla 4.18), el clúster 4 agrupa a un conjunto minoritario de observaciones ($n = 12$) caracterizado valores elevado tanto en la media de las diferencias de CD4 (cds_diff_mean = 1.185) como en la media de la diferencia de carga viral (vlogs_diff_mean = 0.312), alcanzando beneficios clásicos esperados cercanos a cero (payoff = 0.0014, payoff_b = 0.0023). Esta configuración permite que el indicador classification_4 actúe como un interruptor de sensibilidad para capturar dinámicas virales agresivas y no lineales.

Siguiendo inmediatamente en la jerarquía de importancia se encuentra la variable str2_5, la cual codifica la presencia de la puerta de Pauli- Y (Y) en la segunda compuerta del operador cuántico base (donde str2_5 toma el valor de 1 si la compuerta es Y y 0 en caso contrario, bajo una línea base de identidad I). Su relevancia muestra que las rotaciones complejas y la introducción de fases imaginarias en los operadores de Pauli son necesarias para modelar la resistencia y el ajuste dinámico del sistema viral.




Figura 4.9: Explicador global para el modelo de regresión aplicado a competencia de carga viral. El modelo penalizado identifica al beneficio más cercano en el modelo cuántico y a los beneficios esperados por el modelo clásico como los factor más relevantes, superando incluso a marcadores clínicos de alta severidad como la presencia de genorresistencia o coinfección por tuberculosis.

Tabla 4.18: Tabla de resultados de la clasificación de fenotipos para la competencia de carga viral.

classification	cds_diff_mean	vlogs_diff_mean	payoff	n	payoff_b
1	0.8500869	-2.7690434	-2.0210677	9	-2.0279141
2	0.1193709	-1.0792873	-0.8578430	33	-0.8614815
3	-0.0252128	0.0053530	-0.0893257	86	-0.0879815
4	1.1854419	0.3120141	0.0014758	12	0.0023538

La evaluación del dominio de aplicabilidad para el modelo de regresión, presentada en la Tabla 4.19, certificó que las muestras del conjunto de prueba se ubicaron dentro de percentiles de distancia seguros (26.1 % a 82.4 %), lo que garantizó la alta confiabilidad de las inferencias. Finalmente, la integración de los hiperparámetros optimizados en un modelo de ensemble apilado arrojó los niveles de precisión más elevados del estudio para la carga viral, reportados en la Tabla ???. Este ensemble redujo el error cuadrático medio en prueba a $RMSE = 0.1420$, el MAE a 0.0824 y elevó el coeficiente de determinación a $R^2 = 0.9520$, consolidando la efectividad de los descriptores cuánticos dentro de un esquema analítico robusto y de alto rendimiento.

Tabla 4.19: Resumen del dominio de aplicabilidad para el modelo de regresión penalizada en la predicción de competencia de carga viral, evaluando la distancia de las observaciones de prueba respecto al espacio de entrenamiento.

Observation	pred	distance	distance_pctl
Obs_1	-0.1026	1.9695	0.0000
Obs_2	0.1208	2.0657	0.0000
Obs_3	0.1458	1.9452	0.0000
Obs_4	-3.7336	9.8110	1.0000
Obs_5	-2.8831	5.7854	82.6942
Obs_6	-3.8046	10.0730	1.0000

Los resultados correspondientes del dominio de aplicabilidad para el modelo de regresión, presentada en la Tabla 4.19 y sus respectivos percentiles de pertenencia con un umbral estricto del 99 % demostraron que la gran mayoría de las observaciones del conjunto de prueba se encuentran estrechamente contenidas dentro del espacio de calibración. Específicamente, las distancias calculadas oscilan entre 1.945 y 10.073, reflejando que los casos típicos presentan percentiles de distancia de 0.00 %, 82.69 %. Esto confirma que el modelo opera dentro de los márgenes de confianza espaciales definidos por los centroides de entrenamiento, validando la fiabilidad de las estimaciones obtenidas mediante el enfoque de regresión penalizada.

Capítulo 5

Discusión y Conclusiones

5.1. Contraste Metodológico

Los enfoques predictivos tradicionales en VIH (Salgado Jiménez et al., 2025; Li et al., 2022; Sun et al., 2026) evalúan los conteos de CD4 y la carga viral mediante mediciones transversales, valores basales anclados o modelos lineales de pocos rezagos. En contextos reales de alta escasez de datos (como el HGR No. 1 del IMSS en Acapulco, Guerrero, con promedios de datos faltantes del 80.8 % en CD4 y 81.9 % en carga viral por periodo), estos modelos estándar presentan graves deficiencias.

La pérdida de la dinámica temporal de un valor estático de CD4 de 250 células/ μl no distingue si el paciente está en fase de recuperación inmunológica tras iniciar ART o en una trayectoria acelerada de falla inmunológica y el tratamiento aislado de biomarcadores evalúan CD4 y carga viral como variables condicionales independientes, ignorando la competencia evolutiva directa entre la replicación viral y la reconstitución inmune.

Por el contrario, la formulación de competencia de CD4 competencia de carga viral basada en diferencias medias estandarizadas longitudinales ($\mathcal{I}_i^{\text{CD4-STD}}$ y $\mathcal{I}_i^{\text{CV-LOGSTD}}$), capta la velocidad inmunoviológica y determina la tasa de cambio ponderada a lo largo del historial del paciente, preservando la memoria temporal del individuo.

Esta formulación también formaliza la interacción como un juego cuántico siguiendo la extensión del modelo de Özlüer Başer (2022) mediante el paquete qvirus, convierte las trayectorias continuas en beneficios de un juego 2×2 entre fenotipos virales (v vs. V) y asigna etiquetas discretas de puertas cuánticas (I, X, H, Z, S, Y, T) mediante el algoritmo del beneficio más cercano (nearest_payoff). Esto genera la base qphen, transformando un problema de clasificación ruidoso en un espacio discreto e interpretable.

La integración de la base de datos qphen demuestra una mejora sustancial en la capacidad de modelación predictiva clásica respecto a los paradigmas estáticos y autorregresivos convencionales. Al evaluar los modelos de regresión supervisada clásica para predecir las dinámicas continuas de competencia inmunoviológica, los resultados revelan patrones diferenciados según la naturaleza del biomarcador.

Para la competencia de linfocitos T CD4 (cd_diff), la arquitectura óptima corresponde al modelo de regresión penalizada, alcanzando un coeficiente de determinación de $R^2 = 0.8677$ y un error cuadrático medio de $RMSE = 0.1914$. Específicamente, este ren-

dimiento óptimo se logró utilizando una combinación de penalización y mezcla gobernada por los hiperparámetros `penalty` = 0.0231 y `mixture` = 0.5 (correspondiente a una red elástica con balance igualitario entre L_1 y L_2). Esta parametrización demostró ser idónea para seleccionar eficientemente los componentes clave de la matriz `qphen`, eliminando la colinealidad introducida por los términos de beneficio de juego y reteniendo la velocidad de recuperación inmunológica estandarizada ($\mathcal{I}_i^{\text{CD4-STD}}$). Para la competencia de carga viral (`vl_diff`), el modelo de regresión penalizada obtuvo el mejor rendimiento global, logrando un $R^2 = 0.904$ y un $RMSE = 0.3458$. Específicamente, esta configuración se optimizó mediante los hiperparámetros `penalty` = 0.000001 y `mixture` = 0 (lo que equivale funcionalmente a una regresión Ridge pura sin penalización L_1 estricta). A diferencia de la respuesta lineal observada en CD4, la réplica y supresión viral exhibe umbrales no lineales definidos por la capacidad de evasión del virus; los coeficientes de esta regularización ridge casi nula capturaron de forma precisa las interacciones no lineales entre las combinaciones de puertas cuánticas discretas (I, X, H, Z, S, Y, T) asignadas por el algoritmo del beneficio más cercano y el diferencial de supresión logarítmica ($\mathcal{I}_i^{\text{CV-LOGSTD}}$).

Para situar la relevancia de estos hallazgos, es necesario contrastar el desempeño de los modelos de regresión clásicos sobre las variables objetivo de competencia de la base de datos `qphen` frente a la literatura clásica previa, dividida entre los antecedentes de la misma cohorte regional (HGR No. 1 del IMSS en Guerrero) y estudios en cohortes internacionales independientes.

Tabla 5.1: Comparativa del rendimiento predictivo entre el estado del arte y la metodología `qphen`.

Estudio / Enfoque	Cohorte y n	Metodología	Biomarcador / Desenlace	Rendimiento (R^2 / AUC)	Limitaciones Estructurales
Salgado-Jiménez et al. (2020)	IMSS Guerrero ($n = 232$)	Teoría de conjuntos y probabilidad	Conteos CD4 por rangos leucocitarios	Efectividad: 0.54 – 1.00	Poblacional; cae a 53.8 % en extremos.
Salgado Jiménez et al. (2024)	IMSS Guerrero ($n = 142$)	k -medias no supervisado	Agrupamiento longitudinal de CD4	$k = 3$ conglomerados	Solo casos completos; excluye carga viral.
Salgado Jiménez et al. (2025)	IMSS Guerrero ($n = 534$)	Regresión autorregresiva (2 rezagos)	Predicción secuencial de CD4	$R^2 = 0.644 - 0.656$	Ajuste lineal rígido; solo 2 rezagos.
Li et al. (2022)	Yunnan, China ($n = 96$)	SVM, RF y MLP independientes	Cociente CD4/CD8 y CD4 basal	$R^2 = 0.519$ / 0.806	Desplome en $CD4 < 200$; excluye carga viral.
Sun et al. (2026)	Multicéntrico ($n = 30,938$)	RF + SHAP	No respondedores inmunes (INR)	AUC = 0.864	Requiere n masivo; anclaje basal único.
Jin et al. (2026)	Xi'an, China ($n = 4,620$)	Stacking heterogéneo (Ridge)	Predicción prospectiva CD4/CD8	$R^2 = 0.768$ / 0.131	Ajuste colapsa sin anclaje basal.
Esta Tesis (Lasso)	IMSS Guerrero ($n = 176$)	Regresión Penalizada con <code>qphen</code>	Competencia CD4 (<code>cd_diff</code>)	$R^2 = 0.8677$ ($RMSE = 0.1914$)	Maneja > 80 % de datos faltantes.
Esta Tesis (RF)	IMSS Guerrero ($n = 176$)	Regresión Lasso con <code>qphen</code>	Competencia CV (<code>vl_diff</code>)	$R^2 = 0.904$ ($RMSE = 0.3458$)	Maneja > 81 % de datos faltantes.

El modelo autorregresivo lineal de dos rezagos desarrollado por [Salgado Jiménez et al. \(2025\)](#) sobre la misma sede hospitalaria alcanzaba un techo explícito de ajuste en $R^2 = 0.644 - 0.656$. Al sustituir la secuencia de mediciones brutas aisladas por las diferencias medias estandarizadas e integradas en el espacio del juego 2×2 de `qphen`, la regresión

Lasso eleva la varianza explicada del CD4 a $R^2 = 0.8551$ (una ganancia neta superior a 20 puntos porcentuales). Más aún, mientras que el antecedente de [Salgado-Jiménez et al. \(2020\)](#) perdía precisión drásticamente en los extremos sintomáticos (53.8 – 77.0 %), la transformación qphen suaviza el ruido observacional y retiene la velocidad inmunoviológica incluso en presencia de un 80.8 % de registros faltantes de CD4 y 81.9 % de carga viral por periodo.

La literatura internacional evidencia que la predicción clásica de biomarcadores sufre de colapso de rendimiento cuando se remueven los anclajes basales o cuando se evalúan subgrupos con inmunosupresión severa. En [Li et al. \(2022\)](#), los modelos individuales (SVM, RF, MLP) exhibieron una asimetría estructural: en pacientes avanzados ($CD4 < 200$ células/ μ l), el mejor modelo apenas alcanzó $R^2 = 0.519$, cayendo marcadamente respecto al grupo estable ($R^2 = 0.806$).

En [Jin et al. \(2026\)](#), aunque un ensamble stacking de 4,620 pacientes predijo el conteo de CD4 con $R^2 = 0.768$, la capacidad de predecir la interacción CD4/CD8 sin fuga de datos basales colapsó a $R^2 = 0.131$. En [Sun et al. \(2026\)](#), la estabilidad del ensamble ($AUC = 0.864$) dependió de un volumen muestral masivo ($> 30,000$ pacientes y $> 1,300$ casos positivos) e ignoró por completo la trayectoria longitudinal de los biomarcadores durante el tratamiento.

En contraste, la arquitectura de regresión clásica guiada por qphen no depende de muestras masivas inaccesibles en entornos regionales como Guerrero, ni sufre el colapso predictivo del cociente inmunológico. La asignación discreta del espacio de beneficio cuántico actúa como un regularizador de dominio biológico que permite a un modelo clásico convencional (Regresión Penalizada o Lasso) predecir con alta fidelidad ($R^2 > 0.86$) la tasa de cambio ponderada del paciente.

5.2. Interpretación Clínica de las Interacciones en qphen

El análisis de la clasificación de interacciones confirma que la transformación de variables mediante la teoría de juegos cuánticos no es un mero artificio algebraico, sino un marco de interpretación clínica, pues permite el filtrado de ruido y la conservación de la memoria. Las mediciones transversales aisladas reflejan fluctuaciones biológicas transitorias o errores de laboratorio. Al transformar la trayectoria en las diferencias medias estandarizadas, el sistema extrae la inercia del fenotipo viral (v vs. V).

La discretización semántica vía compuertas cuánticas y la asignación de etiquetas (I, X, H, Z, S, Y, T) mediante el beneficio más cercano (`nearest_payoff`) proyecta la competencia continua en estados de equilibrio. La combinación de compuertas codifica si la relación huésped-patógeno se encuentra en un estado de coexistencia nula (I), inversión acelerada (X), superposición de riesgo (H) o supresión por presión selectiva del tratamiento (Z, S, Y, T).

La razón por la cual la regresión penalizada ($R^2 = 0.8677$) y Lasso ($R^2 = 0.904$) superan holgadamente a los modelos previos ante una escasez de datos sobre la misma cohorte radica en que qphen reduce la dimensionalidad efectiva sin perder la interdependencia entre marcadores. Así, los conteos de CD4 y la carga viral dejan de tratarse como variables

independientes o condicionadas unidireccionalmente, evaluándose como las dos caras del beneficio evolutivo de la infección.

El análisis explicativo global por permutación de variables (DALEXtra) permite fundamentar clínicamente la jerarquía con la que cada modelo predice los desenlaces de competencia inmunobiológica. El modelo regularizado mediante penalización $L_1 - L_2$ alcanzó un $R^2 = 0.8677$ en el conjunto de prueba independiente ($n = 36$). La evaluación de explicabilidad global posicionó a las métricas derivadas del marco interactivo de qvirus como los factores dominantes en la reducción del RMSE. En particular, la variable del beneficio más cercano (nearest_payoff) constituye el predictor más determinante para la dinámica de recuperación o pérdida linfocitaria (cd_diff). En segundo y tercer lugar, los beneficios obtenidos en el juego clásico (payoffs) y los beneficios calculados por lote (payoffs_b) se posicionaron como factores importantes en la reducción de la pérdida de RMSE, indicando que existe una estrategia de aprendizaje híbrido o en cascada altamente efectiva derivada de la interacción cruzada entre los fenotipos de replicación lenta (v) y rápida (V).

Para capturar las no linealidades complejas de la replicación virológica, el modelo Lasso alcanzó un $R^2 = 0.904$ y un RMSE de 0.3458 en prueba. La jerarquía de importancia reveló una estructura acoplada con memoria donde también el beneficio más cercano (nearest_payoff) concentró el mayor peso explicativo sobre el desenlace virológico. Algorítmicamente, nearest_payoff realiza una proyección por distancia mínima entre el cambio cinético longitudinal de la carga viral ($\Delta \log_{10} \text{VL}$, obtenido de vlogs3_diff) y el espacio de pagos teóricos derivado de la interacción de operadores cuánticos (comportamiento de compuertas con la función phen_hiv de qvirus). Esto confirma que mapear la dinámica cinética empírica hacia el estado de estrategia cuántica de menor diferencia matemática modela con alta precisión el paisaje de aptitud evolutiva y evasión del patógeno.

Los beneficios clásicos esperados por lotes (payoffs_b), ocuparon el segundo lugar en la reducción del RMSE, indicando que la modelación en cascada y por bloques captura de manera más eficiente la varianza poblacional de la replicación viral y la presión de mutación masiva inherente a la alta tasa evolutiva del VIH.

Además, una inercia temporal longitudinal (vlogs_diff_mean y cds_diff_mean), marcada por las medias longitudinales históricas del cambio logarítmico en carga viral y recuento de CD4 aportaron la memoria necesaria para estabilizar las predicciones.

Ante escenarios de extrema escasez de datos (donde el promedio de datos faltantes por periodo supera el 80 % en ambos marcadores y los métodos tradicionales como MICE o missForest fallan), se establece el siguiente marco de decisión para guiar la conducta médica:




Figura 5.1: Marco de reglas de decisión clínica estructurado según la jerarquía de importancia de variables en los modelos Lasso y Random Forest bajo la transformación **qphen**.

Regla 1: Tipo de Pre-procesamiento según Disponibilidad de Datos

- Escenario con Alta Densidad de Faltantes sin Plataforma Cuántica: Si el expediente clínico presenta lagunas temporales prolongadas y no se cuenta con la canalización **qvirus**, utilizar las diferencias medias estandarizadas (**cds_diff_mean** y **vlogs_diff_mean**). Estas métricas de inercia evitan los sesgos introducidos por la imputación simple de promedios o la sustitución por el límite de detección.
- Escenario Estructurado con **qphen**: Ejecutar la transformación vía teoría de juegos cuánticos. Las variables discretizadas (**nearest_payoff**, **payoffs**, **phen_1**, clústeres) reducen la dimensionalidad sin perder la interdependencia entre CD4 y carga viral.

Regla 2: Riesgo de Deterioro Inmunológico (Competencia de CD4)

Al evaluar la recuperación de linfocitos T CD4 mediante las variables dominantes del modelo penalizado (**nearest_payoff** como realidad empírica y **payoffs** como expectativa teórica a priori), se establece la siguiente matriz de decisión clínica combinada:

- Reconstitución exitosa y estabilidad clínica ($\text{nearest_payoff} \geq 0 \wedge \text{payoffs} \geq 0$). Concordancia entre la realidad empírica y el historial pronóstico favorable. El paciente muestra estabilidad y una respuesta favorable al tratamiento antirretroviral; se sugiere mantener el esquema actual y el monitoreo de rutina.
- Ganancia inesperada o respuesta hiper-resiliente ($\text{nearest_payoff} \geq 0 \wedge \text{payoffs} \ll 0$). Respuesta clínica atípica donde el paciente presenta una recuperación linfocitaria real favorable a pesar de un pronóstico teórico adverso. Se recomienda evaluar factores protectores individuales y adherencia estricta.
- Alerta temprana de descenso oculto o deterioro incipiente ($\text{nearest_payoff} \ll 0 \wedge \text{payoffs} \geq 0$). Señal de alerta crítica. A pesar de una expectativa teórica favorable ($\text{payoffs} \geq 0$), la realidad empírica refleja un descenso linfocitario ($\text{nearest_payoff} \ll 0$). Requiere revisión inmediata del esquema y la búsqueda activa de complicaciones o factores incipientes de falla.
- Deterioro o falla confirmada ($\text{nearest_payoff} \ll 0 \wedge \text{payoffs} \ll 0$). Concordancia de pérdida o estancamiento de CD4 tanto en la realidad empírica como en el historial pronóstico. Se requiere intervención clínica intensiva, reevaluación del tratamiento y la búsqueda activa o evaluación de coinfecciones oportunistas (como tuberculosis activa TB_1).

Regla 3: Resistencia y Respuesta Viroológica (Competencia de Carga Viral)

Al evaluar la supresión viral mediante las variables dominantes del modelo Lasso (nearest_payoff como realidad empírica de supresión/replicación y payoffs_b como expectativa teórica a priori por lotes), se establece la siguiente matriz de decisión clínica combinada:

- Concordancia de replicación activa o falla virológica ($\text{nearest_payoff} \geq 0 \wedge \text{payoffs_b} \geq 0$). Tanto el estado real post-observado como la expectativa teórica coinciden en un régimen de alta carga viral o fracaso virológico. Se recomienda evaluar la adherencia, verificar la presencia de genorresistencia (GR_1) y considerar la optimización del esquema antirretroviral.
- Reboté viral inesperado a pesar de pronóstico favorable ($\text{nearest_payoff} \geq 0 \wedge \text{payoffs_b} \ll 0$). Incremento viral empírico abrupto ($\text{nearest_payoff} \geq 0$) que contradice el pronóstico teórico de control ($\text{payoffs_b} \ll 0$). Constituye una alerta de resistencia emergente o falla atípica que amerita genotipificación inmediata.
- Supresión viral temprana a pesar de expectativa de riesgo ($\text{nearest_payoff} \ll 0 \wedge \text{payoffs_b} \geq 0$). Indicios empíricos de control viral efectivo ($\text{nearest_payoff} \ll 0$) a pesar de una historia clínica o expectativa de alto riesgo ($\text{payoffs_b} \geq 0$). Sugiere una respuesta favorable temprana al ajuste del tratamiento que debe vigilarse de cerca.
- Concordancia de supresión y control viral exitoso ($\text{nearest_payoff} \ll 0 \wedge \text{payoffs_b} \ll 0$). Control viral efectivo confirmado tanto por la realidad empírica como por el historial pronóstico. El régimen ART actual ejerce una presión selectiva óptima; se sugiere mantener el manejo clínico actual.

5.3. Limitaciones

En la práctica clínica habitual, el seguimiento de la infección por VIH se basa en mediciones puntuales y absolutas del recuento de linfocitos T CD4 (células/ μ L) y la carga viral de ARN-VIH (copias/mL). Si bien estos valores absolutos son el estándar para definir la etapa clínica y el éxito virológico, presentan severas limitaciones cuando se analizan en cohortes con alta tasa de datos faltantes (donde más del 80 % de los datos faltan por periodo de seguimiento). Para superar la rigidez del análisis transversal, esta tesis introdujo las variables derivadas de ingeniería de características basadas en teoría de juegos cuánticos:

-cd_diff ($\mathcal{I}_i^{\text{CD4-STD}}$): Promedio de las diferencias estandarizadas consecutivas del conteo de linfocitos T CD4 a lo largo del tiempo.

-vl_diff ($\mathcal{I}_i^{\text{CV-LOG-STD}}$): Promedio de las diferencias consecutivas de la carga viral transformada logarítmicamente y estandarizada.

A pesar de las ventajas metodológicas de cd_diff y vl_diff para capturar la inercia inmunológica y la competencia fenotípica, su traducción a la toma de decisiones clínicas presenta limitaciones fundamentales en comparación con la predicción estándar:

1. Pérdida de la Magnitud Absoluta de Riesgo (Efecto Inmune Basal)

- Problema: Un paciente con una inmunosupresión severa pero numéricamente estable (ej. CD4 constante en 50 células/ μ L) puede registrar un cd_diff ≈ 0 . De manera idéntica, un paciente virológicamente controlado con un conteo alto y estable (ej. CD4 en 700 células/ μ L) registrará un cd_diff ≈ 0 .
- Riesgo Clínico: Si un modelo predictivo clásico o cuántico se alimenta exclusivamente de la tasa de cambio (cd_diff), pierde la capacidad de distinguir entre la estabilidad en zona de peligro (riesgo inminente de coinfección por tuberculosis TB_1) y la estabilidad en zona de seguridad inmunológica.

2. Sensibilidad a la Irregularidad y Espaciamiento Temporal

- Problema: El cálculo de diferencias consecutivas ($\Delta C_{i,j}$ y $\Delta L'_{i,j}$) asume o promedia cambios entre visitas. Sin embargo, en el entorno de recursos limitados del IMSS Guerrero, los intervalos entre consultas varían ampliamente (de 3 meses hasta más de un año por interrupciones de seguimiento).
- Riesgo Clínico: Un cambio abrupto de carga viral en un intervalo corto (30 días) produce el mismo Δ aritmético que un cambio gradual ocurrido a lo largo de 18 meses, distorsionando la estimación de la velocidad de falla virológica o aparición de genoresistencia (GR_1).

3. Efecto de Censura por Límite de Detección en Carga Viral

- Problema: Las cargas virales por debajo del límite de detección del ensayo (≤ 20 o ≤ 40 copias/mL) son asignadas como valores fijos o cero antes de la transformación logarítmica.
- Riesgo Clínico: Las oscilaciones menores en el umbral analítico generan variaciones absolutas pequeñas que, al estandarizarse en vl_diff, pueden simular “falsas dinámicas de competencia”.

4. Tamaño Muestral Reducido y Homogeneidad de la Cohorte

- **Tamaño y Depuración Muestral:** La cohorte inicial de $n = 213$ registros se redujo a $n = 176$ pacientes debido al criterio de exclusión de registros con una sola medición (necesaria para derivar dinámicas temporales). Aunque el análisis de sensibilidad demostró la ausencia de sesgo en las distribuciones basales de CD4 y carga viral ($p > 0.05$), la muestra final sigue siendo pequeña para tareas de regresión o modelación clásica compleja.
- **Homogeneidad Geográfica e Institucional:** La totalidad de los datos proviene de una única sede: el Hospital General Regional No. 1 “Vicente Guerrero” del IMSS en Acapulco, Guerrero.

5. Generalización a Otras Poblaciones de PLWH. Los resultados de este estudio no pueden extrapolarse directamente a otras poblaciones de PLWH debido a:

- **Condiciones Socioeconómicas y de Infraestructura Local:** La población del estado de Guerrero enfrenta determinantes estructurales específicos (alta dispersión geográfica, interrupciones en el suministro de fármacos y menor acceso continuo a citometría de flujo y carga viral).
- **Regímenes de ART y Cepas Virales:** Los patrones de falla virológica y respuesta inmunológica están condicionados por los esquemas de ART prescritos en el IMSS entre 2018 y 2024, los cuales pueden diferir de las pautas de tratamiento utilizadas en otros países o en el sector privado.

5.4. Conclusión

El análisis de modelación clásica aplicado sobre la ingeniería de características de juegos cuánticos permite consolidar la representación de competencia. La predicción continua de la velocidad inmunoviroológica mediante modelos clásicos integrados a qphen supera sistemáticamente a los enfoques lineales autorregresivos y de conjuntos convencionales reportados en el estado del arte. Se alcanzaron coeficientes de determinación de $R^2 = 0.8677$ ($RMSE = 0.1914$) para la competencia de CD4 mediante regresión penalizada, y de $R^2 = 0.904$ ($RMSE = 0.3458$) para la competencia de carga viral mediante Lasso.

Se logra una resolución de la inestabilidad por faltantes frente al escenario crítico del IMSS Guerrero (con más del 80 % de datos faltantes por periodo). La combinación de estandarización longitudinal y mapeo al espacio discreto de beneficios cuánticos proporciona una matriz de características robusta que previene la degradación del modelo, superando los techos históricos de $R^2 \approx 0.65$ reportados para la misma cohorte.

Se valida la hipótesis en la modelación clásica y se confirma la hipótesis de este trabajo: la estructuración de las dinámicas de CD4 y carga viral como un juego cuántico de competencia fenotípica proporciona una alternativa viable ante el esquema severo de datos faltantes en un contexto de recursos y datos limitados.

Apéndice A

Apéndice: Ingeniería de Características

A.1. Qvirus

```
library(qvirus)
```

A.2. Base de Datos y Cohorte de Estudio

```
cd_data <- cd_3[, -1]  
vl_data <- vl_3[, -1]
```

A.3. Interacciones de Competencia

```
cd_result <- cds_diff(cd_data)  
vl_result <- vlogs_diff(vl_data)
```

A.4. Clasificación de Interacciones

```
class_obj <-  
InteractionClassification(cds_diff(cd_data), vlogs_diff(vl_data),  
k=4, seed=123)
```

A.5. Estimación de Parámetros

```
library(viralmodels)  
predictions_df <-  
viraltab(tibble(cd_result, vl_result), 123, "vlogs3_diff", c(), 10, 7, 2,  
2, rank_output = FALSE) |>
```

```
viralpreds(123, tibble(cd_result,vl_result), prediction_type = "full")
predictions_df2 <-
viralpreds(tibble(cd_result,vl_result), 123, "vlogs3_diff", c(), 10, 2,
3, 3, rank_output = FALSE) |>
viralpreds(123, tibble(cd_result,vl_result), prediction_type = "batch")
```

A.6. Simulación del Algoritmo del Beneficio más Cercano

```
opt_pars <-
summary(estimate_payoffs(class_obj, predictions_df))$payoff_mean |>
sort()
alpha <- opt_pars[3]
beta <- opt_pars[1]
gamma <- opt_pars[4]
theta <- opt_pars[2]

opt_pars2 <-
summary(estimate_payoffs(class_obj, predictions_df2))$payoff_mean |>
sort()
alpha2 <- opt_pars2[3]
beta2 <- opt_pars2[1]
gamma2 <- opt_pars2[4]
theta2 <- opt_pars2[2]

gates <- list(Tg = Tgate()$data,
X = PauliX()$data,
I = Identity()$data,
H = Hadamard()$data,
Z = PauliZ()$data,
S = Sgate()$data,
Y = PauliY()$data,
Z = PauliZ()$data)

plist <-
payoffs_list(
gates, alpha, beta, gamma, theta, alpha2, beta2, gamma2, theta2
)

class_obj |>
dplyr::bind_cols(id = cd_3$ID) |>
dplyr::relocate(id) |> dplyr::rowwise() |>
dplyr::mutate(
nearest = list(nearest_payoff(vlogs3_diff, plist))
) |>
dplyr::mutate(
```

```
nearest_payoff = nearest$value, payoff_name = nearest$name) |>  
dplyr::select(-nearest)
```


Apéndice B

Apéndice: Modelación Clásica de Regresión

B.1. Regresión sobre el conjunto de entrenamiento

```
library(tidyverse)
library(tidymodels)
library(qvirus)

# INTERCAMBIAR VARIABLE OBJETIVO: vl_diff
# PARA PREDECIR COMPETENCIA DE CARGA VIRAL

# 1. CARGA DE DATOS
traindata_final <- qphen[, -1] |>
  as.data.frame()

# 2. RECIPE (pre-procesamiento)
modelo_recipe <- recipe(cd_diff ~ .,
  data = traindata_final) |>
  step_zv(all_predictors()) |>
  step_impute_mean(all_predictors()) |>
  step_normalize(all_predictors())

# 3. VALIDACIÓN CRUZADA (5-fold estratificada)
set.seed(1501)
cv_folds <- vfold_cv(traindata_final, v = 5, strata = cd_diff)

# 4. ESPECIFICACIONES DE MODELOS
knn_spec <- nearest_neighbor(neighbors = tune()) |>
  set_engine("kkn") |>
  set_mode("regression")

rf_spec <- rand_forest(mtry = tune()) |>
  set_engine("ranger", num.threads = parallel::detectCores()) |>
```

```

  set_mode("regression")

lm_spec <- linear_reg(penalty = tune(), mixture = 1) |>
  set_engine("glmnet") |>
  set_mode("regression")

# 5. WORKFLOWS
knn_wflow <- workflow() |>
  add_recipe(modelo_recipe) |>
  add_model(knn_spec)

rf_wflow <- workflow() |>
  add_recipe(modelo_recipe) |>
  add_model(rf_spec)

lm_wflow <- workflow() |>
  add_recipe(modelo_recipe) |>
  add_model(lm_spec)

# 6. TUNING GRIDS
knn_grid <- tibble(neighbors = c(3, 5, 7, 9, 11, 15))
rf_grid <- tibble(mtry = c(1, 2))
lm_grid <- tibble(penalty = c(0.001, 0.01, 0.1, 1))

# 7. ENTRENAR MODELOS (tuning)
knn_tune <- tune_grid(knn_wflow, resamples = cv_folds, grid = knn_grid,
  control = control_grid(verbose = FALSE))

rf_tune <- tune_grid(rf_wflow, resamples = cv_folds, grid = rf_grid,
  control = control_grid(verbose = FALSE))

lm_tune <- tune_grid(lm_wflow, resamples = cv_folds, grid = lm_grid,
  control = control_grid(verbose = FALSE))

# 8. EXTRAER RESULTADOS
knn_metrics <- collect_metrics(knn_tune) |>
  filter(.metric == "rmse") |>
  mutate(model = "KNN") |>
  arrange(mean)

rf_metrics <- collect_metrics(rf_tune) |>
  filter(.metric == "rmse") |>
  mutate(model = "Random Forest") |>
  arrange(mean)

lm_metrics <- collect_metrics(lm_tune) |>
  filter(.metric == "rmse") |>
  mutate(model = "Lasso") |>

```

```

  arrange(mean)

# 9. SELECCIONAR MEJOR MODELO GLOBALMENTE
all_metrics <- bind_rows(knn_metrics, rf_metrics, lm_metrics)

mejor_global <- all_metrics |>
  arrange(mean) |>
  slice(1)

# Determinar workflow y parámetros
if (mejor_global$model == "KNN") {
  best_params <- select_best(knn_tune, metric = "rmse")
  final_wflow <- knn_wflow
  modelo_nombre <- "K-Nearest Neighbors (KNN)"
} else if (mejor_global$model == "Random Forest") {
  best_params <- select_best(rf_tune, metric = "rmse")
  final_wflow <- rf_wflow
  modelo_nombre <- "Random Forest"
} else {
  best_params <- select_best(lm_tune, metric = "rmse")
  final_wflow <- lm_wflow
  modelo_nombre <- "Regresión Lasso"
}

# 10. ENTRENAR MODELO FINAL
final_model <- finalize_workflow(final_wflow, best_params) |>
  fit(traindata_final)

# 11. PREDICCIONES Y EVALUACIÓN
predictions <- augment(final_model, traindata_final)
metrics_final <- predictions |>
  metrics(truth = cd_diff, estimate = .pred)

# 12. VISUALIZACIONES
# Gráfica 1: Comparación de modelos
p_comparacion <- ggplot(all_metrics, aes(x = reorder(model, mean),
                                           y = mean)) +
  geom_boxplot(aes(fill = model), alpha = 0.7, show.legend = FALSE) +
  geom_point(aes(color = model), size = 3, alpha = 0.6,
             show.legend = FALSE) +
  labs(title = "Comparación RMSE entre Modelos",
       subtitle = "Validación cruzada 5-fold",
       x = "Modelo", y = "RMSE") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))

# Gráfica 2: Predicciones vs Realidad
rmse_val <- metrics_final |>

```

```

  filter(.metric == "rmse") |>
  pull(.estimate) |>
  round(4)
rsq_val <- metrics_final |>
  filter(.metric == "rsq") |>
  pull(.estimate) |>
  round(4)
mae_val <- metrics_final |>
  filter(.metric == "mae") |>
  pull(.estimate) |>
  round(4)

p_predicciones <- ggplot(predictions, aes(x = cd_diff, y = .pred)) +
  geom_point(alpha = 0.6, size = 2, color = "steelblue") +
  geom_abline(intercept = 0, slope = 1, linetype = "dashed",
              color = "red", linewidth = 1) +
  labs(title = "Predicciones vs Valores Reales",
       subtitle = paste0("RMSE = ", rmse_val, " | R2 = ", rsq_val,
                        " | MAE = ", mae_val),
       x = "Valor Real (cd_diff)", y = "Predicción") +
  theme_minimal() +
  coord_fixed(ratio = 1)

# Gráfica 3: Residuales
p_residuales <- ggplot(predictions, aes(x = .pred, y = cd_diff - .pred)) +
  geom_point(alpha = 0.6, size = 2, color = "coral") +
  geom_hline(yintercept = 0, linetype = "dashed", color = "red",
             linewidth = 1) +
  geom_smooth(method = "loess", se = TRUE, fill = "lightblue",
             alpha = 0.3, color = "blue") +
  labs(title = "Análisis de Residuales",
       x = "Predicción", y = "Residual (Observado - Predicho)") +
  theme_minimal()

# Gráfica 4: Distribución de residuales
p_residuales_dist <- ggplot(predictions, aes(x = cd_diff - .pred)) +
  geom_histogram(bins = 20, fill = "steelblue", alpha = 0.7,
                color = "white") +
  geom_vline(xintercept = 0, linetype = "dashed", color = "red",
             linewidth = 1) +
  labs(title = "Distribución de Residuales",
       x = "Residual", y = "Frecuencia") +
  theme_minimal()

# Combinar gráficos
(p_comparacion | p_predicciones) / (p_residuales | p_residuales_dist)

```

B.2. Regresión sobre el conjunto de prueba

```
# 1. SPLIT TRAIN TEST (80-20, estratificado)
set.seed(1501)
data_split <- initial_split(traindata_final, prop = 0.80,
                             strata = cd_diff)
train_data <- training(data_split)
test_data <- testing(data_split)

# 2. RECIPE (pre-procesamiento)
# ---Equivalente a rutina en conjunto de entrenamiento---

# 3. VALIDACIÓN CRUZADA (5-fold estratificada)
# ---Equivalente a rutina en conjunto de entrenamiento---

# 4. ESPECIFICACIONES DE MODELOS
# ---Equivalente a rutina en conjunto de entrenamiento---

# 5. WORKFLOWS
# ---Equivalente a rutina en conjunto de entrenamiento---

# 6. TUNING GRIDS
# ---Equivalente a rutina en conjunto de entrenamiento---

# 7. ENTRENAR MODELOS (tuning)
# ---Equivalente a rutina en conjunto de entrenamiento---

# 8. EXTRAER RESULTADOS EN ENTRENAMIENTO
knn_metrics_train <- collect_metrics(knn_tune) |>
  filter(.metric == "rmse") |>
  mutate(model = "KNN", stage = "Entrenamiento") |>
  arrange(mean)

rf_metrics_train <- collect_metrics(rf_tune) |>
  filter(.metric == "rmse") |>
  mutate(model = "Random Forest", stage = "Entrenamiento") |>
  arrange(mean)

lm_metrics_train <- collect_metrics(lm_tune) |>
  filter(.metric == "rmse") |>
  mutate(model = "Lasso", stage = "Entrenamiento") |>
  arrange(mean)

# 9. SELECCIONAR MEJORES HIPERPARÁMETROS
best_knn_params <- select_best(knn_tune, metric = "rmse")
best_rf_params <- select_best(rf_tune, metric = "rmse")
best_lm_params <- select_best(lm_tune, metric = "rmse")
```

```

final_knn <- finalize_workflow(knn_wflow, best_knn_params) |>
  fit(train_data)

final_rf <- finalize_workflow(rf_wflow, best_rf_params) |>
  fit(train_data)

final_lm <- finalize_workflow(lm_wflow, best_lm_params) |>
  fit(train_data)

# 10. PREDICCIONES EN CONJUNTO DE PRUEBA
pred_knn_test <- augment(final_knn, test_data)
pred_rf_test <- augment(final_rf, test_data)
pred_lm_test <- augment(final_lm, test_data)

# 11. EVALUAR EN PRUEBA
metrics_knn_test <- pred_knn_test |>
  metrics(truth = cd_diff, estimate = .pred) |>
  mutate(model = "KNN", stage = "Prueba")

metrics_rf_test <- pred_rf_test |>
  metrics(truth = cd_diff, estimate = .pred) |>
  mutate(model = "Random Forest", stage = "Prueba")

metrics_lm_test <- pred_lm_test |>
  metrics(truth = cd_diff, estimate = .pred) |>
  mutate(model = "Lasso", stage = "Prueba")

# 12. RESUMIR MEJOR MODELO
all_test_metrics <- bind_rows(metrics_knn_test, metrics_rf_test,
                              metrics_lm_test)
mejor_modelo_test <- all_test_metrics |>
  filter(.metric == "rmse") |>
  arrange(.estimate) |>
  slice(1)

# Obtener todas las métricas del mejor modelo
if (mejor_modelo_test$model == "KNN") {
  mejor_modelo_completo <- metrics_knn_test
  mejor_pred_test <- pred_knn_test
  modelo_nombre <- "K-Nearest Neighbors (KNN)"
} else if (mejor_modelo_test$model == "Random Forest") {
  mejor_modelo_completo <- metrics_rf_test
  mejor_pred_test <- pred_rf_test
  modelo_nombre <- "Random Forest"
} else {
  mejor_modelo_completo <- metrics_lm_test
  mejor_pred_test <- pred_lm_test
  modelo_nombre <- "Regresión Lasso"
}

```

```

}

# 13. VISUALIZACIONES
# Gráfico 1: Comparación de RMSE en PRUEBA (CORREGIDO)
rmse_test_values <- bind_rows(
  metrics_knn_test |>
    filter(.metric == "rmse") |>
    mutate(model = "KNN"),
  metrics_rf_test |>
    filter(.metric == "rmse") |>
    mutate(model = "Random Forest"),
  metrics_lm_test |>
    filter(.metric == "rmse") |>
    mutate(model = "Lasso")
)

p_rmse_test <- ggplot(rmse_test_values, aes(x = reorder(model, .estimate),
                                             y = .estimate, fill = model)) +
  geom_col(alpha = 0.7, show.legend = FALSE) +
  geom_text(aes(label = round(.estimate, 4)), vjust = -0.5, size = 4) +
  labs(title = "RMSE en Conjunto de Prueba",
       x = "Modelo", y = "RMSE",
       subtitle = "Comparación final de desempeño") +
  theme_minimal() +
  ylim(0, max(rmse_test_values$.estimate) * 1.15)

# Gráfico 2: Predicciones vs Realidad en PRUEBA
rmse_test <- mejor_modelo_completo |>
  filter(.metric == "rmse") |>
  pull(.estimate) |>
  round(4)
rsq_test <- mejor_modelo_completo |>
  filter(.metric == "rsq") |>
  pull(.estimate) |>
  round(4)
mae_test <- mejor_modelo_completo |>
  filter(.metric == "mae") |>
  pull(.estimate) |>
  round(4)

p_pred_test <- ggplot(mejor_pred_test, aes(x = cd_diff, y = .pred)) +
  geom_point(alpha = 0.7, size = 2.5, color = "steelblue") +
  geom_abline(intercept = 0, slope = 1, linetype = "dashed",
             color = "red", linewidth = 1) +
  labs(title = paste("Predicciones en Prueba -", modelo_nombre),
       subtitle = paste0("RMSE = ", rmse_test, " | R2 = ",
                        rsq_test, " | MAE = ", mae_test),
       x = "Valor Real (cd_diff)", y = "Predicción") +

```

```

theme_minimal() +
coord_fixed(ratio = 1)

# Gráfico 3: Residuales en PRUEBA
p_residuales_test <- ggplot(mejor_pred_test, aes(x = .pred,
                                                  y = cd_diff - .pred)) +
  geom_point(alpha = 0.7, size = 2.5, color = "coral") +
  geom_hline(yintercept = 0, linetype = "dashed", color = "red",
             linewidth = 1) +
  geom_smooth(method = "loess", se = TRUE, fill = "lightblue",
             alpha = 0.3, color = "blue") +
  labs(title = "Análisis de Residuales",
       subtitle = "Conjunto de Prueba",
       x = "Predicción", y = "Residual") +
  theme_minimal()

# Gráfico 4: Distribución de residuales
p_dist_residuales_test <- ggplot(mejor_pred_test,
                                aes(x = cd_diff - .pred)) +
  geom_histogram(bins = 12, fill = "steelblue", alpha = 0.7,
                color = "white") +
  geom_vline(xintercept = 0, linetype = "dashed", color = "red",
            linewidth = 1) +
  geom_vline(xintercept = mean(mejor_pred_test$cd_diff -
                              mejor_pred_test$.pred),
            linetype = "dotted", color = "orange", linewidth = 1) +
  labs(title = "Distribución de Residuales",
       x = "Residual", y = "Frecuencia",
       subtitle = "Línea roja = 0 | Línea naranja = media") +
  theme_minimal()

# Gráfico 5: Comparación Train vs Test
comparacion_train_test <- tibble(
  Modelo = c("KNN", "RF", "Lasso"),
  Train_RMSE = c(
    knn_metrics_train$mean[1],
    rf_metrics_train$mean[1],
    lm_metrics_train$mean[1]
  ),
  Test_RMSE = c(
    metrics_knn_test |> filter(.metric == "rmse") |> pull(.estimate),
    metrics_rf_test |> filter(.metric == "rmse") |> pull(.estimate),
    metrics_lm_test |> filter(.metric == "rmse") |> pull(.estimate)
  )
) |>
pivot_longer(cols = -Modelo, names_to = "Stage", values_to = "RMSE") |>
mutate(Stage = factor(Stage, levels = c("Train_RMSE", "Test_RMSE")))

```



```

p_train_vs_test <- ggplot(comparacion_train_test, aes(x = Modelo,
                                                    y = RMSE, fill = Stage)) +
  geom_col(position = "dodge", alpha = 0.7) +
  geom_text(aes(label = round(RMSE, 4)), vjust = -0.5,
            position = position_dodge(width = 0.9), size = 3.5) +
  labs(title = "RMSE: Entrenamiento vs Prueba",
       x = "Modelo", y = "RMSE",
       subtitle = "Evaluación de overfitting",
       fill = "Conjunto") +
  scale_fill_manual(values = c("Train_RMSE" = "steelblue",
                               "Test_RMSE" = "coral")) +
  theme_minimal()

# Gráfico 6: Q-Q plot de residuales
p_qq_test <- ggplot(mejor_pred_test, aes(sample = cd_diff - .pred)) +
  stat_qq(alpha = 0.6, size = 2.5, color = "steelblue") +
  stat_qq_line(color = "red", linetype = "dashed", linewidth = 1) +
  labs(title = "Q-Q Plot de Residuales",
       subtitle = "Validar normalidad de residuales",
       x = "Cuantiles Teóricos", y = "Cuantiles Muestrales") +
  theme_minimal()

# Combinar gráficos
(p_rmse_test | p_pred_test) /
(p_residuales_test | p_dist_residuales_test) /
(p_train_vs_test | p_qq_test)

# 14. TABLA COMPARATIVA FINAL
tabla_comparativa <- tibble(
  Modelo = c("KNN", "Random Forest", "Lasso"),
  Train_RMSE = c(
    round(knn_metrics_train$mean[1], 4),
    round(rf_metrics_train$mean[1], 4),
    round(lm_metrics_train$mean[1], 4)
  ),
  Test_RMSE = c(
    round(metrics_knn_test |>
      filter(.metric == "rmse") |>
      pull(.estimate), 4),
    round(metrics_rf_test |>
      filter(.metric == "rmse") |>
      pull(.estimate), 4),
    round(metrics_lm_test |>
      filter(.metric == "rmse") |>
      pull(.estimate), 4)
  ),
  Diferencia = NA,
  Overfitting = "NO"

```

```
)

tabla_comparativa$Diferencia <- abs(tabla_comparativa$Train_RMSE -
                                     tabla_comparativa$Test_RMSE)
tabla_comparativa$Overfitting <- ifelse(tabla_comparativa$Diferencia >
                                         0.05, "SÍ (leve)", "NO")
```

B.3. Explicador del Modelo de Regresión Lasso

```
library(viralx)
library(qvirus)
set.seed(123)
hiv_data <- qphen[,-1]
lasso_hyperparameters <- list(penalty = 0.01)
vip_featured <- c("cd_diff")
vip_train <- hiv_data |>
  dplyr::select(-all_of(vip_featured))
v_train <- hiv_data |>
  dplyr::select(all_of(vip_featured))
glob_lasso_vis(
  vip_featured = vip_featured,
  hiv_data = hiv_data,
  lasso_hyperparameters = lasso_hyperparameters,
  vip_train = vip_train,
  v_train = v_train
)
```

B.4. Dominio de Aplicabilidad para la Competencia de CD4

```
library(viraldomain)
library(knitr)
library(tidymodels)
library(recipes)
library(dplyr)
library(ggplot2)
library(patchwork)
library(qvirus)
traindata <- qphen[,-1]
traindata_final <- traindata |>
  as.data.frame()

set.seed(1501)
data_split <- initial_split(traindata_final,prop=0.80,strata=cd_diff)
train_data <- training(data_split)
```

```
test_data <- testing(data_split)

set.seed(123)
featured <- "cd_diff"
lasso_hyperparameters <- list(penalty = 0.01)
threshold_value <- 0.99
# Llamada a la función
lasso_domain_score(featured, train_data, lasso_hyperparameters, test_data,
                    threshold_value) |>
  head(6) |>
  kable()
```

B.5. Aprendizaje por Conjuntos

```
library(tidymodels)
library(recipes)
library(stacks)
library(dplyr)
library(qvirus)

traindata <- qphen[,-1]
traindata_final <- traindata |> as.data.frame()

set.seed(1501)
data_split <- initial_split(traindata_final,prop=0.80,strata=cd_diff)
train_data <- training(data_split)
test_data <- testing(data_split)

modelo_recipe <- recipe(cd_diff ~ ., data = train_data) |>
  step_zv(all_predictors()) |>
  step_impute_mean(all_predictors()) |>
  step_normalize(all_predictors())

set.seed(1501)
cv_folds <- vfold_cv(train_data, v = 5, strata = cd_diff)

knn_spec <- nearest_neighbor(neighbors = tune()) |>
  set_engine("kknn") |>
  set_mode("regression")

rf_spec <- rand_forest(mtry = tune(), trees = 200) |>
  set_engine("ranger", num.threads = parallel::detectCores()) |>
  set_mode("regression")

glmnet_spec <- linear_reg(penalty = tune(), mixture = tune()) |>
  set_engine("glmnet") |>
```

```

  set_mode("regression")

knn_wflow <- workflow() |>
  add_recipe(modelo_recipe) |>
  add_model(knn_spec)
rf_wflow <- workflow() |>
  add_recipe(modelo_recipe) |>
  add_model(rf_spec)
glmnet_wflow <- workflow() |>
  add_recipe(modelo_recipe) |>
  add_model(glmnet_spec)

knn_grid <- tibble(neighbors = c(3, 5, 7, 9))
rf_grid <- tibble(mtry = c(2, 4, 6))
glmnet_grid <- expand_grid(penalty = c(0.0001, 0.001, 0.01, 0.1, 1),
  mixture = c(0, 0.5, 1))

set.seed(1501)
knn_tune <- tune_grid(knn_wflow, resamples = cv_folds, grid = knn_grid,
  control = control_stack_grid())

set.seed(1501)
rf_tune <- tune_grid(rf_wflow, resamples = cv_folds, grid = rf_grid,
  control = control_stack_grid())

set.seed(1501)
glmnet_tune <- tune_grid(glmnet_wflow, resamples = cv_folds,
  grid = glmnet_grid,
  control = control_stack_grid())

stacked_models <- stacks() |>
  add_candidates(knn_tune) |>
  add_candidates(rf_tune) |>
  add_candidates(glmnet_tune)

stashed_blend <- blend_predictions(stacked_models)

stacked_final <- fit_members(stashed_blend)

pred_stack <- predict(stacked_final, test_data) |>
  bind_cols(test_data |> select(cd_diff))

metrics_stack <- pred_stack |>
  metrics(truth = cd_diff, estimate = .pred)

```

B.6. Explicador del Modelo de Bosque Aleatorio

```
library(viralx)
library(qvirus)
set.seed(123)
hiv_data <- qphen[, -1]
vip_featured <- c("vl_diff")
vip_train <- hiv_data |>
  dplyr::select(-all_of(vip_featured))
v_train <- hiv_data |>
  dplyr::select(all_of(vip_featured))
rf_hyperparameters <- list(mtry = 2)
glob_rf_vis(vip_featured, hiv_data, rf_hyperparameters,
            vip_train, v_train)
```

B.7. Dominio de Aplicabilidad para la Competencia de Carga Viral

```
library(viraldomain)
library(knitr)
library(tidymodels)
library(recipes)
library(dplyr)
library(ggplot2)
library(patchwork)
library(qvirus)
traindata <- qphen[, -1]
traindata_final <- traindata |>
  as.data.frame()

set.seed(1501)
data_split <- initial_split(traindata_final, prop=0.80, strata=cd_diff)
train_data <- training(data_split)
test_data <- testing(data_split)

set.seed(123)
featured <- "vl_diff"
rf_hyperparameters <- list(mtry = 2, trees = 500L,
                          min_n = 5)
threshold_value <- 0.99
# Llamada a la función
rf_domain_score(featured, train_data, rf_hyperparameters, test_data,
                threshold_value) |>
  head(6) |>
  kable()
```

Bibliografía

ACUÑA GONZÁLEZ, JUAN PABLO (2025). *qvirus: Quantum Computing for Analyzing CD4 Lymphocytes and Antiretroviral Therapy*.

<https://doi.org/10.32614/CRAN.package.qvirus>.

<https://CRAN.R-project.org/package=qvirus>. R package version 0.0.4.

ALEKSANDROWICZ, GADI; ALEXANDER, THOMAS; BARKOUTSOS, PANAGIOTIS; BELLO, LUCIANO; BEN-HAIM, Yael; BUCHER, DAVID; CABRERA-HERNÁNDEZ, FRANCISCO JOSE; CARBALLO-FRANQUIS, JORGE; CHEN, ADRIAN; CHEN, CHUN-FU; CHOW, JERRY M; CÓRCOLES-GONZALES, ANTONIO D; CROSS, ABIGAIL J; CROSS, ANDREW; CRUZ-BENITO, JUAN; CULVER, CHRIS; DE LA PUENTE GONZÁLEZ, SALVADOR; DE LA TORRE, ENRIQUE; DING, DELTON; DUMITRESCU, EUGENE; DURAN, IVAN; EENDEBAK, PIETER; EVERITT, MARK; SERTAGE, ISMAEL FARO; FRISCH, ALBERT; FUHRER, ANDREAS; GAMBETTA, JAY; GAGO, BORJA GODOY; GOMEZ-MOSQUERA, JUAN; GREENBERG, DONNY; HAMAMURA, IKKO; HAVLICEK, VOJTECH; HELLMERS, JOE; HEROK, ŁUKASZ; HORII, HIROSHI; HU, SHAOHAN; IMAMICHI, TAKASHI; ITOKO, TOSHINARI; JAVADI-ABHARI, ALI; KANAZAWA, NAOKI; KARAZEEV, ANTON; KRSULICH, KEVIN; LIU, PENG; LUH, YANG; MAENG, YUNHO; MARQUES, MANOEL; MARTÍN-FERNÁNDEZ, FRANCISCO JOSE; MCCLURE, DOUGLAS T; MCKAY, DAVID; MEESALA, SRUJAN; MEZZACAPO, ANTONIO; MOLL, NIKOLAJ; RODRÍGUEZ, DIEGO MOREDA; NANNICINI, GIACOMO; NATION, PAUL; OLLITRAULT, PAULINE; O'RIORDAN, LEE JAMES; PAIK, HANHEE; PÉREZ, JESÚS; PHAN, ANNA; PISTOIA, MARCO; PRUTYANOV, VIKTOR; REUTER, MAX; RICE, JULIA; DAVILA, ABDÓN RODRÍGUEZ; RUDY, RAYMOND HARRY PUTRA; RYU, MINGI; SATHAYE, NINAD; SCHNABEL, CHRIS; SCHOUTE, EDDIE; SETIA, KANAV; SHI, YUNONG; SILVA, ADENILTON; SIRAICHI, YUKIO; SIVARAJAH, SEYON; SMOLIN, JOHN A; SOEKEN, MATHIAS; TAKAHASHI, HITOMI; TAVERNELLI, IVANO; TAYLOR, CHARLES; TAYLOUR, PETE; TRABING, KENSO; TREINISH, MATTHEW; TURNER, WES; VOGT-LEE, DESIREE; VUILLOT, CHRISTOPHE; WILDSTROM, JONATHAN A; WILSON, JESSICA; WINSTON, ERICK; WOOD, CHRISTOPHER; WOOD, STEPHEN; WÖRNER, STEFAN; AKHALWAYA, ISMAIL YUNUS y ZOUFAL, CHRISTA (2019). «Qiskit: An Open-source Framework for Quantum Computing». *Zenodo*.

<https://doi.org/10.5281/zenodo.2562110>.

ALLAIRE, JJ; XIE, YIHUI; DERVIEUX, CHRISTOPHE; MCPHERSON, JONATHAN; LURASCHI, JAVIER; USHEY, KEVIN; ATKINS, ARON; WICKHAM, HADLEY; CHENG, JOE; CHANG, WINSTON y IANNONE, RICHARD (2025). *rmarkdown: Dynamic Documents for R*.

<https://github.com/rstudio/rmarkdown>. R package version 2.30.

- AMAZON WEB SERVICES (2024). «Amazon Braket: Explore and Experiment with Quantum Computing». Online.
<https://aws.amazon.com/braket/>. Accessed: 2024-03-29.
- ANAYA, A y DELGADO, F (2022). «Simulating molecules using the VQE algorithm on Qiskit». <https://doi.org/https://doi.org/10.48550/arXiv.2201.04216>.
- BERGHOLM, VILLE; IZAAC, JOSH; SCHULD, MARIA; GOGOLIN, CHRISTIAN; BLANK, CARSTEN; MCKIERNAN, KERI y KILLORAN, NATHAN (2018). «PennyLane: Automatic differentiation of hybrid quantum-classical computations». *arXiv preprint*.
<https://arxiv.org/abs/1811.04968v4>. arXiv:1811.04968v4 [quant-ph].
- BRUMMEL, SEAN S.; VAN DYKE, RUSSELL B.; PATEL, KUNJAL; PURSWANI, MURLI; SEAGE, GEORGE R.; YAO, TZY-JYUN; HAZRA, ROHAN; KARALIUS, BRAD y WILLIAMS, PAIGE L. (2022). «Analyzing Longitudinally Collected Viral Load Measurements in Youth With Perinatally Acquired HIV Infection: Problems and Possible Remedies». *American Journal of Epidemiology*, 191(10), pp. 1820–1830.
<https://doi.org/10.1093/aje/kwac125>.
- CASARES, PAM; CAMPOS, R y MARTIN-DELGADO, MA (2022). «QFold: Quantum walks and deep learning to solve protein folding». *Quantum Sci. Technol.*, 7(2), p. 025013.
<https://doi.org/0.1088/2058-9565/ac4f2f>.
- DONG, WEINAN; FONG, DANIEL YEE TAK; YOON, JIN-SUN; WAN, ERIC YUK FAI; BEDFORD, LAURA ELIZABETH; TANG, ERIC HO MAN y LAM, CINDY LO KUEN (2021). «Generative adversarial networks for imputing missing data for big data clinical research». *BMC Medical Research Methodology*, 21, p. 78.
<https://doi.org/10.1186/s12874-021-01272-3>.
- FACULTAD DE MATEMÁTICAS (UNIV. SEVILLA) (s.f.).
<https://www.matematicas.us.es>.
- GANESH, TINNIAM V (2016). *QCSimulator: A 5-Qubit Quantum Computing Simulator*.
<https://doi.org/10.32614/CRAN.package.QCSimulator>.
<https://CRAN.R-project.org/package=QCSimulator>. R package version 0.0.1.
- GHOSH, INDRANIL (2020). *QGameTheory: Quantum Game Theory Simulator*.
<https://CRAN.R-project.org/package=QGameTheory>. R package version 0.1.2.
- GOOGLE QUANTUM AI (2025). «Google Quantum AI». Online.
<https://quantumai.google/>. Accessed: 2025-12-12.
- HAVLÍČEK, VOJTĚCH; CÓRCOLES, ANTONIO D; TEMME, KRISTAN; HARROW, ARAM W; KANDALA, ABHINAV; CHOW, JERRY M y GAMBETTA, JAY M (2019). «Supervised learning with quantum-enhanced feature spaces». *Nature*, 567(7747), pp. 209–212.

RESUMEN: Machine learning and quantum computing are two technologies that each have the potential to alter how computation is performed to address previously untenable problems. Kernel methods for machine learning are ubiquitous in pattern recognition, with support vector machines (SVMs) being the best known method for classification problems. However, there are limi-

tations to the successful solution to such classification problems when the feature space becomes large, and the kernel functions become computationally expensive to estimate. A core element in the computational speed-ups enabled by quantum algorithms is the exploitation of an exponentially large quantum state space through controllable entanglement and interference. Here we propose and experimentally implement two quantum algorithms on a superconducting processor. A key component in both methods is the use of the quantum state space as feature space. The use of a quantum-enhanced feature space that is only efficiently accessible on a quantum computer provides a possible path to quantum advantage. The algorithms solve a problem of supervised learning: the construction of a classifier. One method, the quantum variational classifier, uses a variational quantum circuit^{1,2} to classify the data in a way similar to the method of conventional SVMs. The other method, a quantum kernel estimator, estimates the kernel function on the quantum computer and optimizes a classical SVM. The two methods provide tools for exploring the applications of noisy intermediate-scale quantum computers³ to machine learning.

I-BASE (2023a). «14. How CD4 and viral load are related».

<https://i-base.info/ttfa/section-2/14-how-cd4-and-viral-load-are-related/>. Accessed: 2025-06-07.

— (2023b). «Symptoms and seroconversion».

<https://i-base.info/guides/testing/symptoms-and-seroconversion>. Accessed: 2025-06-07.

IBM, QUANTUM (2025). «IBM Quantum Technology».

<https://www.ibm.com/quantum/technology>. Accessed: 2025-03-29.

JAKOBSEN, JANUS CHRISTIAN; GLUUD, CHRISTIAN; WETTERSLEV, JØRN y WINKEL, PER (2017). «When and how should multiple imputation be used for handling missing data in randomised clinical trials – a practical guide with flowcharts». *BMC Medical Research Methodology*, 17, p. 162.

<https://doi.org/10.1186/s12874-017-0442-1>.

JIN, JUAN; LI, TINGTING; CHEN, JIE; BA, HUANHUAN; ZHANG, YUAN; LI, JIAJIA; YIN, JINLING; LIU, HUANQING y MA, KANGXIAO (2026). «Predicting immune reconstitution after antiretroviral therapy in HIV/AIDS using ensemble machine learning: a real-world study». *Frontiers in Immunology*, 17, p. 1805202.

<https://doi.org/10.3389/fimmu.2026.1805202>.

LI, BINGXIANG; LI, MINGYU; SONG, YU; LU, XIAONING; LIU, DAJIN; HE, CHENGLU; ZHANG, RUIXIAN; WAN, XINRUI; ZHANG, RENNING; SUN, MING; KUANG, YI-QUN y LI, YA (2022). «Construction of Machine Learning Models to Predict Changes in Immune Function Using Clinical Monitoring Indices in HIV/AIDS Patients After 9.9-Years of Antiretroviral Therapy in Yunnan, China». *Frontiers in Cellular and Infection Microbiology*, 12, p. 867737.

<https://doi.org/10.3389/fcimb.2022.867737>.

LUQUE CALVO, PEDRO L. (2017). *Escribir un Trabajo Fin de Estudios con R Markdown*.

<http://destio.us.es/calvo>.

- (2019). *Cómo crear Tablas de información en R Markdown*.
<http://destio.us.es/calvo>.
- LUQUE CALVO, PEDRO L. (2021). «Página personal de Pedro L. Luque».
<http://destio.us.es/calvo>.
- MENDOZA, NADIA B.; LIN, CHII-DEAN; KIENE, SUSAN M.; MENZIES, NICOLAS A.; WANYENZE, RHODA K.; SCHMARJE, KATHERINE A.; NAIGINO, ROSE; EDIAU, MICHAEL; KALICHMAN, SETH C. y BAILEY, BARBARA A. (2024). «Evaluating Imputation Methods to Improve Prediction Accuracy for an HIV Study in Uganda». *Stats*, 7(4), pp. 1405–1420.
<https://doi.org/10.3390/stats7040082>.
- MICROSOFT AZURE QUANTUM (2025). «Azure Quantum». Online.
<https://azure.microsoft.com/en-us/products/quantum/>. Accessed: 2025-12-12.
- NVIDIA (2025). «NVIDIA cuQuantum SDK». Online.
<https://developer.nvidia.com/cuquantum-sdk>. Accessed: 2025-12-12.
- OSTMEYER, JOHANN y URBACH, CARSTEN (2023). *qsimulatR: A Quantum Computer Simulator*.
<https://CRAN.R-project.org/package=qsimulatR>. R package version 1.1.1.
- ÖZLÜER BAŞER, BILGE (2022). «Analyzing the competition of HIV-1 phenotypes with quantum game theory». *Gazi University Journal of Science*, 35(3), pp. 1190–1198.
<https://doi.org/10.35378/gujs.772616>.
- PALIULIS, SKALVIS (2024). «Investigation of Classification Algorithms in Quantum Computing». Master's thesis, Vilnius University, Faculty of Mathematics and Informatics, Vilnius, Lithuania. VU email: skalvis.paliulis@mif.stud.vu.lt.
- PAN, BINGHUANG y YU, ZHAOYUAN (2024). *QWDAP: Quantum Walk-Based Data Analysis and Prediction*.
<https://CRAN.R-project.org/package=QWDAP>. R package version 1.1.20.
- PERUZZO, A; MCCLEAN, J; SHADBOLT, P; YUNG, MH; ZHOU, XQ; LOVE, PJ; ASPURUGUZIK, A y O'BRIEN, JL (2014). «A variational eigenvalue solver on a photonic quantum processor». *Nature Communications*, p. 4213.
[https://doi.org/10.1038/ncomms5213\(2014\)](https://doi.org/10.1038/ncomms5213(2014)).
- QISKIT DEVELOPMENT TEAM (2024). «Qiskit: An Open-Source Quantum Computing Framework». Online.
<https://qiskit.org/>. Accessed: 2024-03-29.
- R CORE TEAM (2016). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria.
<https://www.R-project.org/>.
- RESCH, SALONIK (2020). *QuantumOps: Performs Common Linear Algebra Operations Used in Quantum Computing and Implements Quantum Algorithms*.
<https://CRAN.R-project.org/package=QuantumOps>. R package version 3.0.1.
- ROBERT, A; BARKOUTSOS, PK; WOERNER, S y TAVERNELLI, I (2021). «Resource-efficient quantum algorithm for protein folding». *Npj Quantum Inf.*, 7(1).
<https://doi.org/https://doi.org/10.1038/s41534-021-00368-4>.

- ROOSAN, D.; KHAN, R.; ASHAKIN, M. R.; KHOU, T.; NIRZHOR, S. y HAIDER, M. R. (2026). «Quantum Variational Transformer Model for Enhanced Cancer Classification». En *Proceedings of the 7th International Conference on Industrial Engineering and Artificial Intelligence*, Krabi, Thailand.
- ROOSAN, D.; KHAN, R.; KHOU, T.; NIRZHOR, S.; HAI, F. y PROVENCHER, B. (2025a). «Bridging Classical Molecular Dynamics and Quantum Foundations for Comprehensive Protein Structural Analysis». *arXiv preprint*.
- ROOSAN, D.; KHOU, T.; NIRZHOR, S.; KHAN, R.; HAI, F.; ESSIEN-ALEKSI, I. y BASKYS, A. (2025b). «Harnessing Quantum and Liquid Neural Networks for Drug Repurposing in Neurology». En F. L. Gaol; Y. Xu y Y. Dessouky (Eds.), *Management Science and Industrial Engineering, Advances in Transdisciplinary Engineering*, pp. 29–36. Bai Island, Indonesia.
- ROOSAN, D.; NIRZHOR, S. y KHAN, R. (2025c). «Integrating Pharmacokinetics and Pharmacodynamics Modeling with Quantum Regression for Predicting Herbal Compound Toxicity». En *Proceedings of the 2025 World Congress in Computer Science, Computer Engineering, and Applied Computing*, Las Vegas, USA.
- ROOSAN, D.; NIRZHOR, S.; KHAN, R. y HAI, F. (2025d). «Quantum Gradient Optimized Drug Repurposing Prototype for Omics Data». En *Proceedings of the 14th International Conference on Data Science, Technology and Applications*, Bilbao, Spain.
- ROOSAN, D.; SAMROSE, S.; KHAN, R.; NIRZHOR, S. y PROVENCHER, B. (2025e). «Quantum Analysis of Protein-Ligand Binding by Integrating Structural Resolution, Sequence Homology, and Ligand Properties». En *Proceedings of the Obesity, Fitness and Wellness Week*, Atlanta, GA, USA.
- ROOSAN, DON; NIRZHOR, SAIF; KHAN, RUBAYAT; HAI, FAHMIDA y HAIDAR, MOHAMMAD RIFAT (2025f). «Quantum Approximate Optimization Algorithm for Spatiotemporal Forecasting of HIV Clusters». <https://arxiv.org/abs/2507.00848>.
- RSTUDIO TEAM (2015). *RStudio: Integrated Development Environment for R*. RStudio, Inc., Boston, MA. <http://www.rstudio.com/>.
- SALGADO JIMENEZ, MARÍA DE LOS ÁNGELES; ACUÑA GONZÁLEZ, JUAN PABLO; JOANICO MORALES, BALTAZAR y VILLAGÓMEZ MÉNDEZ, JUAN (2024). «Análisis de conglomerados usando la distancia Euclidiana en el comportamiento de linfocitos T CD4». *Revista Cubana de Higiene y Epidemiología*, 61, e1485. ID LILACS: biblio-1569836.
- SALGADO JIMÉNEZ, MARÍA DE LOS ÁNGELES; DE LA O ECHEVERRÍA, RAFAEL; BALTAZAR, JOANICO MORALES y FRANCO RÍOS, JORGE JANEMAN (2025). «Predicción de Linfocitos T CD4 en Personas Coinfectadas por VIH y Tuberculosis en Guerrero: Estudio de Cohorte en Área Endémica». *Ciencia Latina Revista Científica Multidisciplinar*, 9(3), pp. 6440–6454. https://doi.org/10.37811/cl_rcm.v9i3.18277.
- SALGADO-JIMÉNEZ, MARÍA DE LOS ÁNGELES; VILLAGÓMEZ-MÉNDEZ, JUAN; JOANICO-MORALES, BALTAZAR y CORTÉS-RAFAEL, MUSTAFÁ (2020). «Importancia de la predicción de linfocitos T CD4 en el VIH mediante la teoría de los conjuntos y la probabi-

lidad». *Medicina Interna de México*, 36(2), pp. 159–165.
<https://doi.org/10.24245/mim.v36i2.3119>.

SCRIBA, THOMAS J.; ZHANG, HUA-TANG; BROWN, HELEN L.; OXENIUS, ANNETTE; TAMM, NORBERT; FIDLER, SARAH; FOX, JULIE; WEBER, JONATHAN N.; KLENERMAN, PAUL; DAY, CHERYL L.; LUCAS, MICHAELA y PHILLIPS, RODNEY E. (2005). «HIV-1specific CD4+ T lymphocyte turnover and activation increase upon viral rebound». *The Journal of Clinical Investigation*, 115(2), pp. 443–450.
<https://doi.org/10.1172/JCI23084>.
<https://www.jci.org/articles/view/23084>.

SETH, NILUFER; KAUFMANN, DANIEL; LAHEY, TIMOTHY; ROSENBERG, ERIC S. y WUCHERPENNIG, KAI W. (2005). «Expansion and Contraction of HIV-Specific CD4 T Cells with Short Bursts of Viremia, but Physical Loss of the Majority of These Cells with Sustained Viral Replication1». *The Journal of Immunology*, 175(10), pp. 6948–6958. ISSN: 0022-1767.
<https://doi.org/10.4049/jimmunol.175.10.6948>.
<https://doi.org/10.4049/jimmunol.175.10.6948>.

SIMÕES, RICARDO DANIEL MONTEIRO; HUBER, PATRICK; MEIER, NICOLA; SMAILOV, NIKITA; FUCHSLIN, RUDOLF M y STOCKINGER, KURT (2023). «Experimental evaluation of quantum machine learning algorithms». *IEEE Access*, 11, pp. 6197–6208.

RESUMEN: Machine learning and quantum computing are both areas with considerable progress in recent years. The combination of these disciplines holds great promise for both research and practical applications. Recently there have also been many theoretical contributions of quantum machine learning algorithms with experiments performed on quantum simulators. However, most questions concerning the potential of machine learning on quantum computers are still unanswered such as How well do current quantum machine learning algorithms work in practice? How do they compare with classical approaches? Moreover, most experiments use different datasets and hence it is currently not possible to systematically compare different approaches. In this paper we analyze how quantum machine learning can be used for solving small, yet practical problems. In particular, we perform an experimental analysis of kernel-based quantum support vector machines and quantum neural networks. We evaluate these algorithm on 5 different datasets using different combinations of quantum feature maps. Our experimental results show that quantum support vector machines outperform their classical counterparts on average by 3 to 4 % in accuracy both on a quantum simulator as well as on a real quantum computer. Moreover, quantum neural networks executed on a quantum computer further outperform quantum support vector machines on average by up to 5 % and classical neural networks by 7 %.

SORET, PERRINE; AVALOS, MARTA; WITTKOP, LINDA; COMMENGES, DANIEL y THIÉBAUT, RODOLPHE (2018). «Lasso regularization for left-censored Gaussian outcome and high-dimensional predictors». *BMC Medical Research Methodology*, 18, p. 159.
<https://doi.org/10.1186/s12874-018-0609-4>.

SUN, RUI; GAO, BINYU; ZHANG, HANXI; WANG, XI; LIU, FANG; ZHAO, HONGXIN; SUN, LIJUN; YU, JIANHUA; LIU, HONGLEI y ZHANG, FUJIE (2026). «Early prediction of immunological non-responders in people living with HIV using machine learning: Model

- development and validation in multicenter cohorts in China». *Journal of Infection and Public Health*, 19, p. 103116.
<https://doi.org/10.1016/j.jiph.2025.103116>.
- TEAM, R CORE (2024). «The Comprehensive R Archive Network (CRAN)». Online.
<https://cran.r-project.org/>. Accessed: 2024-03-29.
- THE QISKIT NATURE DEVELOPERS AND CONTRIBUTORS (2023). «Qiskit Nature 0.6.0». <https://doi.org/https://doi.org/10.5281/zenodo.7828767>.
<https://github.com/qiskit-community/qiskit-nature>.
- VAN ROSSUM, GUIDO y THE PYTHON DEVELOPMENT TEAM (2024). *Python: A Dynamic, Open-Source Programming Language*. Python Software Foundation.
<https://www.python.org/>. Accessed: 2024-03-29.
- XANADU QUANTUM TECHNOLOGIES (2024). «PennyLane: Machine Learning with Quantum Computers». Online.
<https://pennylane.ai/>. Accessed: 2024-03-29.
- XIE, YIHUI (2025). *knitr: A General-Purpose Package for Dynamic Report Generation in R*.
<https://yihui.org/knitr/>. R package version 1.50.